CID
1. Introdução
1.2 - *Big Data*
prof. Cláudio Zaina
IFSP - Pres. Epitácio

- introdução
  - história
    - consolidação de grandes bases de dados
    - décadas 1960-1970
      - primeiros *datacenters*
      - desenvolvimento de BD relacional
    - 2005
      - interesse pelos dados gerados
        - Facebook
        - Youtube
      - Hadoop
        - facilidade
        - armazenamento baixo custo
      - NoSQL
    - IoT
    - *Machine Learning*
  - Problemas x Propostas
    - cenário: clientes desejam acessar conjunto de dados

tipo de distribuição	Centralizado	Replicado	Distribuído
características	→ um repositório central → processa pedidos → envia aos clientes	→ servidores com réplica → clientes acessam réplicas	→ vários servidores → cada servidor tem **parte** dos dados → partes são replicadas em diferentes servidores
capacidade de armazenamento	→ limitada à capacidade de um servidor	→ limitada à capacidade de um servidor	→ limitada ao número de servidores
fila de pedidos	→ limitada à capacidade de um servidor	→ limitada ao número de servidores	→ limitada ao número de servidores
tempo de atendimento	→ depende do número de clientes	→ depende da relação clientes / servidores	→ depende da relação clientes / servidores
busca indexação	→ simples	→ simples	→ complexa
falhas temporárias	→ atrasam resposta para todos clientes	→ atrasam resposta para alguns clientes	→ atrasam resposta para alguns clientes
falhas permanentes	→ falhas não são toleradas	→ n-1 falhas toleradas em n servidores	→ toleradas se mitigadas pela replicação
resumo	→ não escala em armazenamento → não escala em número de clientes	→ administração simples dos dados → não escala em armazenamento	→ administração complexa dos dados → consistência

adaptado de Lucas Wanner (Big Data)

- Os *V*s de *Big Data*
  - **volume**
    - grandes volumes de dados não estruturados
    - talvez de valor desconhecido
      - postagens no Twitter
      - fluxos de cliques
        - portal *web*
        - app
      - sensores
      - dezenas de terabytes
        - centenas de petabytes
    - mais de
      - 1,7 bilhões em redes sociais
      - bilhões de celulares
      - 3 milhões de emails / segundo
      - 100 horas de vídeo / minuto carregados no youtube
      - 100 Tb / dia carregado no facebook
    - 92% dos dados do mundo gerados nos últimos 2 anos
  - **velocidade**
    - alta taxa em que dados são
      - recebidos
      - administrados
    - talvez direto para a memória
    - tempo real (ou quase)
      - operação
      - avaliação
      - resposta
  - **variedade**
    - diversidade de tipos de dados disponíveis
    - tradicionalmente estruturados e adequados a BD relacional
    - novos tipos
    - semiestruturados
    - não estruturados
      - sem relação entre si
      - sem estrutura precisa
      - como
        - texto
        - áudio
        - vídeo
        - *posts*
    - necessário pré-processamento
  - veracidade
    - quanto se pode confiar nos dados?
    - fonte?
    - qualidade?
  - valor
    - dados tem valor
      - mas qual é?
- benefícios
  - utilização de mais informação
    - respostas mais completas
      - maior confiança nas soluções
- aplicação
  - atender desejos não expressos
    - sugestões
  - previsão
    - venda
    - tráfego
  - verificação
    - validação de mobilidade humana na pandemia
  - casos de uso
    - desenvolvimento de produtos
      - antecipar demanda
        - Netflix
        - Procter & Gamble
      - modelos para novos
        - produtos
        - serviços
    - manutenção preditiva
      - previsão de falhas
        - dados estruturados
          - ano
          - modelo
          - marca
        - dados não-estruturados
          - *logs*
          - leituras de sensores
    - experiência do cliente
      - visão clara da experiência do cliente
      - consolidação de dados
        - mídias sociais
        - visitas na *web*
        - registros de chamada
      - oferta personalizadas
      - abordagem proativa de problemas
    - fraude e conformidade
      - ataques são profissionais
      - identificação de padrões
        - dados indicam fraude
    - *machine learning*
      - dados permitem ensinar máquinas
        - bons resultados
        - rápidos
    - eficiência operacional
      - analisar e avaliar
        - produção
        - retorno de clientes
      - prever e reduzir interrupções
      - antecipar demandas
      - tomada de decisão
    - inovação
      - estudar interdependências entre
        - humanos
        - instituições
        - processos
      - aprimorar decisões e planejamentos
      - estar preparado para tendências
      - preços dinâmicos
- desafios
  - volume
    - dobra a cada dois anos
    - eficiência
      - armazenar
      - consultar
  - limpeza
  - 50 a 80% do tempo dos profissionais da área
    - limpeza
    - relevância
  - evolução da tecnologia
    - Hadoop → Spark→ ambos
- passos
  - 1 - integração
    - dados vem de diversas fontes
    - ETL tradicional não é suficiente
      - **E***xtract* - extrair
      - **T***ransform* - transformar
      - **L***oad* - carregar
    - escala terabyte → petabyte → zetabyte
  - 2 - gerenciamento
    - armazenamento
      - local
      - nuvem
      - ambos
    - equilíbrio
      - necessidade
      - utilização
      - de
        - dados
        - processamento
  - 3 - análise
    - investimento só compensa
      - se há análise dos dados
      - age conforme resultados
- *Map Reduce*
  - modelo inspirado em linguagens funcionais
    - operações
      - especializadas
      - independentes
      - paralelas
  - processamento em volume
    - alto
      - desempenho
      - escalabilidade
  - mapeia parcelas dos dados → função de processamento
  - milhares de agentes
    - cada um calculando um resultado parcial
  - reordena resultados parciais
  - envio de resultados parciais para um *redutor*
  - redutor combina resultados parciais em resultado final
  - **Exemplo:**
  - Identificar amigos em comum em rede social
  - Facebook
    - ~ 3 bilhões de usuários
    - cada usuário ~ 330 "amigos"
    - ~ 1 trilhão (1 000 000 000 000) de conexões
  - estratégia distribuída
    - supondo os usuários:

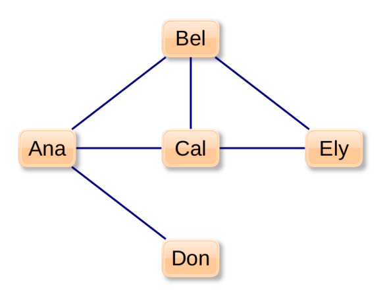

    - informar para cada amigo seus *outros* amigos — ***map*** — paralelo!
    - comparar e unificar as listas de amigos — ***reduce*** — paralelo!
  - Amigos:
    - Ana: {Bel, Cal, Don}
    - Bel: {Ana, Cal, Ely}
    - Cal: {Ana, Bel, Ely}
    - Don: {Ana}
    - Ely: {Bel, Cal}
  - **1. *Map***
    - gerar os pares chave-valor (*key-value*) de usuário e alguém
    - **Ana**: {Bel, Cal, Don}
      - ((Ana, Bel), {Bel, Cal, Don})
      - ((Ana, Cal), {Bel, Cal, Don})
      - ((Ana, Don), {Bel, Cal, Don})
    - **Bel**: {Ana, Cal, Ely}
      - ((Ana, Bel), {Ana, Cal, Ely})
        - Repare que (Bel, Ana) → (Ana, Bel)
        - *ordenado!*
      - ((Bel, Cal), {Ana, Cal, Ely})
      - ((Bel, Don), {Ana, Cal, Ely})
    - **Cal**: {Ana, Bel, Ely}
      - ((Ana, Cal), {Ana, Bel, Ely})
      - ((Bel, Cal), {Ana, Bel, Ely})
      - ((Cal, Ely), {Ana, Bel, Ely})
    - **Don**: {Ana}
      - ((Ana, Don), {Ana})
    - **Ely**: {Bel, Cal}
      - ((Bel, Ely), {Bel, Cal})
      - ((Cal, Ely), {Bel, Cal})
  - **2. Unificar**
    - mesmas *chaves* têm coletados seus *valores*
    - ((Ana, Bel), {{Bel, Cal, Don}, {Ana, Cal, Ely}})
    - ((Ana, Cal), {{Bel, Cal, Don}, {Ana, Bel, Ely}})
    - ((Ana, Don), {{Bel, Cal, Don}, {Ana}})
    - ((Bel, Cal), {{Ana, Cal, Ely}, {Ana, Bel, Ely}})
    - ((Bel, Ely), {{Ana, Cal, Ely}, {Bel, Cal}})
    - ((Cal, Ely), {{Ana, Bel, Ely}, {Bel, Cal}})
  - **3. *Reduce***
    - processa os *maps* consolidando o resultado — aqui, **amigos em comum**
    - ((Ana, Bel), {{Bel, **Cal**, Don}, {Ana, **Cal**, Ely}}) → ((Ana, Bel), {Cal})
    - ((Ana, Cal), {{**Bel**, Cal, Don}, {Ana, **Bel**, Ely}}) → ((Ana, Cal), {Bel})
    - ((Ana, Don), {{Bel, Cal, Don}, {Ana}}) → ((Ana, Don), { })
    - ((Bel, Cal), {{**Ana**, Cal, **Ely**}, {**Ana**, Bel, **Ely**}}) → ((Bel, Cal), {Ana, Ely})
    - ((Bel, Ely), {{Ana, **Cal**, Ely}, {Bel, **Cal**}}) → ((Bel, Ely), {Cal})
    - ((Cal, Ely), {{Ana, **Bel**, Ely}, {**Bel**, Cal}}) → ((Cal, Ely), {Bel})
  - Propriedades
    - total paralelismo
      - mapeamento é completamente independente
        - escalável!
    - processamento simples
- boas práticas
  - alinhar com objetivos de negócio específicos
    - mais dados permitem novas descobertas
    - investir
      - habilidades
      - infraestrutura
      - continuamente em projetos
    - perguntar sempre
      - como *Big Data* apoia / possibilita
        - evolução negócios
        - determinação prioridades
    - exemplos
      - como entender comportamento de compra online
      - como capturar emoção dos usuários nas mídias sociais
      - como correlacionar
        - dados de clientes
        - produtos
        - produção
        - engenharia
  - diminuir escassez de habilidades com padrões e governança
    - garantir que subprodutos sejam adicionados à cadeia de governança em TI
      - tecnologia
      - resultados
      - decisões
    - avaliar necessidade de habilidades
      - antecedência
      - frequência
    - identificar proativamente escassez
  - otimizar a transferência de conhecimento
    - criar "centro de excelência"
      - compartilhar conhecimento
      - administrar supervisão
      - garantir comunicação
    - custos divididos entre departamentos
    - promove maturidade geral da administração da informação
      - sistemática
      - estruturada
  - alinhar dados estruturados com não estruturados
    - base estruturada tende
      - grande
      - completa
    - não estruturada agrega informações pontuais tendem a fazer diferença
    - diferente distinguir sentimentos
      - melhores clientes
      - todos clientes
  - alinhar-se com o modelo de nuvem
    - modelo permite
      - variedade de recursos para experimentação
      - iteratividade
      - vastos domínios de dados
      - áreas restritas criadas sob demanda
- ***Exercícios***
  1. Por que Big Data não é só a administração de um imenso volume de dados?
  2. Discorra sobre três casos de uso em que Big Data é fundamental.
  3. Por que se gasta tanto esforço em Big Data com limpeza e validação dos dados?
- referências
  - Introdução à Ciência de Dados — Fernando Amaral
  - Oracle — `www.oracle.com/br/big-data/what-is-big-data`