Limpeza_Dados_R

August 19, 2022

1 Limpeza de Dados em R

Bibliotecas úteis

[1]:
```
library(repr)
```

Prepraração do ambiente:

[4]:
```
# Ajusta Jupyter para que gráficos sejam 11 x 5
options(repr.plot.width=11,repr.plot.height=5)
```

1.1 Carga

1.1.1 Obtenção dos dados

[5]:
```
# eliminar todas variáveis definidas até aqui
rm(list=ls())
```

O comando `read.table` é o comando genérico para leitura de dados na forma de tabela de dados. Há uma forma mais pré-configurada para ler arquivos texto separados por vírgula (ou *comma separated values* - CSV - como é conhecido). O comando é `read.csv`.

- ler os dados de `arquivo.csv`;
- o nome das variáveis está na primeira linha `header=TRUE`;
- o separador entre os valores é a `,` (`sep=","`).

dados <- read.csv("arquivo.csv", header=TRUE, sep=",") É possível ler já descompactando de um arquivo compactado (zip, gz etc) informando qual é o arquivo dentro do arquivo .zip.

[19]:
```
# ler dados de um arquivo compactado, com valores separados por ";",
# sem nome das variáveis na primeira linha
cepagri_00 <- read.csv(unzip("cepagri_2017_2022.zip","cepagri_2017_2022.csv"),
                       sep=";", header=FALSE)
```

Os dados:

[20]:
```
head(cepagri_00,10)
tail(cepagri_00,10)
```

A data.frame: 10 × 5

	V1 <chr>	V2 <chr>	V3 <dbl>	V4 <dbl>	V5 <dbl>
1	01/01/2017-00:00	22.2	16.2	83.9	21.1
2	01/01/2017-00:10	[ERRO]	NA	NA	NA
3	01/01/2017-00:20	[ERRO]	NA	NA	NA
4	01/01/2017-00:30	[ERRO]	NA	NA	NA
5	01/01/2017-00:40	[ERRO]	NA	NA	NA
6	01/01/2017-00:50	[ERRO]	NA	NA	NA
7	01/01/2017-01:00	[ERRO]	NA	NA	NA
8	01/01/2017-01:10	[ERRO]	NA	NA	NA
9	01/01/2017-01:20	21.7	4.0	84.7	20.6
10	01/01/2017-01:30	21.5	9.2	87.6	20.3

A data.frame: 10 × 5

	V1 <chr>	V2 <chr>	V3 <dbl>	V4 <dbl>	V5 <dbl>
282365	07/06/2022-08:00	15.8	6.4	81.5	14.0
282366	07/06/2022-08:10	16.7	3.9	79.9	15.1
282367	07/06/2022-08:20	17.5	5.0	77.5	16.0
282368	07/06/2022-08:30	17.9	6.0	75.5	16.5
282369	07/06/2022-08:40	18.3	6.7	74.5	16.9
282370	07/06/2022-08:50	18.7	6.5	74.3	17.3
282371	07/06/2022-09:00	19.3	5.5	73.2	17.9
282372	07/06/2022-09:10	19.2	5.6	73.1	17.8
282373	07/06/2022-09:20	19.6	5.2	73.2	18.3
282374	07/06/2022-09:30	19.4	4.5	74.1	18.1

As variáveis `V1` a `V5` são, respectivamento o **marco temporal** (*timestamp*) em que ocorreu a medida (variável `horario`), a **temperatura** medida em °C (`temp`), a **velocidade do vento** em km/h (`vento`), a **umidade** do ar em % (`umid`) e a **sensação térmica** em °C (`sensacao`).

[21]:
```
names(cepagri_00) <- c("horario","temp","vento","umid","sensacao")
```

Estrutura do `data frame` que contém os dados:

[22]:
```
str(cepagri_00)
```

```
'data.frame':   282374 obs. of  5 variables:
 $ horario : chr  "01/01/2017-00:00" "01/01/2017-00:10" "01/01/2017-00:20"
"01/01/2017-00:30" …
 $ temp    : chr  "22.2" " [ERRO]" " [ERRO]" " [ERRO]" …
 $ vento   : num  16.2 NA NA NA NA NA NA NA 4 9.2 …
 $ umid    : num  83.9 NA NA NA NA NA NA NA 84.7 87.6 …
 $ sensacao: num  21.1 NA NA NA NA NA NA NA 20.6 20.3 …
```

[23]:
```
# arquivo original em formato R: compacto e eficiente para carregar
save(cepagri_00, file="cepagri_00.RData")
```

[24]:
```
# qualquer problema, pode-se retomar o trabalho daqui descomentando o load:
# load("cepagri_00.RData")
```

[25]:
```
# usando df (data frame) para ficar mais fácil de escrever que cepagri_00
df <- cepagri_00
# liberando o cepagri_00 da memória
rm(cepagri_00)
```

1.1.2 Temperatura como caractere

[26]:
```
# Por quê a temperatura foi importada como texto?
# achar os registros de temperatura que têm caracteres:
linhas <- grep("[A-Za-z]", df$temp)
head(linhas,10)
tail(linhas,10)
```

1. 2 2. 3 3. 4 4. 5 5. 6 6. 7 7. 8 8. 1830 9. 1831 10. 1832

1. 281928 2. 282030 3. 282071 4. 282072 5. 282215 6. 282216 7. 282264 8. 282318 9. 282359 10. 282360

[27]:
```
head(df[linhas,],10)
```

A data.frame: 10 × 5

	horario <chr>	temp <chr>	vento <dbl>	umid <dbl>	sensacao <dbl>
2	01/01/2017-00:10	[ERRO]	NA	NA	NA
3	01/01/2017-00:20	[ERRO]	NA	NA	NA
4	01/01/2017-00:30	[ERRO]	NA	NA	NA
5	01/01/2017-00:40	[ERRO]	NA	NA	NA
6	01/01/2017-00:50	[ERRO]	NA	NA	NA
7	01/01/2017-01:00	[ERRO]	NA	NA	NA
8	01/01/2017-01:10	[ERRO]	NA	NA	NA
1830	14/01/2017-23:10	[ERRO]	NA	NA	NA
1831	14/01/2017-23:20	[ERRO]	NA	NA	NA
1832	14/01/2017-23:30	[ERRO]	NA	NA	NA

Ops, tem valores de temperatura registradas como "[ERRO]" e que causaram a perda dos valores das demais variáveis

[28]:
```
# Excluindo as linhas com "[ERRO]" na temperatura de df
df <- df[-linhas,]
```

[29]:
```
str(df)
```

```
'data.frame':   248008 obs. of  5 variables:
 $ horario : chr  "01/01/2017-00:00" "01/01/2017-01:20" "01/01/2017-01:30"
"01/01/2017-01:40" …
 $ temp    : chr  "22.2" "21.7" "21.5" "21.6" …
 $ vento   : num  16.2 4 9.2 7.8 11.6 0.5 4 5.4 0 0 …
 $ umid    : num  83.9 84.7 87.6 86.4 87.7 87.4 85.3 83.6 82.2 82.3 …
 $ sensacao: num  21.1 20.6 20.3 20.4 20.1 20.2 20.3 20.6 20.9 20.9 …
```

Dispensadas 34366 linhas com problemas. Ainda há texto em `temp`?

[30]:
```
linhas <- grep("[A-Za-z]", df$temp)
linhas
length(linhas)
```

0

Não há mais texto, então pode ser convertida para número:

[31]:
```
df$temp <- as.numeric(df$temp)
```

Como está a estrutura do `data frame`

[32]:
```
str(df)
```

```
'data.frame':   248008 obs. of  5 variables:
 $ horario : chr  "01/01/2017-00:00" "01/01/2017-01:20" "01/01/2017-01:30"
"01/01/2017-01:40" …
 $ temp    : num  22.2 21.7 21.5 21.6 21.2 21.3 21.5 21.7 22 22 …
 $ vento   : num  16.2 4 9.2 7.8 11.6 0.5 4 5.4 0 0 …
 $ umid    : num  83.9 84.7 87.6 86.4 87.7 87.4 85.3 83.6 82.2 82.3 …
 $ sensacao: num  21.1 20.6 20.3 20.4 20.1 20.2 20.3 20.6 20.9 20.9 …
```

Aparentemente, ok.
Mas será?

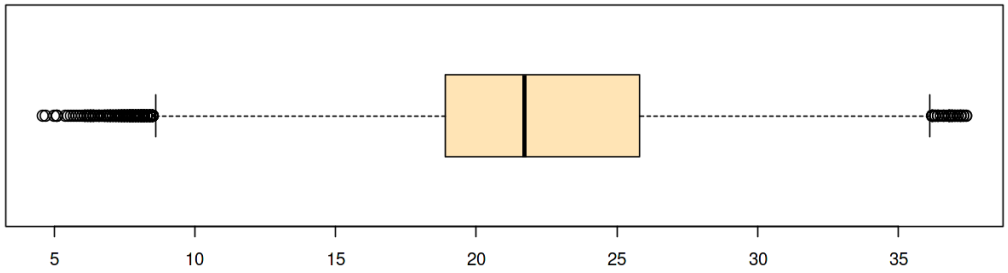
[33]:
```
summary(df)
```

```
  horario              temp           vento             umid
Length:248008      Min.   : 4.60   Min.   :  0.00   Min.   :  0.00
Class :character   1st Qu.:18.90   1st Qu.: 10.70   1st Qu.: 55.10
Mode  :character   Median :21.70   Median : 19.30   Median : 71.10
                   Mean   :22.22   Mean   : 23.01   Mean   : 67.29
                   3rd Qu.:25.80   3rd Qu.: 32.20   3rd Qu.: 81.60
                   Max.   :37.40   Max.   :120.10   Max.   :100.00
   sensacao
Min.   :-0.20
1st Qu.:17.50
Median :20.50
Mean   :20.84
3rd Qu.:24.60
Max.   :99.90
```

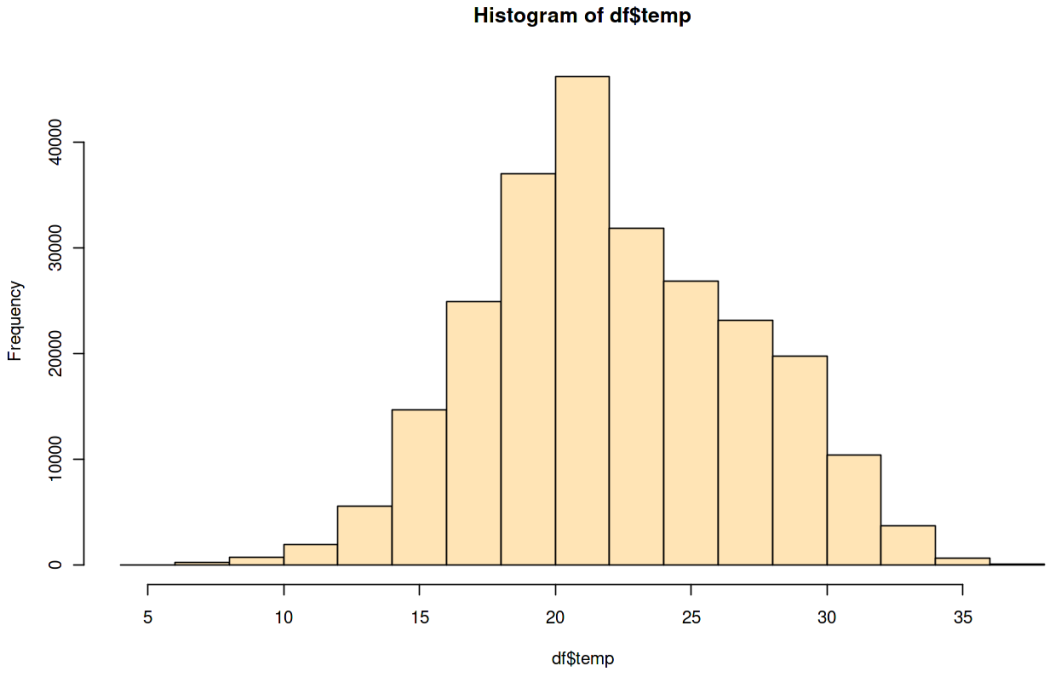
Temperatura Entre 4,6°C e 37,4°C, com média em 22,2°C. Parece Campinas...

[34]:
```
# preparação para ajustar a proporção dos gráficos
library(repr)
options(repr.plot.width=10, repr.plot.height=6)
```

[47]:
```
options(repr.plot.width=11,repr.plot.height=4)
boxplot(df$temp, horizontal=TRUE, cex=1.3, col="moccasin")
```

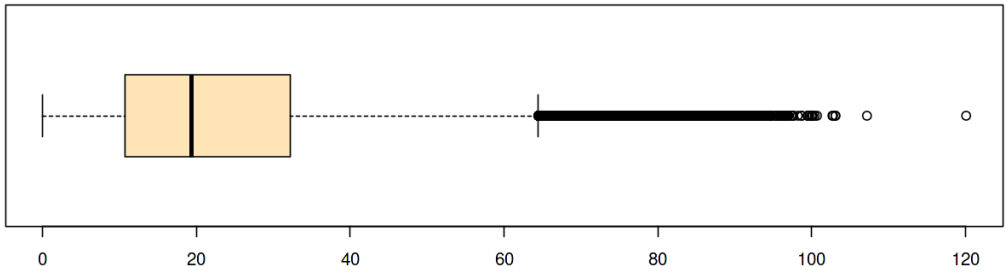


[50]:
```
options(repr.plot.width=11,repr.plot.height=7)
hist(df$temp, col="moccasin")
```

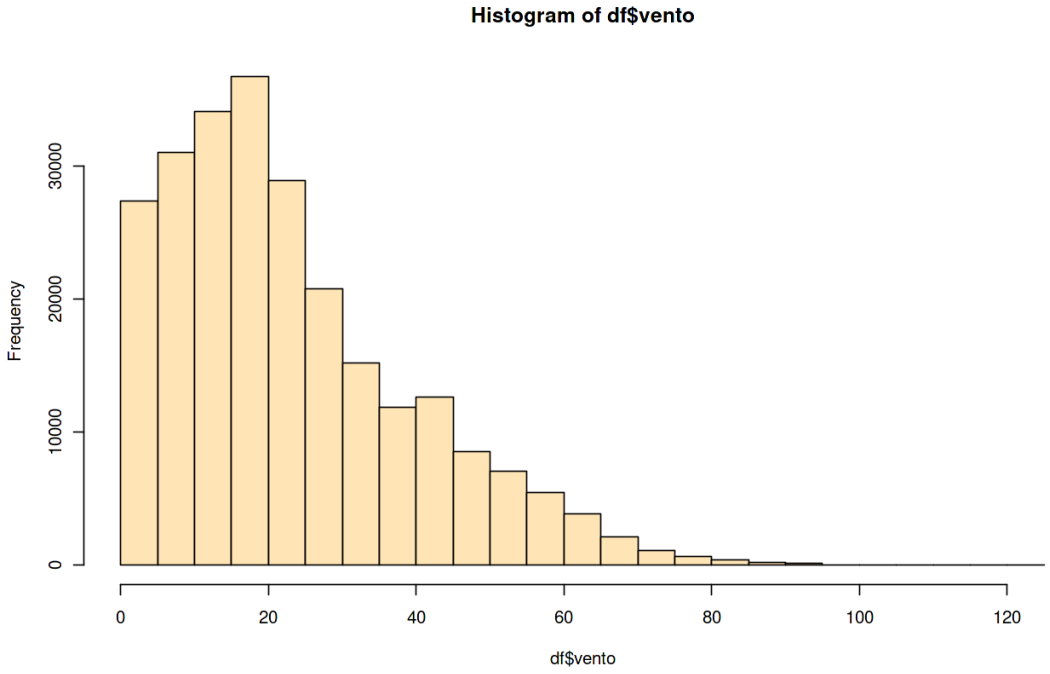


Velocidade do vento Mínimo em 0 km/h e máximo em 120 km/h. **Ops**.

[48]:
```
options(repr.plot.width=11,repr.plot.height=4)
boxplot(df$vento, horizontal=TRUE, col="moccasin")
```



[51]:
```
options(repr.plot.width=11,repr.plot.height=7)
hist(df$vento, col="moccasin")
```



[52]:
```
# quais registros com vento acima de 100 km/h?
df[df$vento > 100,]
```

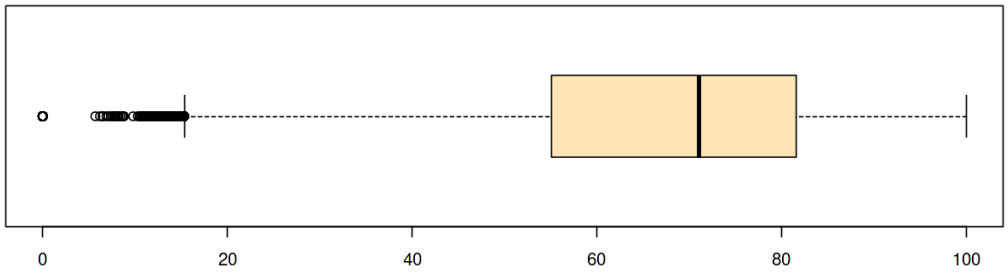
	horario <chr>	temp <dbl>	vento <dbl>	umid <dbl>	sensacao <dbl>
121085	28/04/2019-18:20	20.9	107.2	81.4	19.7
134873	02/08/2019-20:00	19.1	100.1	78.3	17.8
136575	14/08/2019-15:40	17.1	100.1	66.8	15.5
136576	14/08/2019-15:50	17.1	100.1	66.8	15.5
136577	14/08/2019-16:00	17.1	100.1	66.8	15.5
136578	14/08/2019-16:10	17.1	100.1	66.8	15.5
136579	14/08/2019-16:20	17.1	100.1	66.8	15.5
139745	05/09/2019-16:30	18.3	100.1	72.3	16.8
139746	05/09/2019-16:40	18.3	100.1	72.3	16.8
139760	05/09/2019-19:00	15.5	102.8	79.9	13.7
139769	05/09/2019-20:30	15.3	100.4	81.2	13.4
142236	22/09/2019-23:50	15.5	103.1	75.2	13.7
142237	23/09/2019-00:00	15.5	103.1	75.2	13.7
142334	23/09/2019-16:10	20.9	100.1	58.3	19.7
142352	23/09/2019-19:10	15.9	100.7	73.9	14.1
145357	14/10/2019-22:00	22.2	102.7	69.5	21.0
147644	30/10/2019-19:10	19.1	120.1	84.1	17.8

A data.frame: 17 × 5

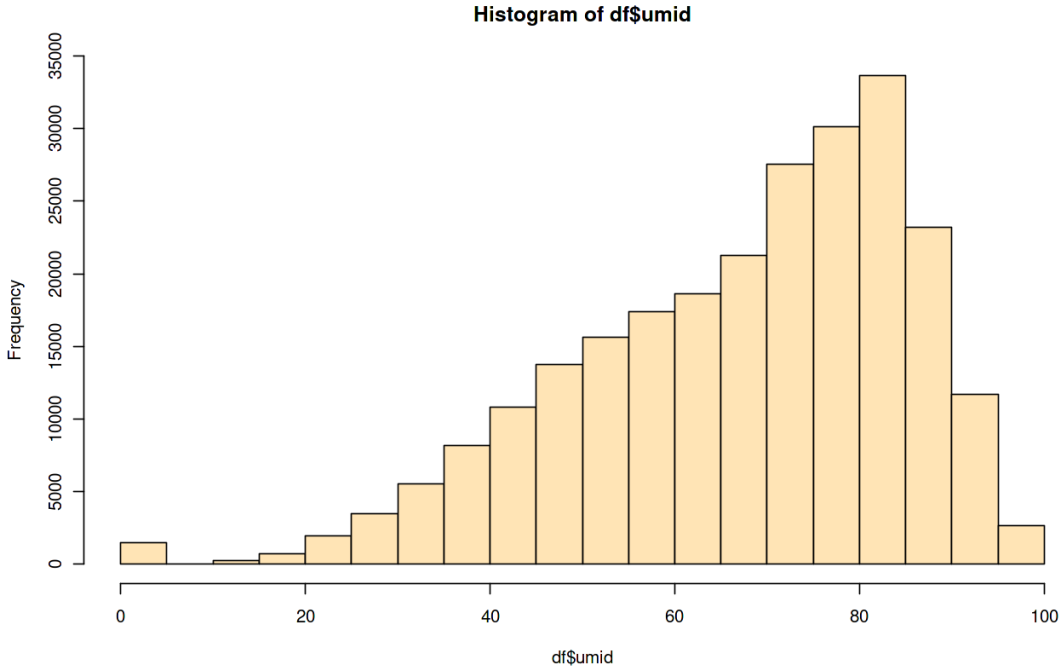
Todos os dias foram em 2019. O que teria acontecido entre abril e outubro de 2019?
Pesquisar o que houve nesses dias, pois ventos de mais de 100 km/h causam grande destruição e, a partir 118 km/h já é considerado furacão.
A propósito, nunca houve furacão em Campinas...

Umidade do ar

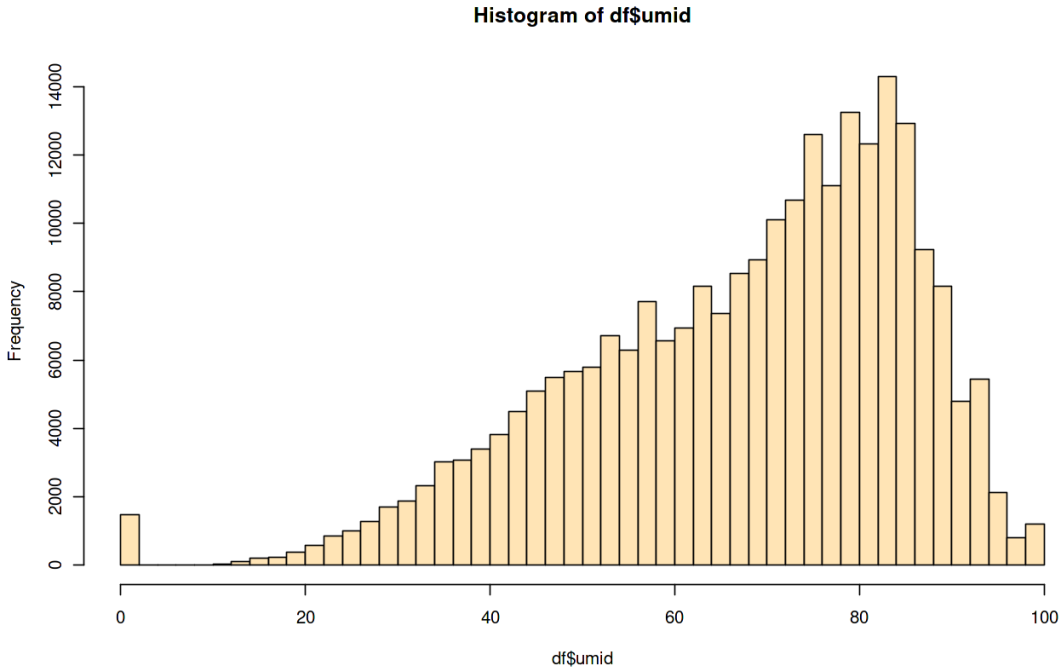
[54]:
```
options(repr.plot.width=11,repr.plot.height=4)
boxplot(df$umid, horizontal=TRUE, col="moccasin")
```



[55]:
```
options(repr.plot.width=11,repr.plot.height=7)
hist(df$umid, col="moccasin")
```



[56]:
```
hist(df$umid, breaks=60, col="moccasin")
```



Tem uma grande quantidade de registros (aparentemente uns 1700) registrando 0% de umidade. É um problema, com certeza, pois *desertos* tem em torno de 10% de umidade...

[57]:
```
df[df$umid == 0, ]
```

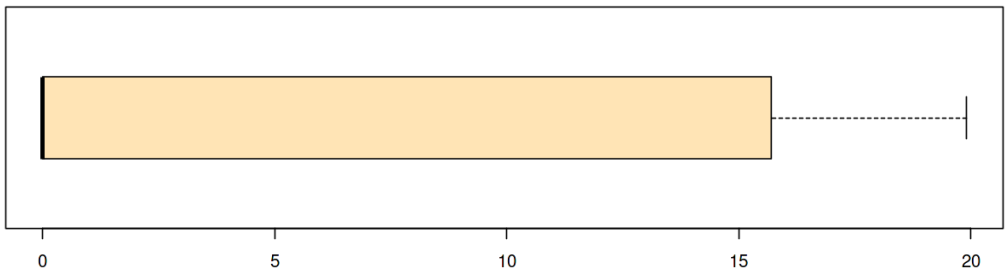
	horario	temp	vento	umid	sensacao
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
104918	05/01/2019-07:00	20.6	17.0	0	19.4
104919	05/01/2019-07:10	20.6	15.7	0	19.5
104920	05/01/2019-07:20	20.6	15.7	0	19.5
104921	05/01/2019-07:30	20.7	14.7	0	19.6
104922	05/01/2019-07:40	20.8	15.2	0	19.6
104923	05/01/2019-07:50	20.8	15.2	0	19.6
104924	05/01/2019-08:00	20.9	15.2	0	19.7
104925	05/01/2019-08:10	20.8	18.6	0	19.7
105062	06/01/2019-07:00	20.4	13.8	0	19.2
105063	06/01/2019-07:10	20.7	15.2	0	19.5
105064	06/01/2019-07:20	21.1	14.8	0	20.0
105065	06/01/2019-07:30	21.1	14.8	0	20.0
105066	06/01/2019-07:40	21.6	11.1	0	20.5
105067	06/01/2019-07:50	21.6	11.1	0	20.5
105068	06/01/2019-08:00	22.0	11.4	0	20.9
105069	06/01/2019-08:10	22.1	14.6	0	21.0
105206	07/01/2019-07:00	20.0	19.9	0	18.8
105207	07/01/2019-07:10	20.3	19.2	0	19.1
105208	07/01/2019-07:20	20.8	14.8	0	19.6
105209	07/01/2019-07:30	20.8	14.8	0	19.6
105210	07/01/2019-07:40	22.2	12.7	0	21.1
105211	07/01/2019-07:50	22.8	11.3	0	21.7
105212	07/01/2019-08:00	22.8	11.3	0	21.7
105213	07/01/2019-08:10	23.2	15.7	0	22.1
105350	08/01/2019-07:00	20.5	15.3	0	19.4
105351	08/01/2019-07:10	20.8	12.4	0	19.6
105494	09/01/2019-07:00	21.1	27.5	0	19.9
105495	09/01/2019-07:10	21.1	23.5	0	20.0
105638	10/01/2019-07:00	21.5	20.3	0	20.3
A data.frame: 1476 × 5 105639	10/01/2019-07:10	21.5	18.8	0	20.4
189851	21/08/2020-07:50	25.6	24.6	0	24.4
189852	21/08/2020-08:00	25.6	24.6	0	24.4
189853	21/08/2020-08:10	25.6	24.6	0	24.4
189854	21/08/2020-08:20	25.6	24.6	0	24.4
189855	21/08/2020-08:30	25.6	24.6	0	24.4
189856	21/08/2020-08:40	25.6	24.6	0	24.4
189857	21/08/2020-08:50	25.6	24.6	0	24.4
189858	21/08/2020-09:00	25.6	24.6	0	24.4
189859	21/08/2020-09:10	25.6	24.6	0	24.4
189860	21/08/2020-09:20	25.6	24.6	0	24.4
189861	21/08/2020-09:30	25.6	24.6	0	24.4
189862	21/08/2020-09:40	25.6	24.6	0	24.4
189863	21/08/2020-09:50	25.6	24.6	0	24.4
189864	21/08/2020-10:00	25.6	24.6	0	24.4
189865	21/08/2020-10:10	25.6	24.6	0	24.4
189866	21/08/2020-10:20	25.6	24.6	0	24.4
189867	21/08/2020-10:30	25.6	24.6	0	24.4
189868	21/08/2020-10:40	25.6	24.6	0	24.4
189869	21/08/2020-10:50	25.6	24.6	0	24.4
189870	21/08/2020-11:00	25.6	24.6	0	24.4

Pois é, 2019 **e** 2020.

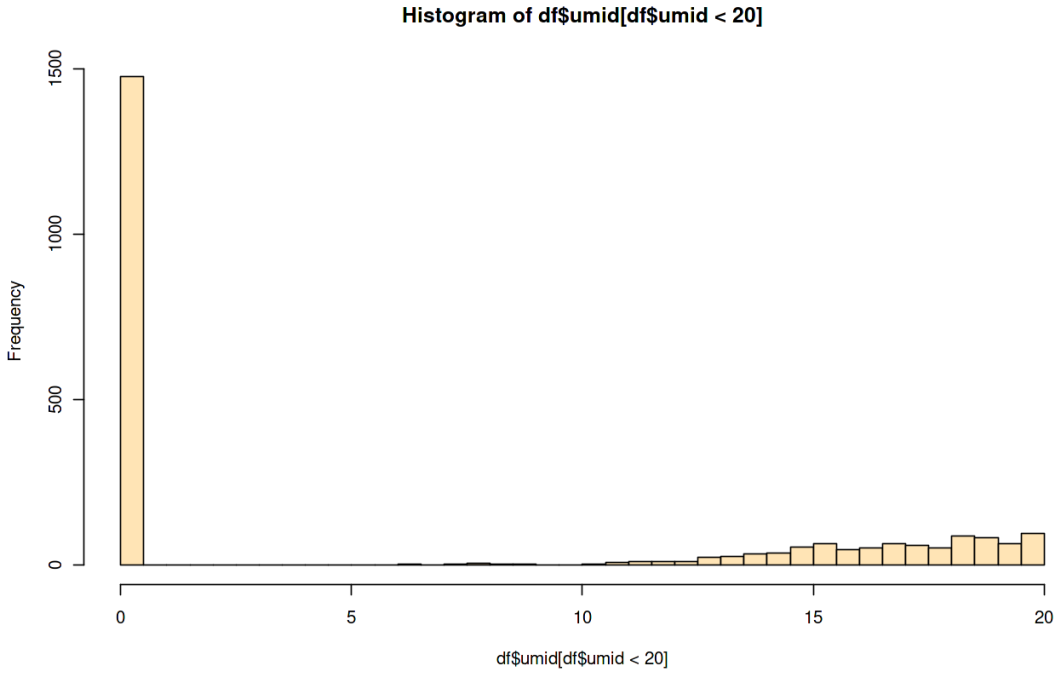
Como se comportaram as medidas abaixo de 20% de umidade?

[58]:
```
cat("há",length(df$umid[df$umid < 20]),"registros abaixo de 20% de umidade")
options(repr.plot.width=11,repr.plot.height=4)
boxplot(df$umid[df$umid < 20], horizontal=TRUE, col="moccasin")
```

```
há 2386 registros abaixo de 20% de umidade
```



[59]:
```
options(repr.plot.width=11,repr.plot.height=7)
hist(df$umid[df$umid < 20], breaks=30, col="moccasin")
```



Registros em torno de 10% são ruins, aparentemente são raros e devem ser estudados.
Observações com 0% são seguramente erros e convém que sejam eliminados.

[60]:
```
linhas <- df$umid != 0
linhas
```

1. TRUE 2. TRUE 3. TRUE 4. TRUE 5. TRUE 6. TRUE 7. TRUE 8. TRUE 9. TRUE 10. TRUE 11. TRUE 12. TRUE 13. TRUE 14. TRUE 15. TRUE 16. TRUE 17. TRUE 18. TRUE 19. TRUE 20. TRUE 21. TRUE 22. TRUE 23. TRUE 24. TRUE 25. TRUE 26. TRUE 27. TRUE 28. TRUE 29. TRUE 30. TRUE 31. TRUE 32. TRUE 33. TRUE 34. TRUE 35. TRUE 36. TRUE 37. TRUE 38. TRUE 39. TRUE 40. TRUE 41. TRUE 42. TRUE 43. TRUE 44. TRUE 45. TRUE 46. TRUE 47. TRUE 48. TRUE 49. TRUE 50. TRUE 51. TRUE 52. TRUE 53. TRUE 54. TRUE 55. TRUE 56. TRUE 57. TRUE 58. TRUE 59. TRUE 60. TRUE 61. TRUE 62. TRUE 63. TRUE 64. TRUE 65. TRUE 66. TRUE 67. TRUE 68. TRUE 69. TRUE 70. TRUE 71. TRUE 72. TRUE 73. TRUE 74. TRUE 75. TRUE 76. TRUE 77. TRUE 78. TRUE 79. TRUE 80. TRUE 81. TRUE 82. TRUE 83. TRUE 84. TRUE 85. TRUE 86. TRUE 87. TRUE 88. TRUE 89. TRUE 90. TRUE 91. TRUE 92. TRUE 93. TRUE 94. TRUE 95. TRUE 96. TRUE 97. TRUE 98. TRUE 99. TRUE 100. TRUE 101. TRUE 102. TRUE 103. TRUE 104. TRUE 105. TRUE 106. TRUE 107. TRUE 108. TRUE 109. TRUE 110. TRUE 111. TRUE 112. TRUE 113. TRUE 114. TRUE 115. TRUE 116. TRUE 117. TRUE 118. TRUE 119. TRUE 120. TRUE 121. TRUE 122. TRUE 123. TRUE 124. TRUE 125. TRUE 126. TRUE 127. TRUE 128. TRUE 129. TRUE 130. TRUE 131. TRUE 132. TRUE 133. TRUE 134. TRUE 135. TRUE 136. TRUE 137. TRUE 138. TRUE 139. TRUE 140. TRUE 141. TRUE 142. TRUE 143. TRUE 144. TRUE 145. TRUE 146. TRUE 147. TRUE 148. TRUE 149. TRUE 150. TRUE 151. TRUE 152. TRUE 153. TRUE 154. TRUE 155. TRUE 156. TRUE 157. TRUE 158. TRUE 159. TRUE 160. TRUE 161. TRUE 162. TRUE 163. TRUE 164. TRUE 165. TRUE 166. TRUE 167. TRUE 168. TRUE 169. TRUE 170. TRUE 171. TRUE 172. TRUE 173. TRUE 174. TRUE 175. TRUE 176. TRUE 177. TRUE 178. TRUE 179. TRUE 180. TRUE 181. TRUE 182. TRUE 183. TRUE 184. TRUE 185. TRUE 186. TRUE 187. TRUE 188. TRUE 189. TRUE 190. TRUE 191. TRUE 192. TRUE 193. TRUE 194. TRUE 195. TRUE 196. TRUE 197. TRUE 198. TRUE 199. TRUE 200. TRUE 201. 202. TRUE 203. TRUE 204. TRUE 205. TRUE 206. TRUE 207. TRUE 208. TRUE 209. TRUE 210. TRUE 211. TRUE 212. TRUE 213. TRUE 214. TRUE 215. TRUE 216. TRUE 217. TRUE 218. TRUE 219. TRUE 220. TRUE 221. TRUE 222. TRUE 223. TRUE 224. TRUE 225. TRUE 226. TRUE 227. TRUE 228. TRUE 229. TRUE 230. TRUE 231. TRUE 232. TRUE 233. TRUE 234. TRUE 235. TRUE 236. TRUE 237. TRUE 238. TRUE 239. TRUE 240. TRUE 241. TRUE 242. TRUE 243. TRUE 244. TRUE 245. TRUE 246. TRUE 247. TRUE 248. TRUE 249. TRUE 250. TRUE 251. TRUE 252. TRUE 253. TRUE 254. TRUE 255. TRUE 256. TRUE 257. TRUE 258. TRUE 259. TRUE 260. TRUE 261. TRUE 262. TRUE 263. TRUE 264. TRUE 265. TRUE 266. TRUE 267. TRUE 268. TRUE 269. TRUE 270. TRUE 271. TRUE 272. TRUE 273. TRUE 274. TRUE 275. TRUE 276. TRUE 277. TRUE 278. TRUE 279. TRUE 280. TRUE 281. TRUE 282. TRUE 283. TRUE 284. TRUE 285. TRUE 286. TRUE 287. TRUE 288. TRUE 289. TRUE 290. TRUE 291. TRUE 292. TRUE 293. TRUE 294. TRUE 295. TRUE 296. TRUE 297. TRUE 298. TRUE 299. TRUE 300. TRUE 301. TRUE 302. TRUE 303. TRUE 304. TRUE 305. TRUE 306. TRUE 307. TRUE 308. TRUE 309. TRUE 310. TRUE 311. TRUE 312. TRUE 313. TRUE 314. TRUE 315. TRUE 316. TRUE 317. TRUE 318. TRUE 319. TRUE 320. TRUE 321. TRUE 322. TRUE 323. TRUE 324. TRUE 325. TRUE 326. TRUE 327. TRUE 328. TRUE 329. TRUE 330. TRUE 331. TRUE 332. TRUE 333. TRUE 334. TRUE 335. TRUE 336. TRUE 337. TRUE 338. TRUE 339. TRUE 340. TRUE

341. TRUE 342. TRUE 343. TRUE 344. TRUE 345. TRUE 346. TRUE 347. TRUE 348. TRUE 349. TRUE 350. TRUE 351. TRUE 352. TRUE 353. TRUE 354. TRUE 355. TRUE 356. TRUE 357. TRUE 358. TRUE 359. TRUE 360. TRUE 361. TRUE 362. TRUE 363. TRUE 364. TRUE 365. TRUE 366. TRUE 367. TRUE 368. TRUE 369. TRUE 370. TRUE 371. TRUE 372. TRUE 373. TRUE 374. TRUE 375. TRUE 376. TRUE 377. TRUE 378. TRUE 379. TRUE 380. TRUE 381. TRUE 382. TRUE 383. TRUE 384. TRUE 385. TRUE 386. TRUE 387. TRUE 388. TRUE 389. TRUE 390. TRUE 391. TRUE 392. TRUE 393. TRUE 394. TRUE 395. TRUE 396. TRUE 397. TRUE 398. TRUE 399. TRUE 400. TRUE 401. TRUE

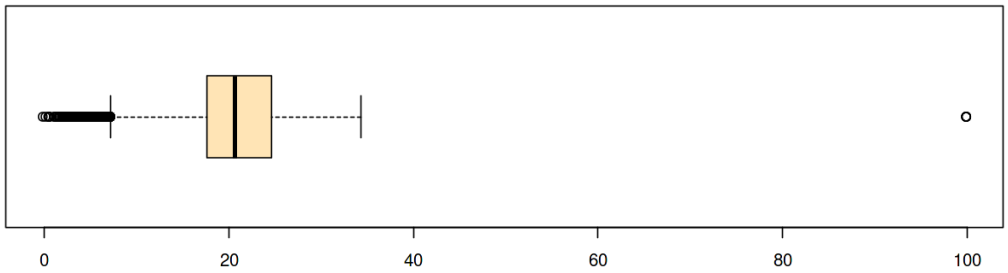
[61]:
```
df <- df[linhas,]
```

[62]:
```
summary(df)
```

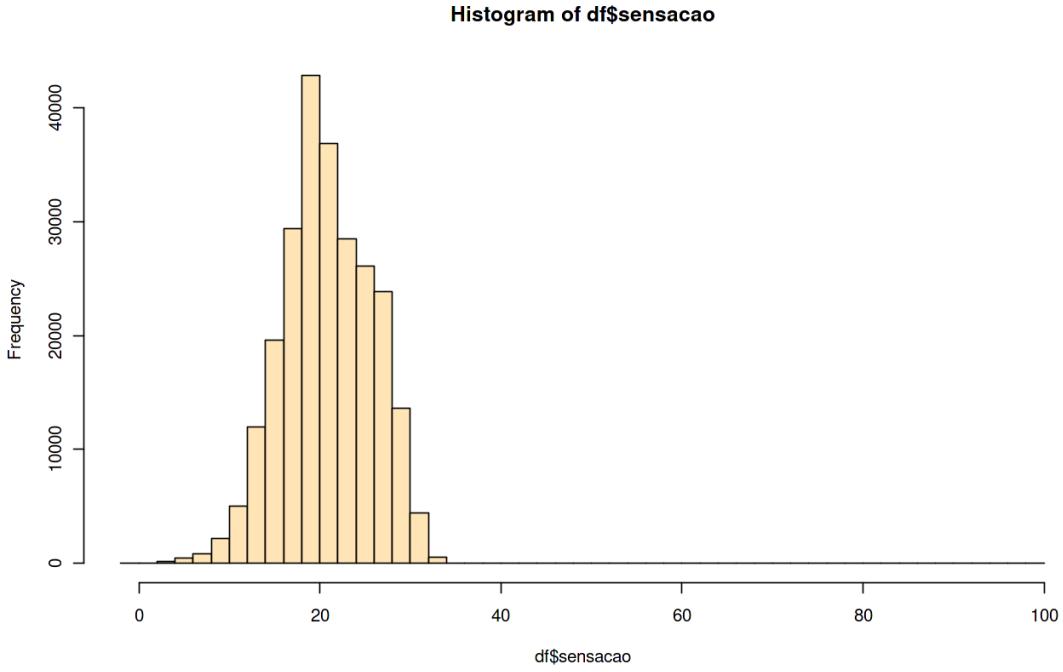
```
  horario               temp           vento            umid       
Length:246532      Min.   : 4.60   Min.   :  0.00   Min.   :  5.70  
Class :character   1st Qu.:18.90   1st Qu.: 10.60   1st Qu.: 55.50  
Mode  :character   Median :21.70   Median : 19.30   Median : 71.10  
                   Mean   :22.23   Mean   : 22.98   Mean   : 67.69  
                   3rd Qu.:25.80   3rd Qu.: 32.20   3rd Qu.: 81.60  
                   Max.   :37.40   Max.   :120.10   Max.   :100.00  
   sensacao      
Min.   :-0.20  
1st Qu.:17.60  
Median :20.60  
Mean   :20.85  
3rd Qu.:24.60  
Max.   :99.90  
```

Sensação térmica Algo estranho nos valores da sensação térmica (`sensacao`)? Quantas vezes você ouviu "Está quente! A sensação térmica de hoje é 100°C" ...

[63]:
```
options(repr.plot.width=11,repr.plot.height=4)
boxplot(df$sensacao, horizontal=TRUE, col="moccasin")
```



[64]:
```
options(repr.plot.width=11,repr.plot.height=7)
hist(df$sensacao, breaks=50, col="moccasin")
```



A distribuição dos valores, diferentemente do caso da umidade, não são contínuos até 100°C. Aparentemente os casos com 100°C são isolados.

[133]:
```
df[df$sensacao > 40,]
```

A data.frame: 5 × 5

	horario <chr>	temp <dbl>	vento <dbl>	umid <dbl>	sensacao <dbl>
87668	07/09/2018-07:10	13.4	37.0	75.3	99.9
87812	08/09/2018-07:10	16.1	26.3	64.5	99.9
87956	09/09/2018-07:10	15.1	28.1	75.8	99.9
88100	10/09/2018-07:10	14.8	33.4	74.5	99.9
88244	11/09/2018-07:10	15.4	34.7	76.2	99.9

Interessante. Há cinco registros com sensação térmica de 99,9°C: são as medidas das 7h10 de 7 a 11 de setembro de 2018. Cinco dias em seguida, no mesmo horário, sendo o primeiro um feriado...

Como estão as medidas *vizinhas*?

[65]:
```
# quais índices das linhas com problemas?
linhas <- which(df$sensacao == 99.9)
linhas
```

1. 86401 2. 86545 3. 86689 4. 86833 5. 86977

[66]:
```
x <- linhas[1]
x
medidas <- df[(x-3):(x+3), "sensacao"]
medidas
media   <- mean(medidas[-4])
media
df[x, "sensacao"] <- media
df[x,]
```

86401

1. 10.3 2. 10.6 3. 10.6 4. 99.9 5. 11.7 6. 12.1 7. 12.4

11.2833333333333

A data.frame: 1 × 5

	horario <chr>	temp <dbl>	vento <dbl>	umid <dbl>	sensacao <dbl>
87668	07/09/2018-07:10	13.4	37	75.3	11.28333

[136]:
```
for (x in linhas) {
    medidas <- df[(x-3):(x+3), "sensacao"]
    media   <- mean(medidas[-4])
    df[x, "sensacao"] <- media
}
```

[137]:
```
df[linhas,]
```

A data.frame: 5 × 5

	horario <chr>	temp <dbl>	vento <dbl>	umid <dbl>	sensacao <dbl>
87668	07/09/2018-07:10	13.4	37.0	75.3	11.28333
87812	08/09/2018-07:10	16.1	26.3	64.5	14.58333
87956	09/09/2018-07:10	15.1	28.1	75.8	13.23333
88100	10/09/2018-07:10	14.8	33.4	74.5	12.95000
88244	11/09/2018-07:10	15.4	34.7	76.2	13.73333

[ ]:
```
summary(df)
```

[ ]:
```
cepagri_01 <- df
```

[ ]:
```
save(cepagri_01, file="cepagri_01.RData")
```

[ ]:
```
```