Regressão

IFSP - PEP

Cláudio M. Zaina

Técnica Estatística de Regressão Linear Simples

Índice

Regressão Linear **1**
Introdução 1
Modelo 1
Avaliação do Modelo 6
EAM - Erro Absoluto Médio (ou MAE - *Mean Absolute Error*) 6
EQM - Erro Quadrático Médio (ou MSE - *Mean Squared Error*) 6
Referências 13

Regressão Linear

Introdução

Análise de regressão é um dos modos mais simples e mais utilizados de predição. É um método estatístico fundamental para iniciar o entendimento de aprendizados de máquina e o ponto de partida para cientistas de dados.

Poderia ser um objeto de estudo de alguém quantos quilômetros um determinado carro percorre com determinada quantidade de combustível ou por quanto foi vendida uma casa com determinados metros quadrados de área construída. Mesmo carros de mesmo tipo e ano não terão o mesmo consumo; mesmo casas com a mesma metragem não terão o mesmo preço. `consumo` no caso dos carros e `preço` no caso das casas são variáveis que *dependem* das outras (`quantidade de litros`, `metros quadrados`). As variáveis dependentes são também chamadas *resposta*. As variáveis sobre as quais temos controle, podendo escolher ou medir, são ditas variáveis *independentes*, *explanatórias* ou *regressoras*. Podemos estabelecer uma relação entre as variáveis dependentes (*respostas*) e as variáveis independentes (*regressores*) através de um modelo que explique *como* uma resposta se comporta dependendo de um regressor.

Modelos de regressão são muito valiosos por serem um dos meios mais comuns e simples de fazer inferência e predição. Também é importante para determinar quais fatores mais influenciam de modo significativo um resultado.

Modelo

O modelo de regressão nos ajuda a fazer previsões sobre a **população** baseadas em informações dos dados **amostrais**. O objetivo é explorar o relacionamento entre duas (ou mais) variáveis (atributos / *features*) de modo a ganhar informação sobre uma delas a partir do valor da(s) outra(s).

Amostra → Construção do modelo → Previsão sobre a **população**

Modelo de Regressão Linear:
$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$

Y_i - elemento i da variável dependente Y
β_0 - constante linear
β_1 - coeficiente de inclinação
X_i - elemento i da variável independente X
ϵ_i - erro (do elemento i)

Como os parâmetros referem-se à população, são utilizadas letras gregas.

Equação da Regressão Linear:
$y_i = b_0 + b_1 x_i$
y_i - elemento i estimado (predito)
b_0 - constante linear estimada
b_1 - coeficiente de inclinação estimado
x_i - elemento i da variável independente amostral x

Em R, `lm(fórmula, dados)`, a `fórmula` é do tipo "$y \sim x_1 + x_2 + x_1 : x_2$", por exemplo. As os termos x_i são variáveis independentes e y_i o valor predito pelo modelo.

Vamos utilizar o banco de dados `women` de R:

```
mlh <- women
```

A variável `weight` está em libras. Convertendo para kgf:

```
mlh$peso <- women$weight * 0.45
mlh$weight <- NULL
```

A variável `height` está em polegadas, convertendo para m:

```
mlh$altura <- women$height * 0.0253
mlh$height <- NULL
```

```
print(mlh)
```

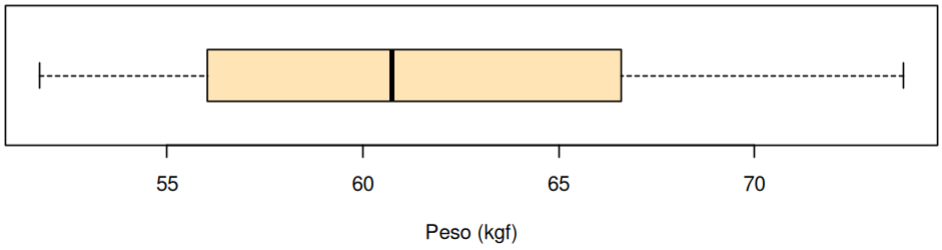
```
    peso altura
1  51.75 1.4674
2  52.65 1.4927
3  54.00 1.5180
4  55.35 1.5433
5  56.70 1.5686
6  58.05 1.5939
7  59.40 1.6192
8  60.75 1.6445
9  62.55 1.6698
10 63.90 1.6951
11 65.70 1.7204
12 67.50 1.7457
13 69.30 1.7710
14 71.55 1.7963
15 73.80 1.8216
```

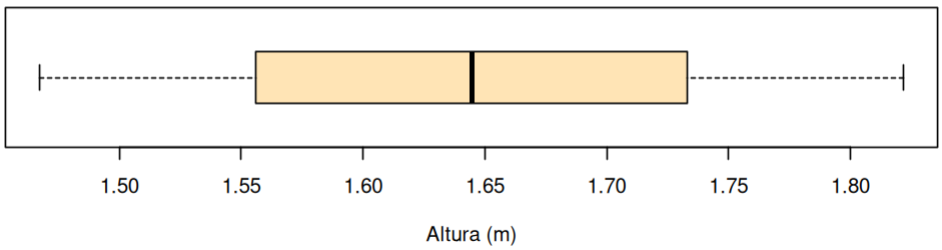
```
options(digits=3)
summary(mlh)
```

```
     peso          altura     
 Min.   :51.8   Min.   :1.47  
 1st Qu.:56.0   1st Qu.:1.56  
 Median :60.8   Median :1.64  
 Mean   :61.5   Mean   :1.64  
 3rd Qu.:66.6   3rd Qu.:1.73  
 Max.   :73.8   Max.   :1.82  
```

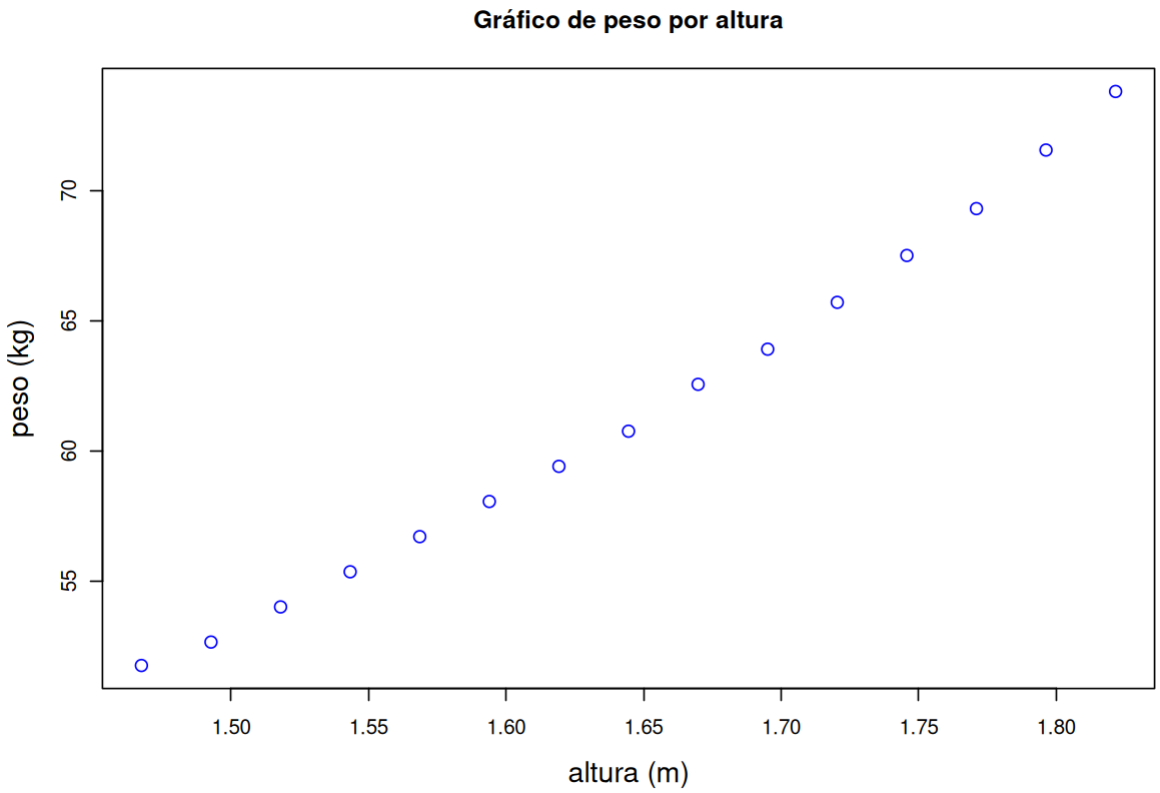
```r
# criando função para dimensionar gráfico no Jupyter
library(repr)
grafdim <- function(x,y) { options(repr.plot.width=x, repr.plot.height=y) }
```

```r
grafdim(9,3)
boxplot(mlh$peso, horizontal=TRUE, col="moccasin", xlab="Peso (kgf)")
boxplot(mlh$altura, horizontal=TRUE, col="moccasin", xlab="Altura (m)")
```






```r
grafdim(10,7)
plot(mlh$altura, mlh$peso, col="blue", cex=1.2, cex.lab=1.4,
     xlab="altura (m)", ylab="peso (kg)",
     main="Gráfico de peso por altura")
```



Construindo a regressão do peso em função da altura:

```
reg <- lm(formula=peso ~ altura, data=mlh)
```

```
reg
```

```
Call:
lm(formula = peso ~ altura, data = mlh)

Coefficients:
(Intercept)       altura
      -39.4         61.4
```

Os resultados dizem que a fórmula da regressão seria:
`peso` = -39,4 + 61,4 · `altura`
Assim espera-se um aumento de 61,4 (kg) para cada 1 (m) de altura (ou 6,1 kg para cada 10 cm).

```
summary(reg)
```

```
Call:
lm(formula = peso ~ altura, data = mlh)

Residuals:
   Min     1Q Median     3Q    Max
-0.780 -0.510 -0.172  0.334  1.403

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   -39.38       2.67   -14.7  1.7e-09 ***
```

```
altura         61.36       1.62    37.9  1.1e-14 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.686 on 13 degrees of freedom
Multiple R-squared:  0.991, Adjusted R-squared:  0.99
F-statistic: 1.43e+03 on 1 and 13 DF,  p-value: 1.09e-14
```

```r
predito <- predict(reg)
dif <- mlh$peso-predito
```

Informações úteis:

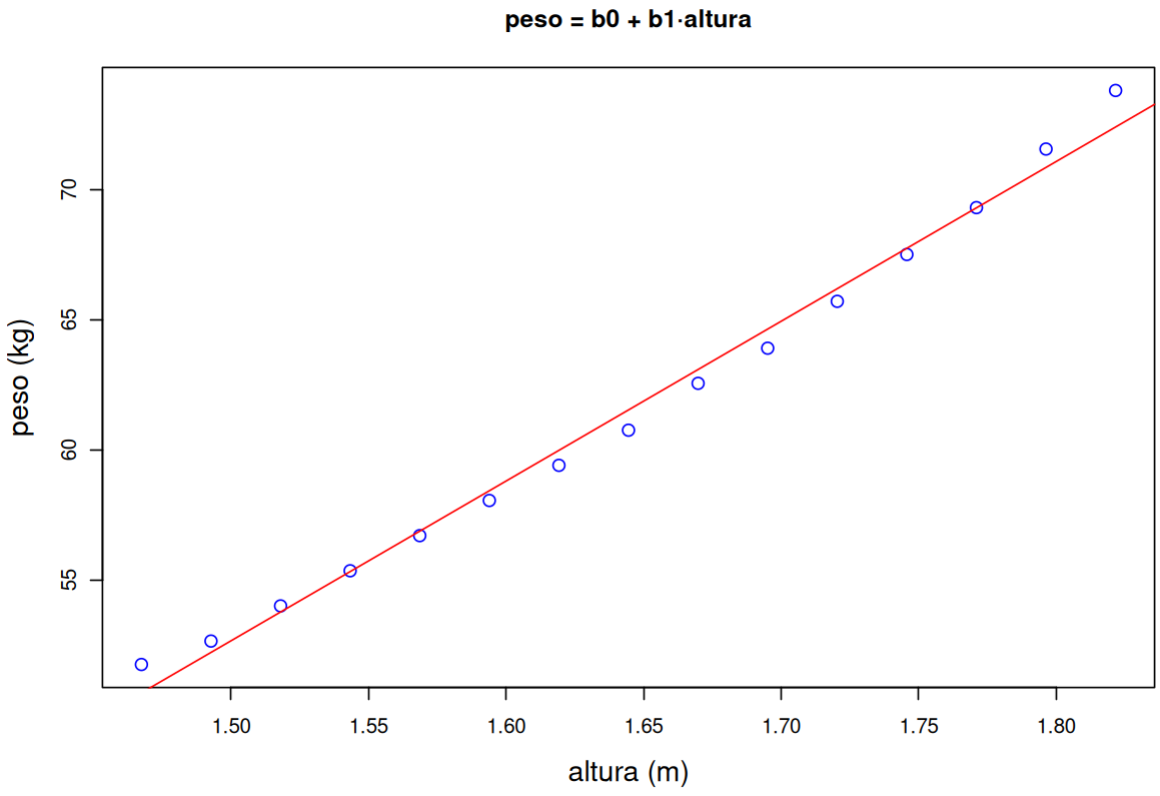
Valores estimados dos parâmetros:

parâmetro	valor	significância estatística (é importante para a variável dependente?)	
intercept b_0	$-39,38$	$1,7.10^{-9} < 0,05$?	$\rightarrow$ sim
primeiro parâmetro b_1 (`altura`)	$61,36$	$1,1.10^{-14} < 0,05$?	$\rightarrow$ sim

Observação: o nível de significância é **pré-fixado** em todo experimento. Normalmente 0,05.

O valor do coeficiente de correlação R^2 (ajustado) é 0,9903, significando que o modelo explica 99% dos erros. Vale lembrar que $0 \leq R^2 \leq 1$.

```r
plot(mlh$altura, mlh$peso,  col="blue", cex=1.2, cex.lab=1.4,
     xlab="altura (m)", ylab="peso (kg)",
     main="peso = b0 + b1·altura")
abline(reg, col="red")
```



Avaliação do Modelo

O modelo deve ser verificado e um processo iterativo iniciado para ajustar o modelo de modo que explique o máximo possível da variável resposta sem ser excessivamente dependente dos dados do aprendizado.

Iniciamos a avaliação do modelo verificando a distância dos dados previstos com relação as dados originais. Quanto maior a distância, mais pobre foi a modelagem.

EAM - Erro Absoluto Médio (ou MAE - *Mean Absolute Error*)

O Erro Absoluto Médio é a média dos módulos das diferenças entre os valores previstos e os observados, ou seja:

$$EAM(\hat{y}) = \frac{1}{n}\sum_{i=1}^{n}|\hat{y}_i - x_i|$$

```
# definindo como calcular o erro absoluto médio:
eam <- function (predito, observado) {
    if (length(predito) == length(observado)) {
        resultado <- sum(abs(predito - observado)) / length(observado)
        return (resultado)
    } else {
        return (NA)
    }
}
```

EQM - Erro Quadrático Médio (ou MSE - *Mean Squared Error*)

O Erro Quadrático Médio é a média dos quadrados das diferenças entre os valores previstos e os observados, ou seja:

$$EQM(\hat{y}) = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - x_i)^2$$

```
# definindo como calcular o erro quadrático médio:
eqm <- function (predito, observado) {
    if (length(predito) == length(observado)) {
        diferenca <- predito - observado
        resultado <- sum(diferenca * diferenca) / length(observado)
        return (resultado)
    } else {
        return (NA)
    }
}
```

```
predito <- fitted(reg)
print(data.frame(mlh$peso, predito, dif=mlh$peso-predito))
```

```
   mlh.peso predito     dif
1      51.8    50.7  1.0875
2      52.6    52.2  0.4350
3      54.0    53.8  0.2325
4      55.4    55.3  0.0300
5      56.7    56.9 -0.1725
```

```
6      58.1    58.4 -0.3750
7      59.4    60.0 -0.5775
8      60.8    61.5 -0.7800
9      62.6    63.1 -0.5325
10     63.9    64.6 -0.7350
11     65.7    66.2 -0.4875
12     67.5    67.7 -0.2400
13     69.3    69.3  0.0075
14     71.5    70.8  0.7050
15     73.8    72.4  1.4025
```

```
sum(abs(predito - mlh$peso)) / 15
eam(predito, mlh$peso)
```

0.5200000000000001

0.5200000000000001

```
sum((predito - mlh$peso)^2) / 15
eqm(predito, mlh$peso)
```

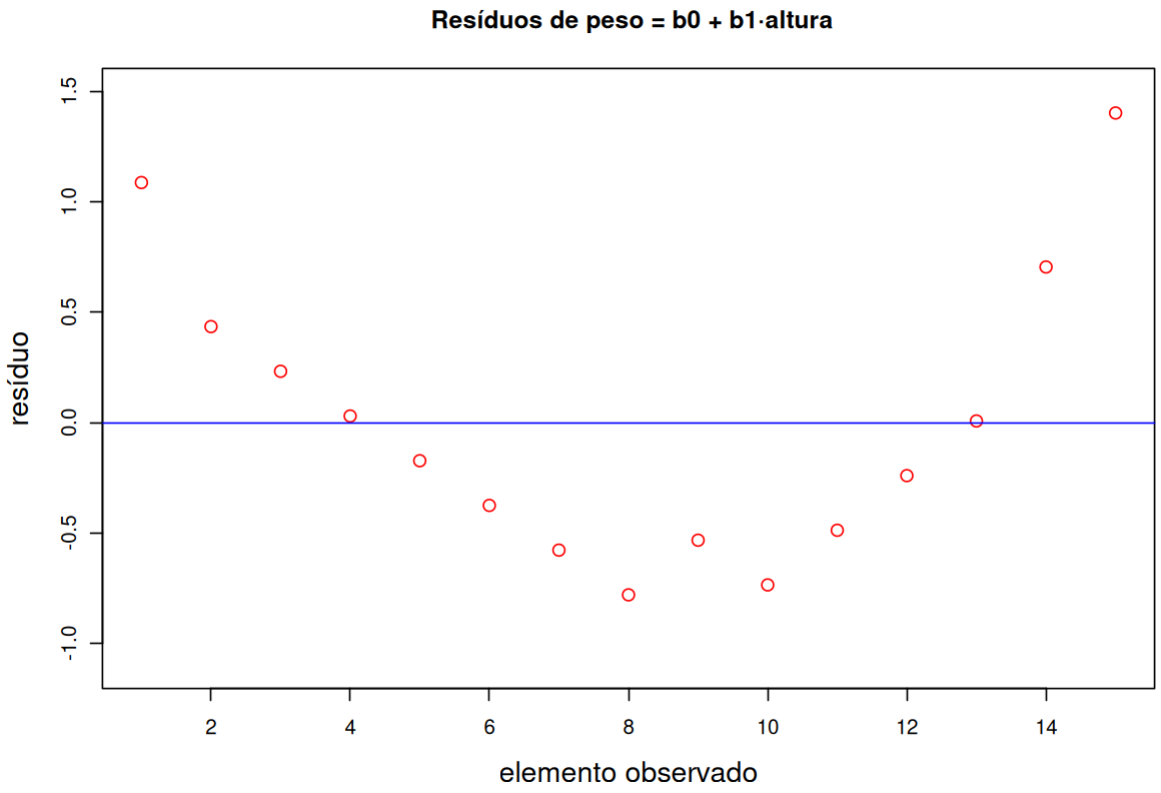
0.4081500000000001

0.4081500000000001

Pode-se, então, construir uma tabela avaliando a adequação do modelo:

modelo	EAM	EQM	R^2
`peso` = -39,38 + 61,36 · `altura`	0,52	0,40	0,9903

```
plot(reg$residuals, col="red", cex=1.2, cex.lab=1.4,
     xlab="elemento observado", ylab="resíduo",
     ylim=c(-1.1,1.5), main=" Resíduos de peso = b0 + b1·altura")
abline(h=0.0, col="blue")
```



Os resíduos, que supostamente deveriam apenas ser valores aleatórios ao redor de 0, apresentam um claro comportamento de parábola. É uma clara indicação que o modelo falha em capturar uma possível componente em x^2.

Aderindo uma regressão com componente ao quadrado:

```
reg2 <- lm(formula=peso ~ altura + I(altura^2), data=mlh)
```

A nova regressão modela a expressão:
$y_i = b_0 + b_1 x_i + b_2 x_i^2$
y_i - elemento i estimado (predito)
b_0 - constante linear estimada
b_1 - coeficiente de inclinação estimado
b_2 - coeficiente do termo ao quadrado
x_i - elemento i da variável independente amostral x

```
reg2
```

```
Call:
lm(formula = peso ~ altura + I(altura^2), data = mlh)

Coefficients:
(Intercept)       altura  I(altura^2)
      117.8       -130.7         58.4
```

O novo ajuste propõe a regressão:
`peso` $= 117{,}8$ -$130{,}7$ $\cdot$ `altura` $+ 58{,}4$ $\cdot$ `altura`^{2}

```
summary(reg2)
```

```
Call:
lm(formula = peso ~ altura + I(altura^2), data = mlh)

Residuals:
     Min       1Q   Median       3Q      Max
-0.22923 -0.13325 -0.00423  0.12877  0.26868

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)    117.8       11.3   10.39  2.4e-07 ***
altura        -130.7       13.8   -9.45  6.6e-07 ***
I(altura^2)     58.4        4.2   13.89  9.3e-09 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.173 on 12 degrees of freedom
Multiple R-squared:  0.999, Adjusted R-squared:  0.999
F-statistic: 1.14e+04 on 2 and 12 DF,  p-value: <2e-16
```

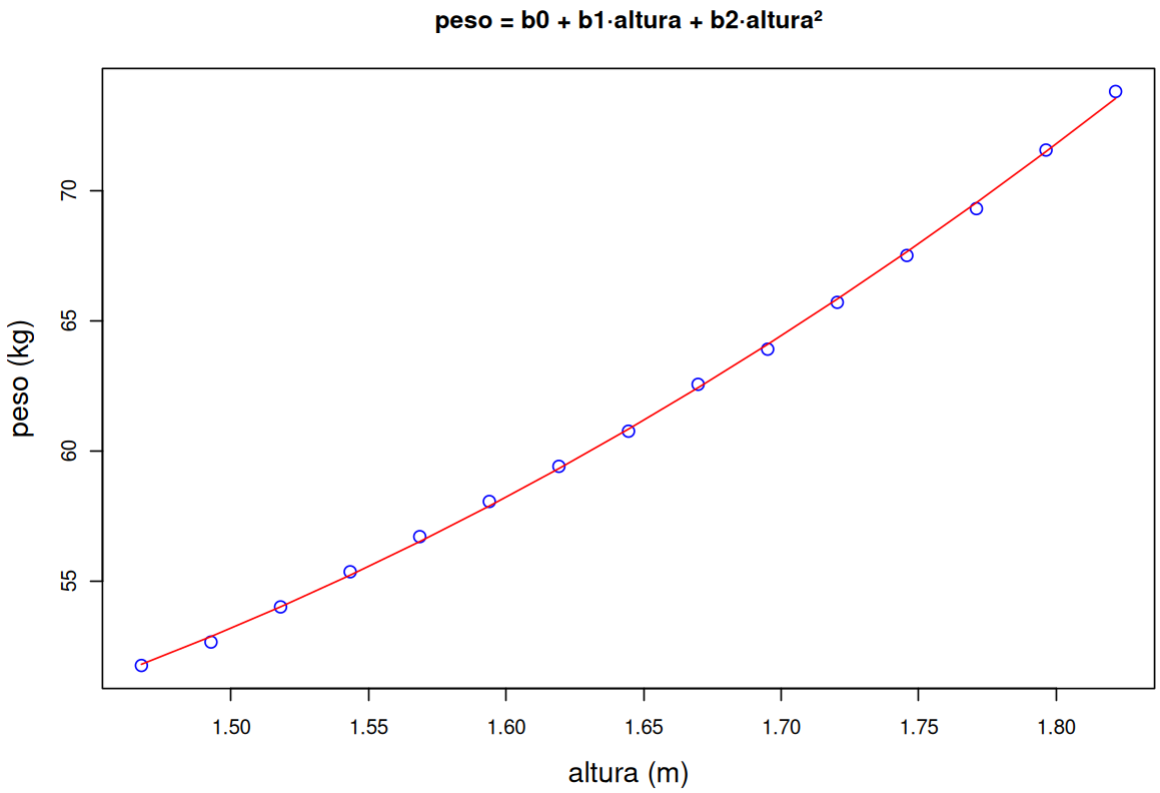
Informações úteis:

Valores estimados dos parâmetros:

parâmetro	valor	significância estatística (é importante para a variável dependente?)	
b_0	$117{,}8$	$2,4.10^{-7} < 0{,}05$?	$\rightarrow$ sim
b_1 (`altura`)	$-130,7$	$6,6.10^{-7} < 0{,}05$?	$\rightarrow$ sim
b_2 (`altura²`)	$58,4$	$9,3.10^{-9} < 0{,}05$?	$\rightarrow$ sim

O valor do coeficiente de correlação R^2 (ajustado) é 0,999, significando que o modelo explica 99,9% dos erros.

```r
plot(mlh$altura, mlh$peso,
     col="blue", cex=1.2, cex.lab=1.4,
     xlab="altura (m)", ylab="peso (kg)",
     main="peso = b0 + b1·altura + b2·altura²")
lines(mlh$altura, fitted(reg2), col="red")
```



```
predito2 <- fitted(reg2)
eam(predito2, mlh$peso)
```

0.137096315449262

```
eqm(predito2, mlh$peso)
```

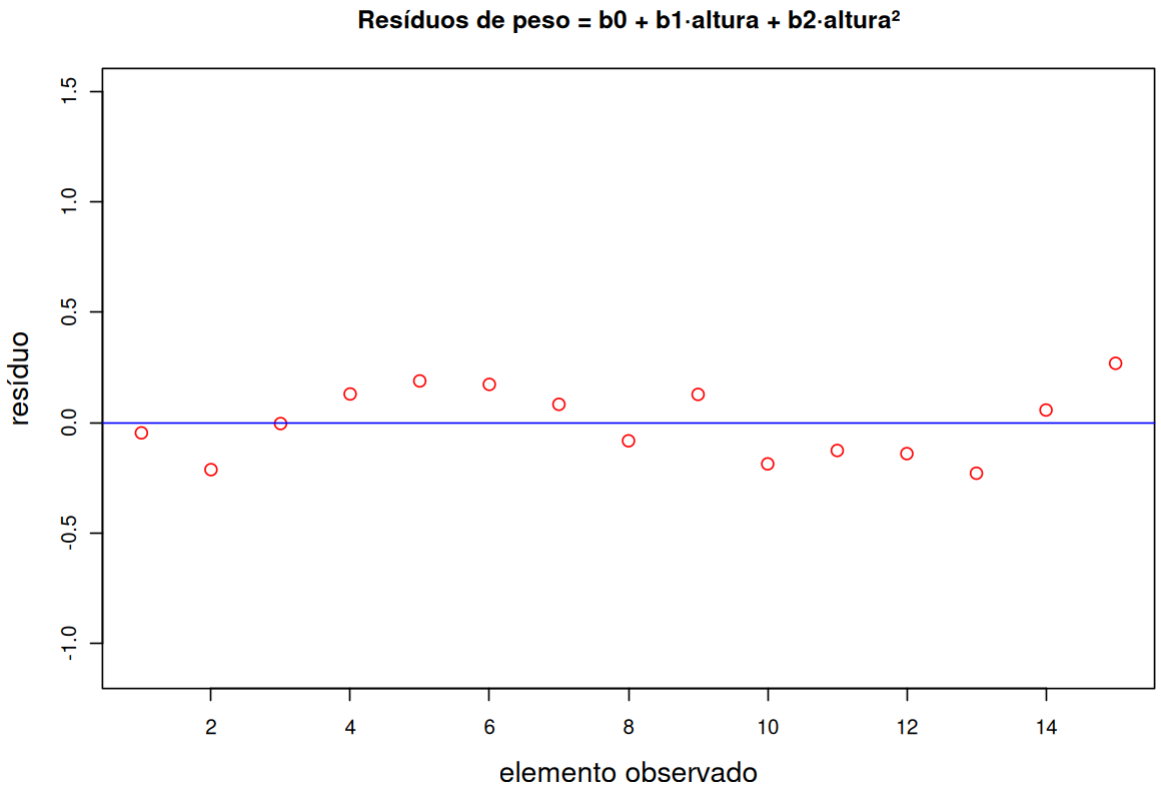
0.0238959599224317

Vamos comparar os modelos:

modelo	EAM	EQM	R^2
`peso` = -32,38 + 50,45 · `altura`	0,52	0,40	0,9903
`peso` = 96,9 -107,5 · `altura` + 48,0 · `altura`^{2}	0,14	0,02	0,9990

Avaliando os resíduos do novo modelo:

```
plot(reg2$residuals, xlab="elemento observado", ylab="resíduo",
     col="red", ylim=c(-1.1,1.5), cex.lab=1.4, cex=1.2,
     main="Resíduos de peso = b0 + b1·altura + b2·altura²")
abline(h=0.0, col="blue")
```



Como exercício didático, poderíamos verificar se não há uma componente cúbica (na forma de `altura`^{3}), o que seria forçar demais os poucos dados à procura de explicação...

```
reg3 <- lm(formula=peso ~ altura + I(altura^2) + I(altura^3), data=mlh)
```

```
reg3
```

```
Call:
lm(formula = peso ~ altura + I(altura^2) + I(altura^3), data = mlh)

Coefficients:
(Intercept)       altura  I(altura^2)  I(altura^3)
       -404          825         -525          118
```

```
summary(reg3)
```

```
Call:
lm(formula = peso ~ altura + I(altura^2) + I(altura^3), data = mlh)

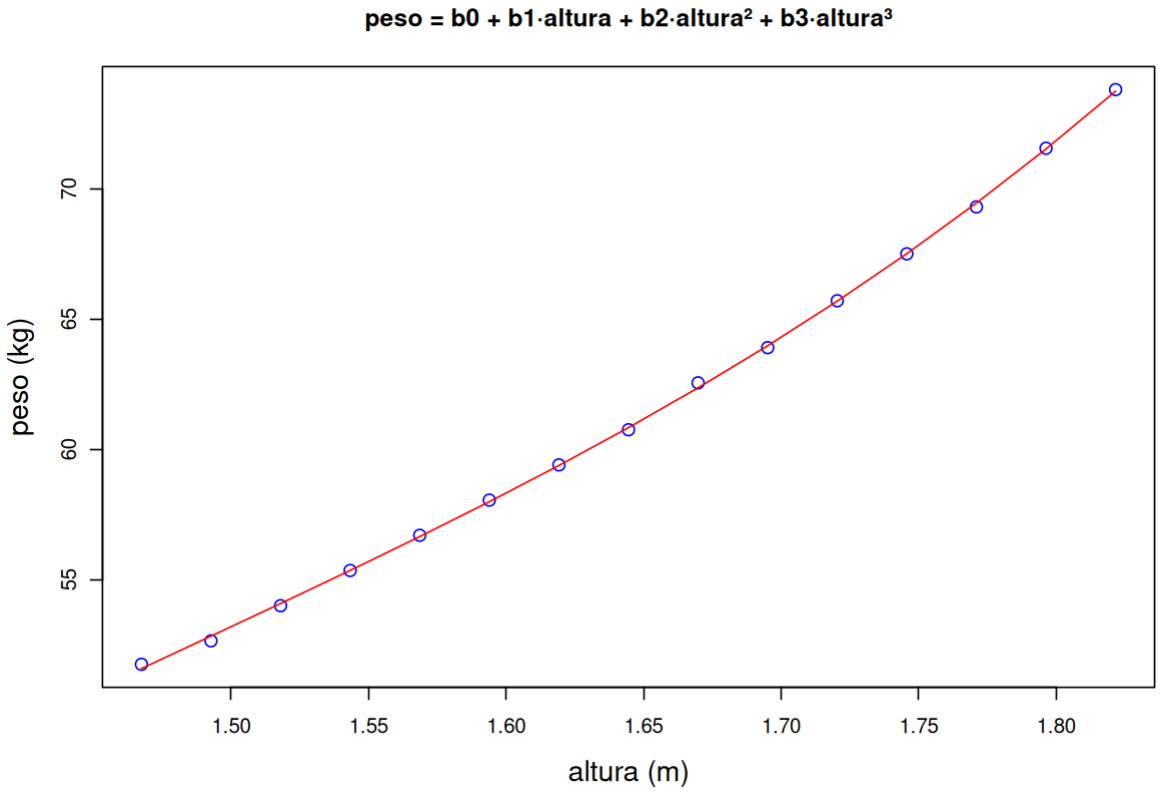
Residuals:
    Min      1Q  Median      3Q     Max
-0.1830 -0.0783  0.0139  0.0542  0.1899

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)     -404        133   -3.04   0.0112 *
altura           826        243    3.40   0.0059 **
I(altura^2)     -525        148   -3.54   0.0046 **
I(altura^3)      118         30    3.94   0.0023 **
```

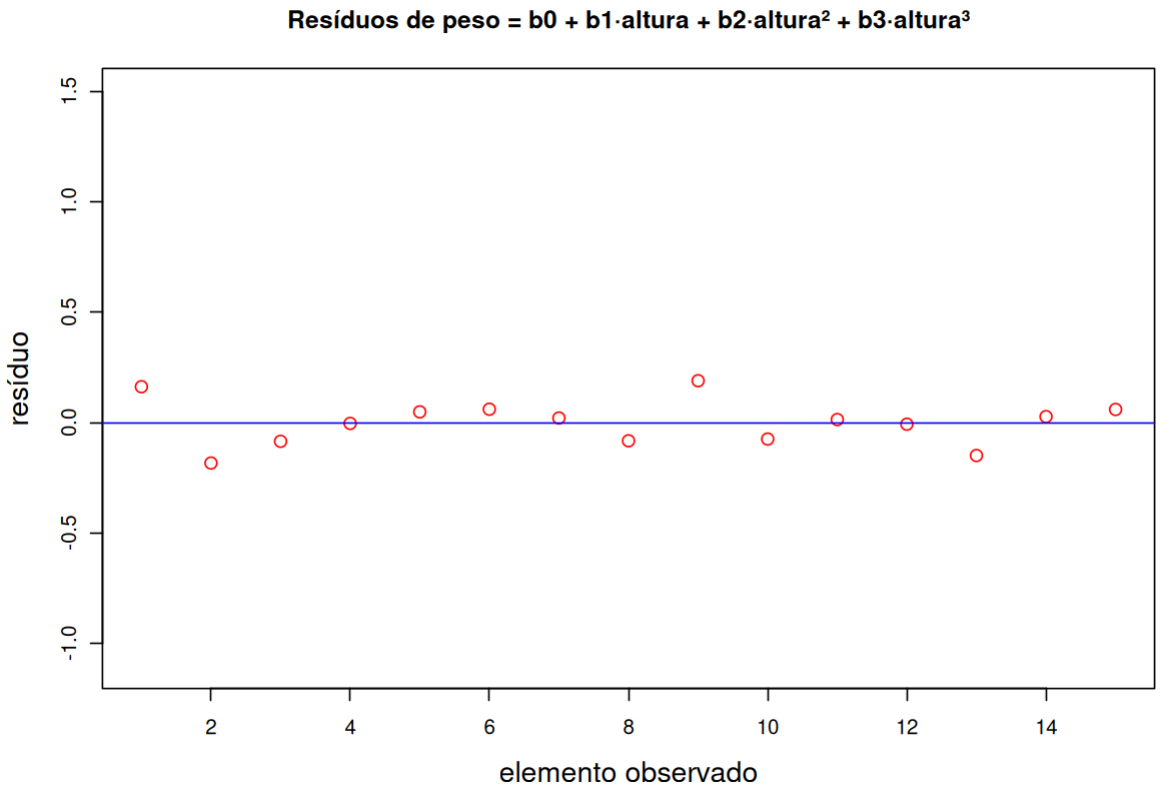
```
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.116 on 11 degrees of freedom
Multiple R-squared:     1,  Adjusted R-squared:     1
F-statistic: 1.68e+04 on 3 and 11 DF,  p-value: <2e-16
```

```r
plot(mlh$altura, mlh$peso, col="blue", cex=1.2, cex.lab=1.4,
     xlab="altura (m)", ylab="peso (kg)",
     main="peso = b0 + b1·altura + b2·altura² + b3·altura³")
lines(mlh$altura, fitted(reg3), col="red")
```




```r
plot(reg3$residuals, col="red", cex=1.2, cex.lab=1.4,
     xlab="elemento observado", ylab="resíduo",
     ylim=c(-1.1,1.5),
     main="Resíduos de peso = b0 + b1·altura + b2·altura² + b3·altura³")
abline(h=0.0, col="blue")
```



Apesar de aparentemente ter obtido a regressão "perfeita", seria absurdo propor uma explicação utilizando `altura`^{3} para 15 dados.
Além disso, poderíamos estar passando para um problema de *overfitting* (sobreajuste ou superajuste).

Referências

Probabilidade e Estatística para Engenharia e Ciências - 3. ed. / 2006 - (Livros) DEVORE, Jay L. ed. São Paulo: Cengage Learning, 2019. xiii, 692 p. ISBN 9788522104598.
Número de chamada: 519.2 D512p 3. ed. (PE)