Regressão Múltipla - Padronização

IFSP - PEP

Cláudio M. Zaina

Técnicas de preparo do conjunto de dados para aprendizado de máquina - padronização.

```
rm(list=ls())
```

```
# criando função para dimensionar gráfico no Jupyter
library(repr)
grafdim <- function(x=11,y=8) { options(repr.plot.width=x, repr.plot.height=y) }
```

```
load("assassinato_EUA_1977.RData")
```

```
summary(st)
```

```
  assassinato       populacao     analfabetismo       renda      
 Min.   : 1.400   Min.   :  365   Min.   :0.500   Min.   :3098  
 1st Qu.: 4.350   1st Qu.: 1080   1st Qu.:0.625   1st Qu.:3993  
 Median : 6.850   Median : 2838   Median :0.950   Median :4519  
 Mean   : 7.378   Mean   : 4246   Mean   :1.170   Mean   :4436  
 3rd Qu.:10.675   3rd Qu.: 4968   3rd Qu.:1.575   3rd Qu.:4814  
 Max.   :15.100   Max.   :21198   Max.   :2.800   Max.   :6315  
  congelamento     ensino_medio    expectativa          regiao   
 Min.   :  0.00   Min.   :37.80   Min.   :67.96   Meio-Oeste:12  
 1st Qu.: 66.25   1st Qu.:48.05   1st Qu.:70.12   Nordeste  : 9  
 Median :114.50   Median :53.25   Median :70.67   Oeste     :13  
 Mean   :104.46   Mean   :53.11   Mean   :70.88   Sul       :16  
 3rd Qu.:139.75   3rd Qu.:59.15   3rd Qu.:71.89                  
 Max.   :188.00   Max.   :67.30   Max.   :73.60                  
    estado         
 Length:50          
 Class :character   
 Mode  :character   
```

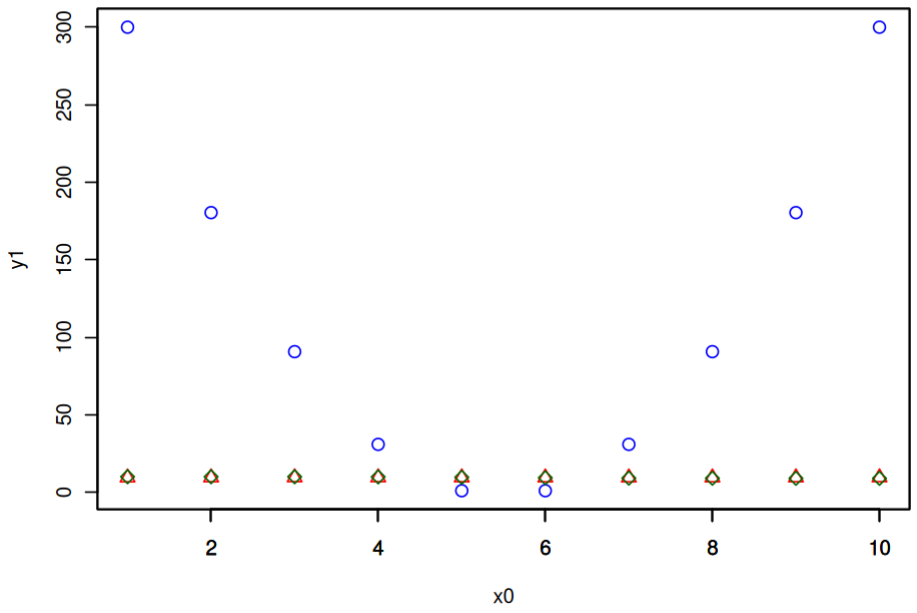
Padronização

A padronização é o processo no qual se "escalam" as variáveis, normalmente de grandezas diferentes, de modo que fiquem comparáveis, todas em uma mesma escala, para análise. Por exemplo, podemos ter em um *dataset* variáveis em m^2 — com valores entre 100 e 10000 — assim como porcentagens — entre 0 e 1 — ou concentrações de elementos químicos, na grandeza de 10^{-4}.
A padronização garante que a grandeza da escala mantenha a grandeza dos coeficientes proporcional à sua importância no modelo. `estado`

Vamos observar como se comportam variáveis, por exemplo y_1, y_2 e y_3, ao longo de x:

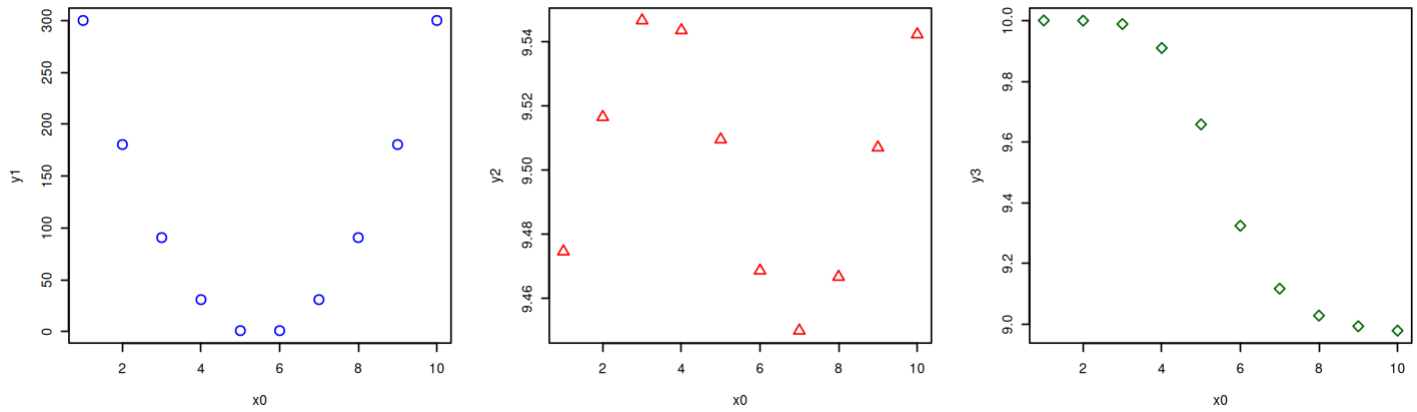
```r
x0 <- c(1:10)
y1 <- {function(x) 14.95*x*x - 164.45*x + 449.5} (x0)
y2 <- {function(x) sin(x/1.15 - 1.4)/20 + 9.5} (x0)
y3 <- {function(x) 8.96597 + (10.00088 - 8.96597)/(1 + (x/5.502773)^7.344993)} (x0)
```

```r
grafdim(8,6)
ymin <- min(min(y1), min(y2), min(y3))
ymax <- max(max(y1), max(y2), max(y3))
plot(x0, y1, ylim=c(ymin,ymax), cex=1.2, col="blue", pch=1,)
par(new=T)
plot(x0,y2, ylim=c(ymin,ymax), cex=1.2, yaxt="n", pch=2,
     col="red", ylab="", xlab="")
par(new=T)
plot(x0,y3, ylim=c(ymin,ymax), cex=1.2, yaxt="n", pch=23,
     col="darkgreen", ylab="", xlab="")
par(new=F)
```



Podemos reparar que, se os dados forem graficados independentemente, cada um com sua escala, é possível perceber o comportamento de cada variável.,

```r
grafdim(12,4)
par(mfrow=c(1,3))
plot(x0,y1, cex=1.4, col="blue", pch=1)
plot(x0,y2, cex=1.4, col="red",  pch=2)
plot(x0,y3, cex=1.4, col="darkgreen", pch=23)
```



O ideal então seria considerar um modo de ser possível representá-las juntas, para observar como cada uma se comporta, independente da escala. Esse processo é a padronização.

Min-Max

A técnica MinMax reduz a variável ao intervalo [0; 1] por subtrair da variável (*feature*) seu valor mínimo — deslocando o menor valor para 0 — e dividindo-a pela sua amplitude — reduzindo o maior valor a 1.
A transformação é

$$x'_i = \frac{x_i - min(x)}{max(x) - min(x)}$$

```
minmax <- function (x) {
    xmin <- min(x)
    xmax <- max(x)
    return ((x - xmin) / (xmax - xmin))
}
```

```
x <- c(3, 200,  55, 150, -10, 110)
```

```
print(x)
```

```
[1]   3 200  55 150 -10 110
```

```
(xmin <- min(x))
(xmax <- max(x))
```

-10

200

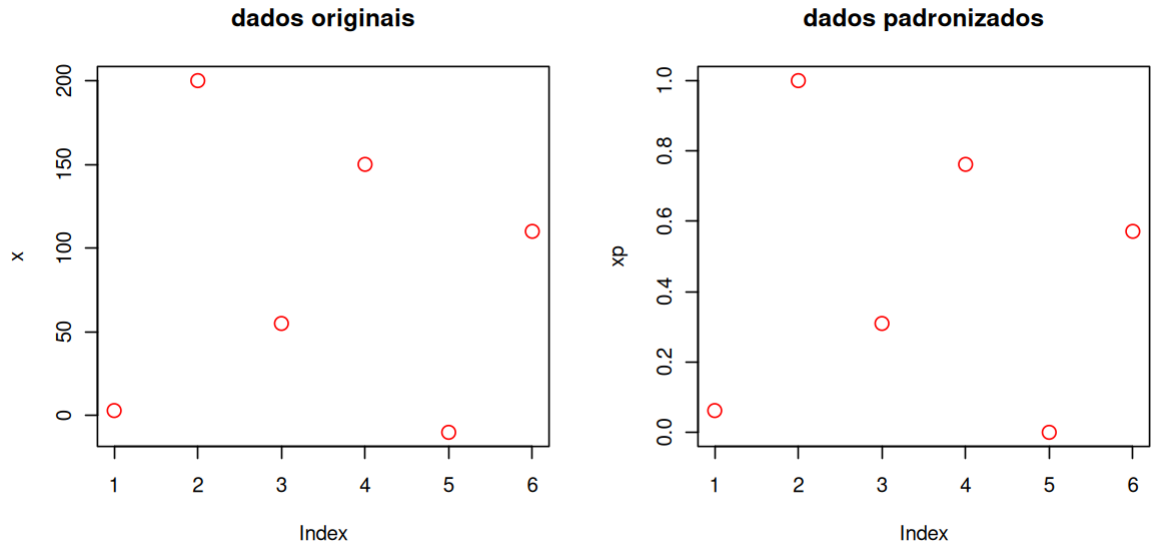
```
xp <- (x - xmin) / (xmax - xmin)
print(xp)
print(minmax(x))
```

```
[1] 0.06190476 1.00000000 0.30952381 0.76190476 0.00000000 0.57142857
[1] 0.06190476 1.00000000 0.30952381 0.76190476 0.00000000 0.57142857
```

```r
print(data.frame("x_original"=x, "x_padronizado"=xp))
```

```
  x_original x_padronizado
1          3    0.06190476
2        200    1.00000000
3         55    0.30952381
4        150    0.76190476
5        -10    0.00000000
6        110    0.57142857
```

```r
grafdim(10,5)
par(mfrow=c(1,2))
plot( x, cex=1.4, col="red", pch=1, main="dados originais")
plot(xp, cex=1.4, col="red", pch=1, main="dados padronizados")
```



É possível observar que o relacionamento entre os dados — distância proporcional entre os pontos, ordem etc — e o perfil da variável se manteve.

Podemos verificar se também funciona para variáveis com uma escala pequena:

```r
y <- c(-0.03, 0.04, 0.2, 0.13, -0.015, 0.115)
```

```r
(ymin <- min(y))
(ymax <- max(y))
```

-0.03

0.2

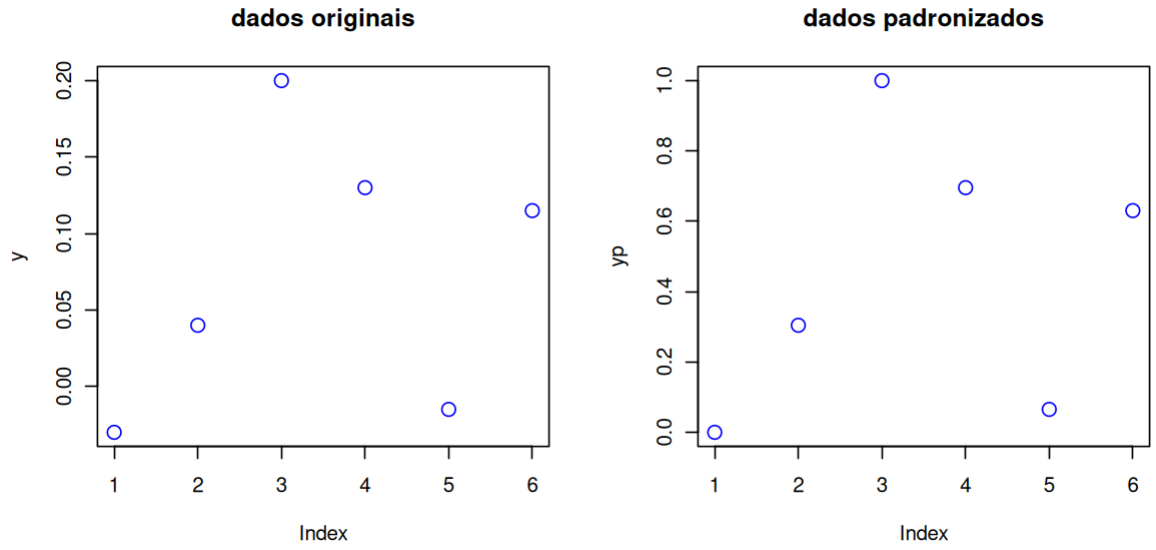
```r
yp <- (y - ymin) / (ymax - ymin)
print(yp)
print(minmax(y))
```

```
[1] 0.00000000 0.30434783 1.00000000 0.69565217 0.06521739 0.63043478
[1] 0.00000000 0.30434783 1.00000000 0.69565217 0.06521739 0.63043478
```

```r
print(data.frame("y_original"=y, "y_padronizado"=yp))
```

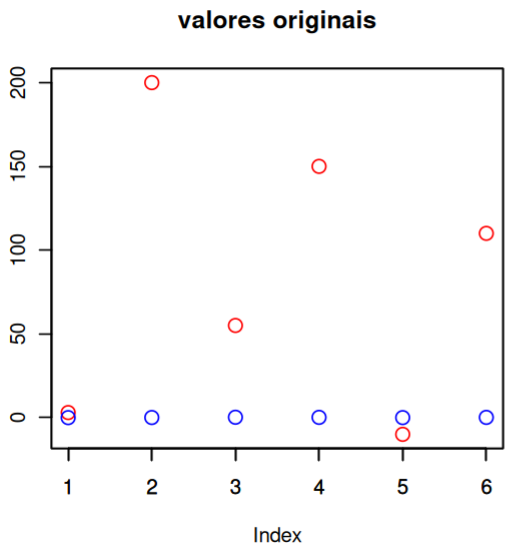
```
  y_original y_padronizado
1     -0.030    0.00000000
2      0.040    0.30434783
3      0.200    1.00000000
4      0.130    0.69565217
5     -0.015    0.06521739
6      0.115    0.63043478
```

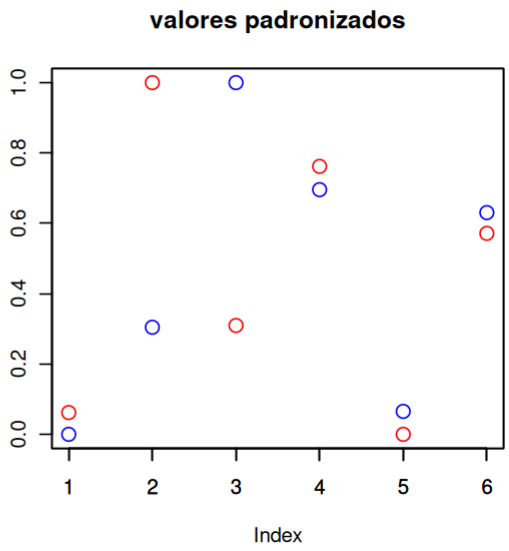
```r
grafdim(10,5)
par(mfrow=c(1,2))
plot( y, cex=1.4, col="blue", pch=1, main="dados originais")
plot(yp, cex=1.4, col="blue", pch=1, main="dados padronizados")
```



Como se comportavam os dados antes e depois da padronização?

```r
grafdim(10,5)
par(mfrow=c(1,2))
plot(x, ylim=c(min(x,y),max(x,y)), cex=1.4, col="red", ylab="", main="valores originais")
par(new=T)
plot(y, ylim=c(min(x,y),max(x,y)), cex=1.4, yaxt="n", col="blue", ylab="", xlab="")
par(new=F)
plot(xp, ylim=c(0,1), cex=1.4, col="red", ylab="", main="valores padronizados")
par(new=T)
plot(yp, ylim=c(0,1), cex=1.4, yaxt="n", col="blue", ylab="", xlab="")
par(new=F)
```





ZNorm (ou Z-*score*)

A técnica ZNorm, Z-*score* ou padronização pela curva normal ("normalização") padroniza por transformar todos os elementos de uma variável (*feature*) ao subtrair dos dados a sua média — deslocando o centro para o 0 — e dividindo pelo desvio — garantindo uma dispersão de 1.
A transformação é

$$x'_i = \frac{x_i - \bar{x}}{\sigma}$$

sendo $\bar{x}$ a média da variável x e σ seu desvio padrão, ou seja

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

$$s = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1}}$$

```
znorm <- function (x) {
    xmedia  <- mean(x)
    xdesvio <- sd(x)
    return ((x - xmedia) / xdesvio)
}
```

```
xpz <- znorm(x)
print(data.frame("x_original"=x, "x_znorm"=xpz))
```

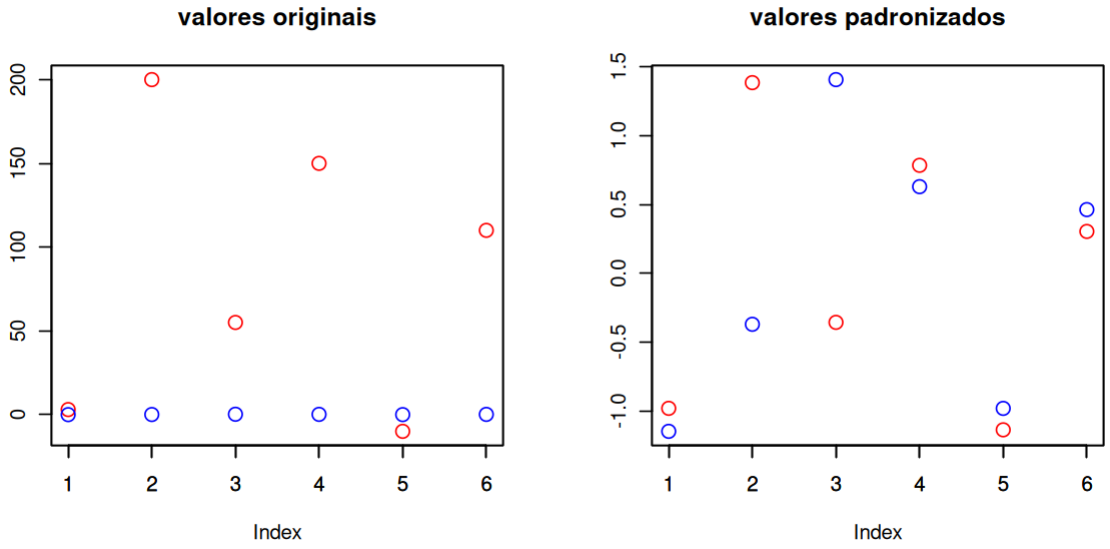
```
  x_original    x_znorm
1          3 -0.9799843
2        200  1.3839779
3         55 -0.3559943
4        150  0.7839875
5        -10 -1.1359818
6        110  0.3039951
```

```
ypz <- znorm(y)
print(data.frame("y_original"=y, "y_znorm"=ypz))
```

```
  y_original    y_znorm
1     -0.030 -1.1469687
2      0.040 -0.3699899
3      0.200  1.4059617
4      0.130  0.6289829
5     -0.015 -0.9804733
6      0.115  0.4624874
```

Novamente, vamos comparar os dados originais com os padronizados:

```
grafdim(10,5)
par(mfrow=c(1,2))
plot(x, ylim=c(min(x,y),max(x,y)), cex=1.4, col="red", ylab="", main="valores originais")
par(new=T)
plot(y, ylim=c(min(x,y),max(x,y)), cex=1.4, yaxt="n", col="blue", ylab="", xlab="")
par(new=F)
plot(xpz, ylim=c(min(xpz,ypz),max(xpz,ypz)), cex=1.4, col="red", ylab="", main="valores padroniza
par(new=T)
plot(ypz, ylim=c(min(xpz,ypz),max(xpz,ypz)), cex=1.4, yaxt="n", col="blue", ylab="", xlab="")
par(new=F)
```



Ambas técnicas são interessantes e podem ser aplicadas às variáveis em estudo. Um fator que pode ser de interesse na hora de decidir entre MinMax e Znorm é a possibilidade de zero perturbar alguma etapa do processamento ou da análise (uma transformação por logaritmo, por exemplo). A utilização do MinMax *garante* o aparecimento de pelo menos um dado sendo 0 em cada variável; em Znorm, o 0 só ocorreria no caso extremamente particular em que um dos dados seja *exatamente* igual à média.

Um detalhe com relação à padronização é que a variável dependente, a ser estudada, ***nunca*** deve ser padronizada, uma vez que o resultado do processo de estudo não pode ser alterado.

Vamos padronizar então os dados y_1, y_2 e y_3:

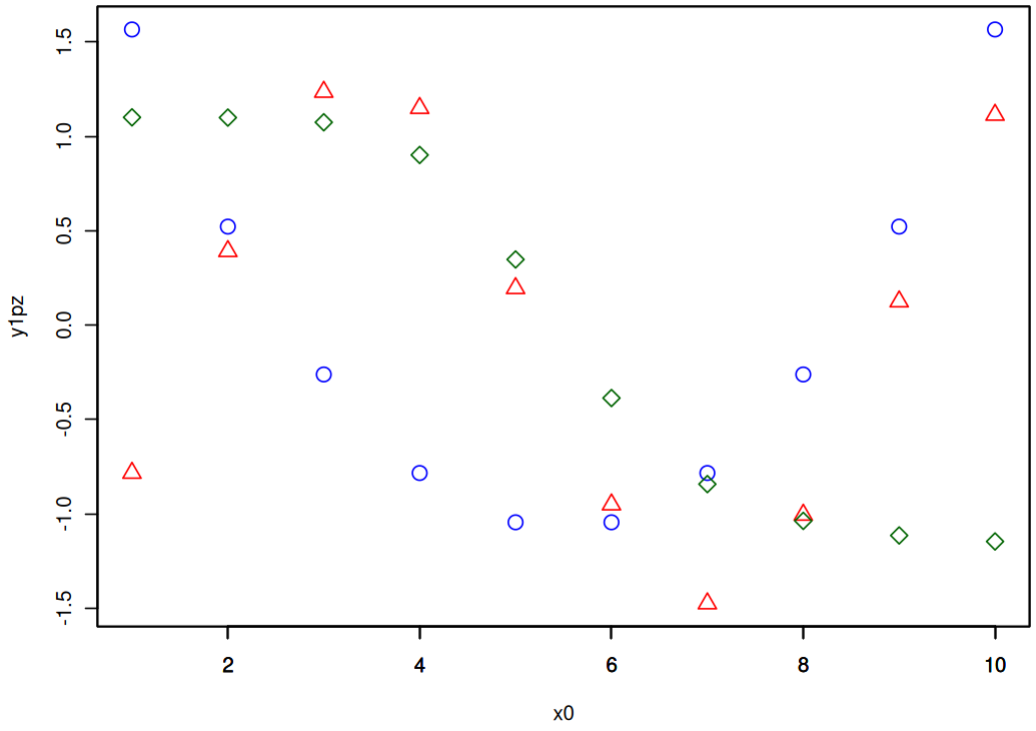
```
y1pz <- znorm(y1)
y2pz <- znorm(y2)
y3pz <- znorm(y3)
```

```
grafdim(9,7)
ymin <- min(min(y1pz), min(y2pz), min(y3pz))
ymax <- max(max(y1pz), max(y2pz), max(y3pz))

plot(x0, y1pz, ylim=c(ymin,ymax), cex=1.5, col="blue", pch=1,)

par(new=T)
plot(x0,y2pz, ylim=c(ymin,ymax), cex=1.5, yaxt="n", pch=2,
     col="red", ylab="", xlab="")

par(new=T)
plot(x0,y3pz, ylim=c(ymin,ymax), cex=1.5, yaxt="n", pch=23,
     col="darkgreen", ylab="", xlab="")
par(new=F)
```



Agora é possível observar o comportamento de cada variável em um mesmo gráfico, uma vez que todas tem a mesma escala.

Preparação dos dados com padronização

```
load("assassinato_EUA_1977.RData")
stp <- st
```

```
summary(st)
```

```
  assassinato       populacao     analfabetismo       renda
 Min.   : 1.400   Min.   :  365   Min.   :0.500   Min.   :3098
 1st Qu.: 4.350   1st Qu.: 1080   1st Qu.:0.625   1st Qu.:3993
 Median : 6.850   Median : 2838   Median :0.950   Median :4519
```

```
 Mean   : 7.378   Mean   : 4246   Mean   :1.170   Mean   :4436
 3rd Qu.:10.675   3rd Qu.: 4968   3rd Qu.:1.575   3rd Qu.:4814
 Max.   :15.100   Max.   :21198   Max.   :2.800   Max.   :6315
  congelamento     ensino_medio    expectativa           regiao
 Min.   :  0.00   Min.   :37.80   Min.   :67.96   Meio-Oeste:12
 1st Qu.: 66.25   1st Qu.:48.05   1st Qu.:70.12   Nordeste  : 9
 Median :114.50   Median :53.25   Median :70.67   Oeste     :13
 Mean   :104.46   Mean   :53.11   Mean   :70.88   Sul       :16
 3rd Qu.:139.75   3rd Qu.:59.15   3rd Qu.:71.89
 Max.   :188.00   Max.   :67.30   Max.   :73.60
    estado
 Length:50
 Class :character
 Mode  :character
```

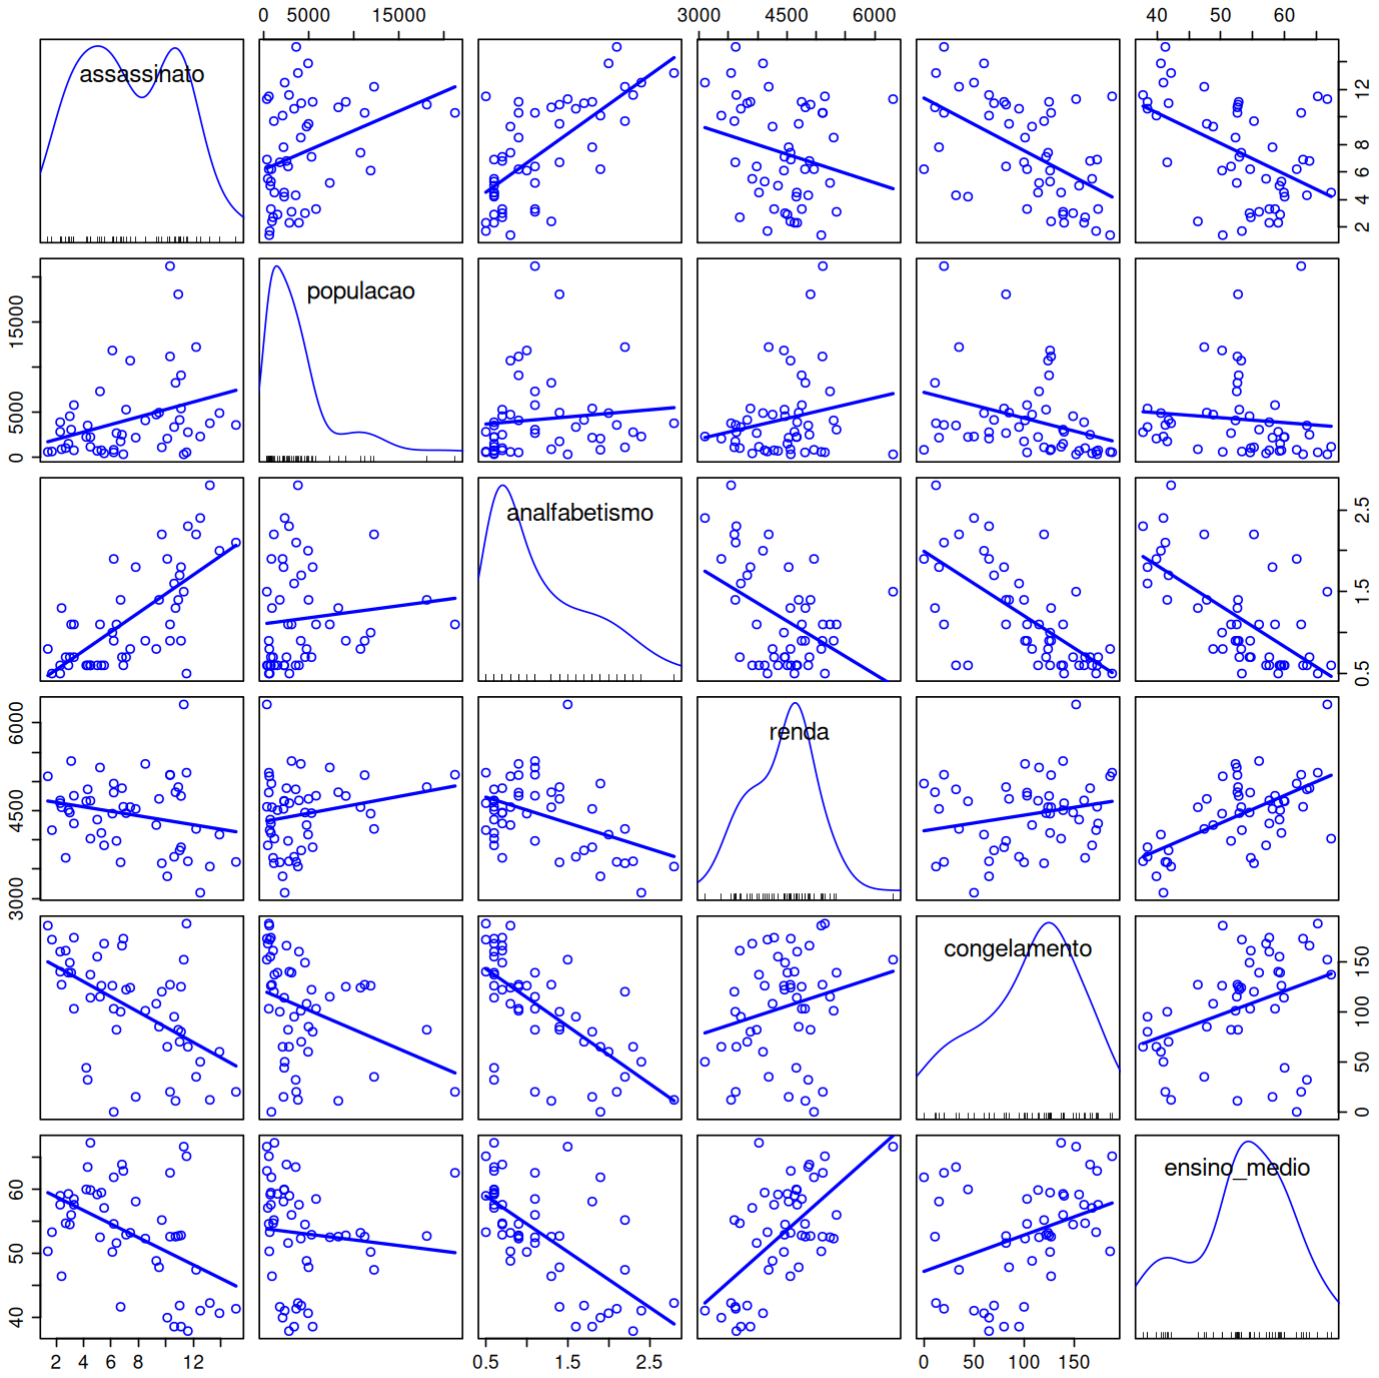
```
stp$populacao     <- znorm(st$populacao)
stp$analfabetismo <- znorm(st$analfabetismo)
stp$renda         <- znorm(st$renda)
stp$congelamento  <- znorm(st$congelamento)
stp$ensino_medio  <- znorm(st$ensino_medio)
stp$expectativa   <- znorm(st$expectativa)
```

```
library(car)
```

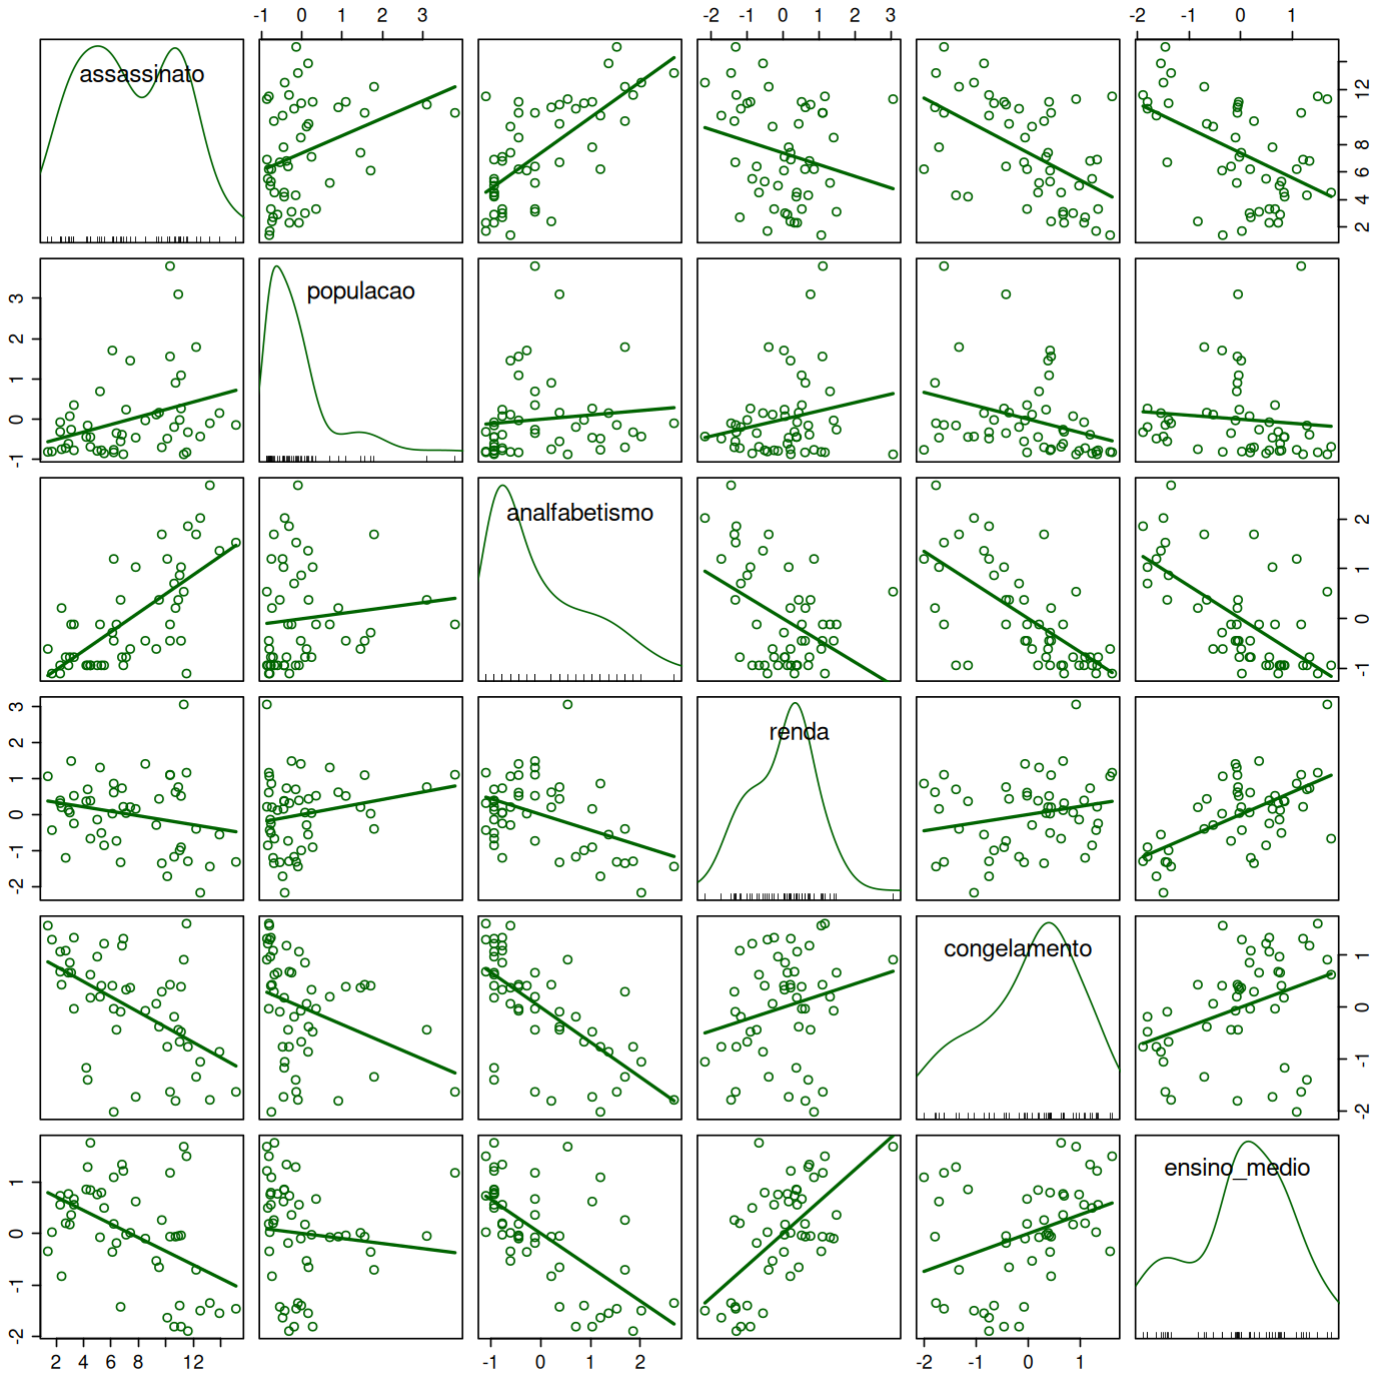
```
Loading required package: carData
```

```
grafdim(12,12)
```

```
scatterplotMatrix(st[,c(1:6)], regLine=TRUE, smooth=FALSE,
                  cex=1.2, cex.lab=1.8, cex.axis=1.4)
```




```
scatterplotMatrix(stp[,c(1:6)], regLine=TRUE, smooth=FALSE,
                  cex=1.2, cex.lab=1.8, cex.axis=1.4, col="darkgreen")
```




```
reg_nivel2_simp2 <- lm(formula= assassinato ~ populacao +  congelamento + ensino_medio +
                                expectativa + congelamento:ensino_medio,
                       data=st)
```

```
summary(reg_nivel2_simp2)
```

```
Call:
lm(formula = assassinato ~ populacao + congelamento + ensino_medio +
    expectativa + congelamento:ensino_medio, data = st)

Residuals:
    Min      1Q  Median      3Q     Max
-2.8632 -1.1720 -0.1792  1.0812  3.3888
```

```
Coefficients:
                            Estimate Std. Error t value Pr(>|t|)
(Intercept)                1.258e+02  1.522e+01   8.262 1.70e-10 ***
populacao                  2.220e-04  5.682e-05   3.907 0.000318 ***
congelamento              -1.912e-01  4.362e-02  -4.383 7.18e-05 ***
ensino_medio              -2.760e-01  8.653e-02  -3.190 0.002624 **
expectativa               -1.439e+00  2.554e-01  -5.634 1.16e-06 ***
congelamento:ensino_medio  3.037e-03  7.769e-04   3.909 0.000316 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.617 on 44 degrees of freedom
Multiple R-squared:  0.8277,    Adjusted R-squared:  0.8082
F-statistic: 42.28 on 5 and 44 DF,  p-value: 1.011e-15
```

```r
reg_znorm <- lm(formula= assassinato ~ populacao + congelamento + ensino_medio +
                         expectativa + congelamento:ensino_medio,
                data=stp)
```

```r
summary(reg_znorm)
```

```
Call:
lm(formula = assassinato ~ populacao + congelamento + ensino_medio +
    expectativa + congelamento:ensino_medio, data = stp)

Residuals:
    Min      1Q  Median      3Q     Max
-2.8632 -1.1720 -0.1792  1.0812  3.3888

Coefficients:
                           Estimate Std. Error t value Pr(>|t|)
(Intercept)                  6.9197     0.2570  26.928  < 2e-16 ***
populacao                    0.9911     0.2537   3.907 0.000318 ***
congelamento                -1.5545     0.2838  -5.478 1.96e-06 ***
ensino_medio                 0.3329     0.2962   1.124 0.267085
expectativa                 -1.9318     0.3429  -5.634 1.16e-06 ***
congelamento:ensino_medio    1.2751     0.3262   3.909 0.000316 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.617 on 44 degrees of freedom
Multiple R-squared:  0.8277,    Adjusted R-squared:  0.8082
F-statistic: 42.28 on 5 and 44 DF,  p-value: 1.011e-15
```

É provável que a explicação trazida pelo `ensino_medio` tenha sido capturada pela interação `congelamento:ensino_medio`.
Vamos considerar um modelo sem a interação e ver se o `ensino_medio` se torna relevante.

```r
reg_znorm2 <- lm(formula= assassinato ~ populacao +  congelamento + ensino_medio +
                                        expectativa,
                 data=stp)
```

```r
summary(reg_znorm2)
```

```
Call:
lm(formula = assassinato ~ populacao + congelamento + ensino_medio +
    expectativa, data = stp)

Residuals:
    Min      1Q  Median      3Q     Max
-3.9442 -1.3810  0.0452  1.6331  3.0730

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)    7.3780     0.2624  28.113  < 2e-16 ***
populacao      0.7339     0.2812   2.610 0.012246 *
congelamento  -1.1339     0.3014  -3.763 0.000484 ***
ensino_medio   0.2465     0.3390   0.727 0.470834
expectativa   -2.6790     0.3268  -8.199 1.77e-10 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.856 on 45 degrees of freedom
Multiple R-squared:  0.7679,    Adjusted R-squared:  0.7473
F-statistic: 37.22 on 4 and 45 DF,  p-value: 9.749e-14
```

Não. Mesmo sem a componente de interação `congelamento:ensino_medio`, o `ensino_medio` não é relevante e o modelo passou a explicar menos os dados (R^2 foi de 0,8082 para 0,7473).
Isso indica que, o que é importante para explicar a variabilidade dos dados é o quanto de `congelamento` contribui *conforme aumenta* o `ensino_medio`.

```r
reg_znorm2 <- lm(formula= assassinato ~  populacao +  congelamento + expectativa +
                                         congelamento:ensino_medio,
                data=stp)
```

```r
summary(reg_znorm2)
```

```
Call:
lm(formula = assassinato ~ populacao + congelamento + expectativa +
    congelamento:ensino_medio, data = stp)

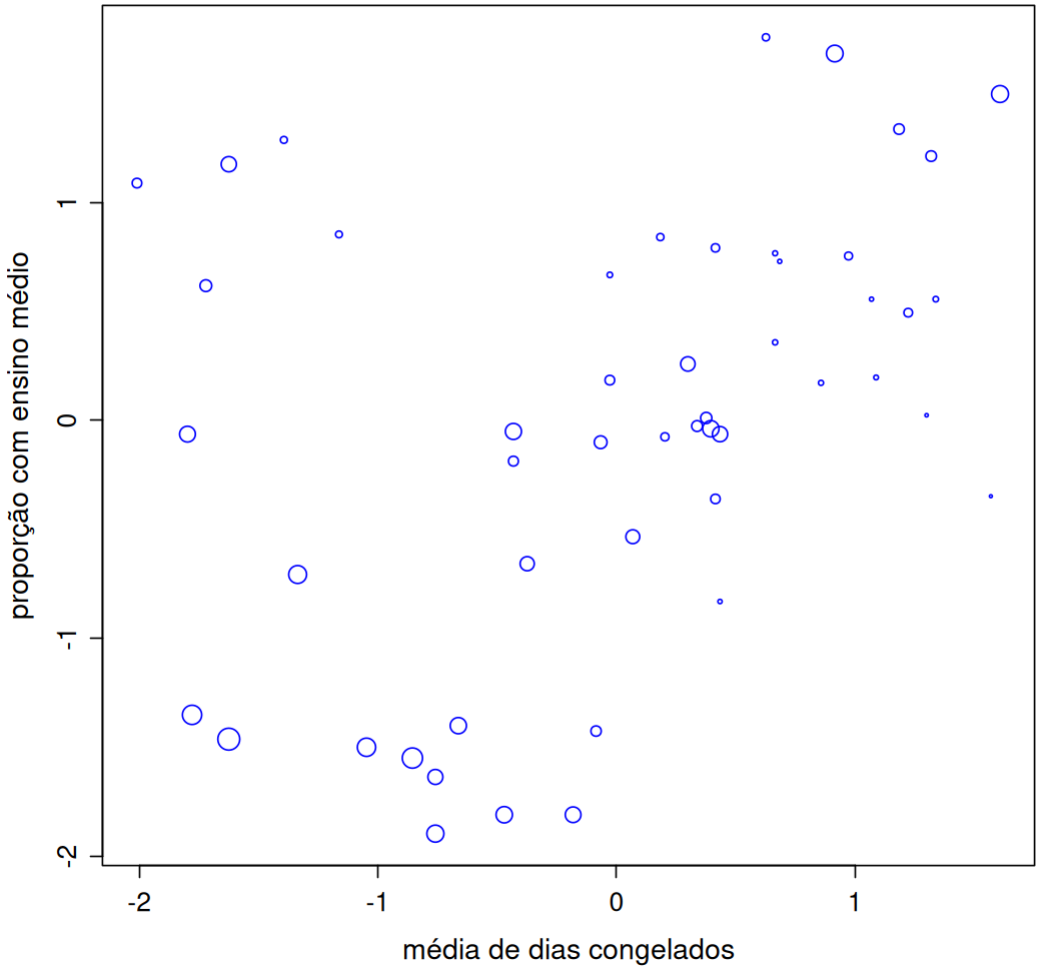
Residuals:
    Min      1Q  Median      3Q     Max
-2.8393 -1.0965 -0.1231  0.7528  3.3988

Coefficients:
                          Estimate Std. Error t value Pr(>|t|)
(Intercept)                 6.9295     0.2576  26.904  < 2e-16 ***
populacao                   0.9906     0.2544   3.894 0.000324 ***
congelamento               -1.4676     0.2738  -5.360 2.76e-06 ***
expectativa                -1.7751     0.3142  -5.649 1.03e-06 ***
congelamento:ensino_medio   1.2477     0.3262   3.825 0.000401 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
Residual standard error: 1.622 on 45 degrees of freedom
Multiple R-squared:  0.8228,    Adjusted R-squared:  0.807
F-statistic: 52.23 on 4 and 45 DF,  p-value: 2.406e-16
```

Uma vez que as variáveis preditoras tem a mesma escala, seus coeficientes dão uma ideia da "força" da sua contribuição na explicação do modelo.

```
grafdim(9,9)
plot(stp$congelamento, stp$ensino_medio,
     cex=stp$assassinato/6.5, cex.lab=1.4, cex.axis=1.3,
     col="blue", xlab="média de dias congelados",
     ylab="proporção com ensino médio")
```




```
tail(stp[order(stp$ensino_medio), c("assassinato", "congelamento", "ensino_medio")],10)
```

A data.frame: 10 × 3

	assassinato <dbl>	congelamento <dbl>	ensino_medio <dbl>
Kansas	4.5	0.1835291	0.8409065
Oregon	4.2	-1.1631207	0.8532873
Hawaii	6.2	-2.0095863	1.0885233
California	10.3	-1.6248292	1.1751891
Wyoming	6.9	1.3185626	1.2123316

	assassinato <dbl>	congelamento <dbl>	ensino_medio <dbl>
Washington	4.3	-1.3939749	1.2866167
Colorado	6.8	1.1838976	1.3361400
Nevada	11.5	1.6071304	1.4970909
Alaska	11.3	0.9145676	1.6828035
Utah	4.5	0.6259998	1.7570885

Podemos observar que, exceto Nevada e Alasca — com alta taxa de dias congelados e alta taxa de ensino médio, há alta taxa de assassinato — e Oregon, Havai e Washington — com baixa taxa de dias congelados, alta taxa de ensino médio e baixa taxa de assassinatos —, há uma correlação positiva (crescimento de uma variável está assossiado ao crescimento da outra) entre `congelamento` e `ensino_medio`.

```
save(stp, file="assassinato_EUA_1977_znorm.RData")
```