Regressão Múltipla

IFSP - PEP

Cláudio M. Zaina

Técnica de Regressão Múltipla

Índice

Regressão Linear Múltipla **1**
Dados . . . 1
Análise Exploratória . . . 2
Modelo Padrão-Base (*Baseline*) . . . 5
Modelos Avançados . . . 8
Modelo Escolhido . . . 13

Regressão Linear Múltipla

Regressão Linear Simples pode ser expandida para utilizar mais variáveis preditoras. Temos então a regressão linear múltipla. Tecnicamente, regressão polinomial (como visto anteriormente) já é um caso de regressão linear múltipla.

Dados

Vamos utilizar o banco de dados `state.x77` disponível em R na forma de matriz com os dados dos 50 estados dos Estados Unidos. As variáveis são:

Nome original	Nome	Descrição	Tradução (livre)
`Population`	`populacao`	*population estimate as of July 1, 1975*	população estimada em 01/07/1975
`Income`	`renda`	*per capita income (1974)*	renda per capita em 1974
`Illiteracy`	`analfabetismo`	*illiteracy (1970, percent of population)*	analfabetismo (porcentagem da população em 1970)
`Life Exp`	`expectativa`	*life expectancy in years (1969–71)*	expectativa de vida em anos (1961-1971)
`Murder`	`assassinato`	*murder and non-negligent manslaughter rate per 100,000 population (1976)*	taxa de homicídios e homicídios culposos não negligentes por 100.000 habitantes (1976)
`HS Grad`	`ens_medio`	*percent high-school graduates (1970)*	porcentagem de concluintes do ensino médio (1970)
`Frost`	`congelamento`	*mean number of days with minimum temperature below freezing (1931–1960) in capital or large city*	número médio de dias com temperaturas mínimas abaixo do ponto de congelamento (1931-1960) na capital ou em grandes cidades

Foram incorporadas as variáveis `state.region` como `regiao` e `state.name` como `estado`. O conjunto de dados foi salvo (no exercício de Regressão Linear Simples) e está pronto para ser utilizado, bastando carregá-lo no caderno.

```
rm(list=ls())
```

```
# criando função para dimensionar gráfico no Jupyter
library(repr)
grafdim <- function(x=11,y=8) { options(repr.plot.width=x, repr.plot.height=y) }
```

```
load("assassinato_EUA_1977.RData")
```

```
summary(st)
```

```
  assassinato       populacao     analfabetismo       renda      
 Min.   : 1.400   Min.   :  365   Min.   :0.500   Min.   :3098  
 1st Qu.: 4.350   1st Qu.: 1080   1st Qu.:0.625   1st Qu.:3993  
 Median : 6.850   Median : 2838   Median :0.950   Median :4519  
 Mean   : 7.378   Mean   : 4246   Mean   :1.170   Mean   :4436  
 3rd Qu.:10.675   3rd Qu.: 4968   3rd Qu.:1.575   3rd Qu.:4814  
 Max.   :15.100   Max.   :21198   Max.   :2.800   Max.   :6315  
  congelamento     ensino_medio    expectativa          regiao   
 Min.   :  0.00   Min.   :37.80   Min.   :67.96   Meio-Oeste:12  
 1st Qu.: 66.25   1st Qu.:48.05   1st Qu.:70.12   Nordeste  : 9  
 Median :114.50   Median :53.25   Median :70.67   Oeste     :13  
 Mean   :104.46   Mean   :53.11   Mean   :70.88   Sul       :16  
 3rd Qu.:139.75   3rd Qu.:59.15   3rd Qu.:71.89                  
 Max.   :188.00   Max.   :67.30   Max.   :73.60                  
    estado         
 Length:50          
 Class :character   
 Mode  :character   
```

```
head(st)
```

A data.frame: 6 × 9

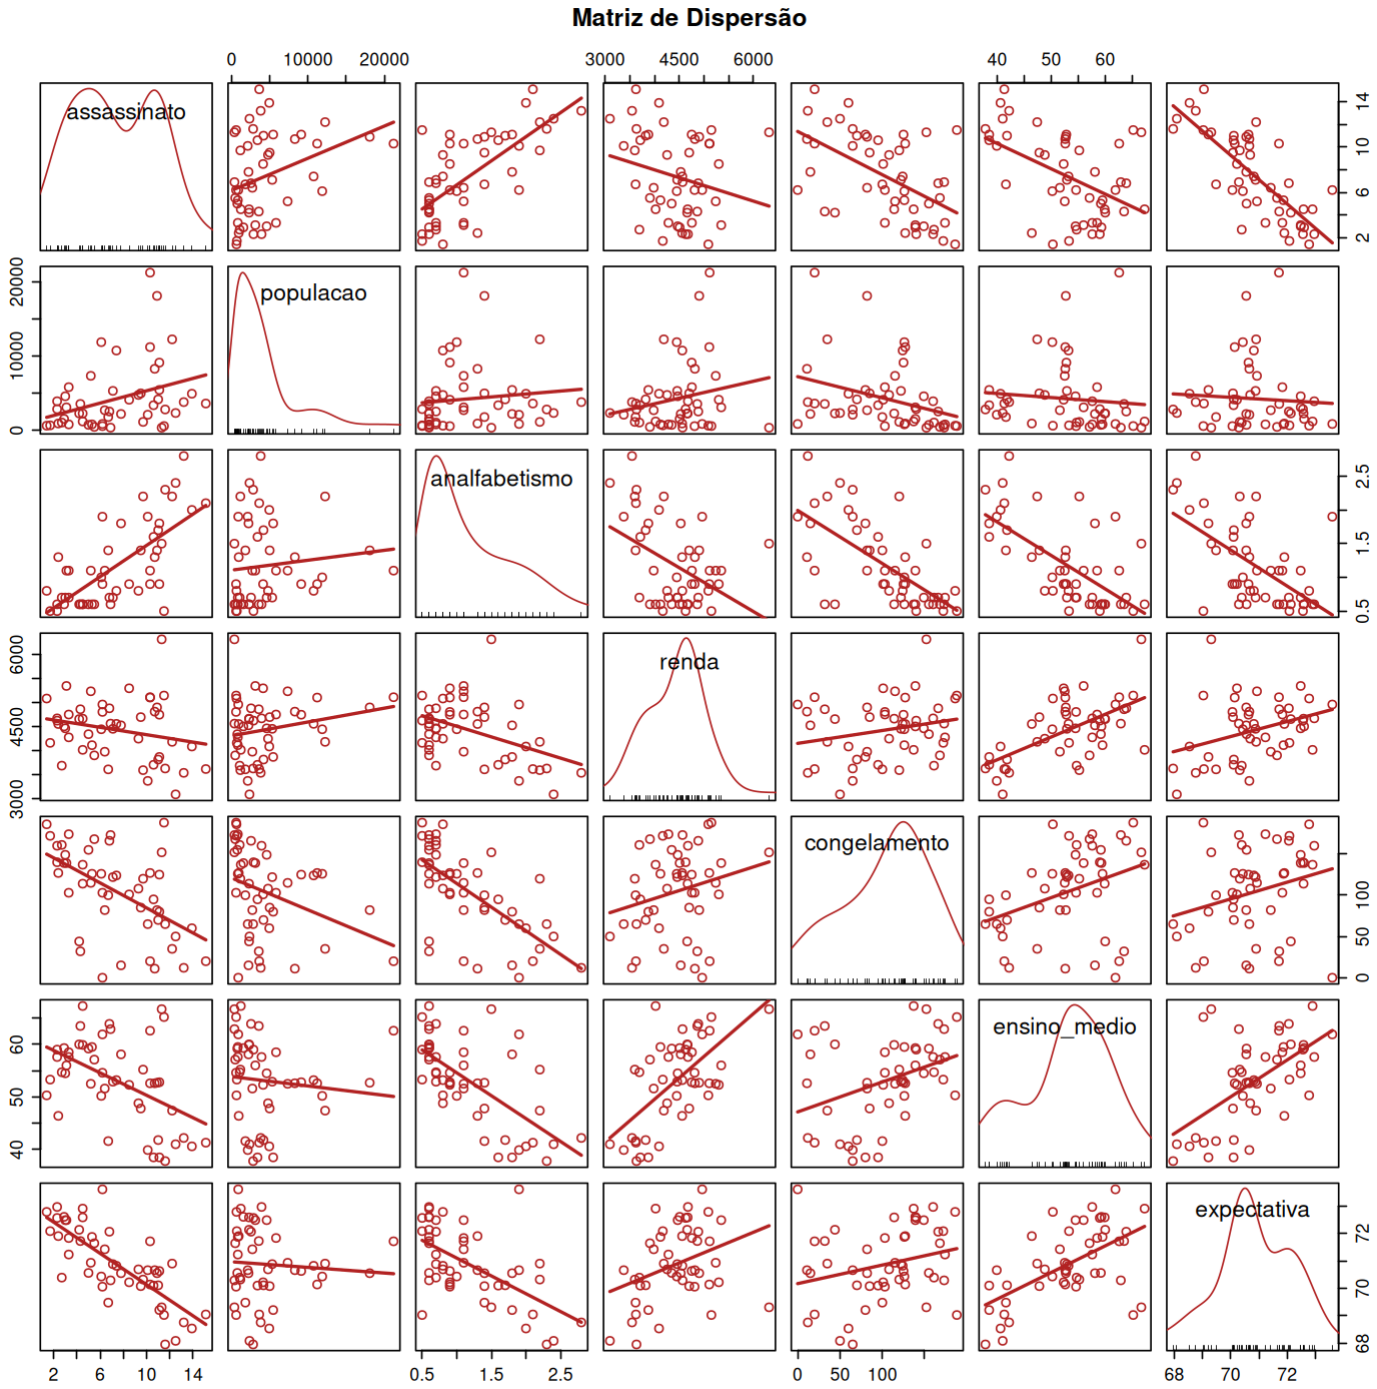
	assassinato <dbl>	populacao <dbl>	analfabetismo <dbl>	renda <dbl>	congelamento <dbl>	ensino_medio <dbl>	expectativa <dbl>	regiao <fct>	estado <chr>
Alabama	15.1	3615	2.1	3624	20	41.3	69.05	Sul	Alabama
Alaska	11.3	365	1.5	6315	152	66.7	69.31	Oeste	Alaska
Arizona	7.8	2212	1.8	4530	15	58.1	70.55	Oeste	Arizona
Arkansas	10.1	2110	1.9	3378	65	39.9	70.66	Sul	Arkansas
California	10.3	21198	1.1	5114	20	62.6	71.71	Oeste	California
Colorado	6.8	2541	0.7	4884	166	63.9	72.06	Oeste	Colorado

Análise Exploratória

Examinando as variáveis e os seus relacionamentos:

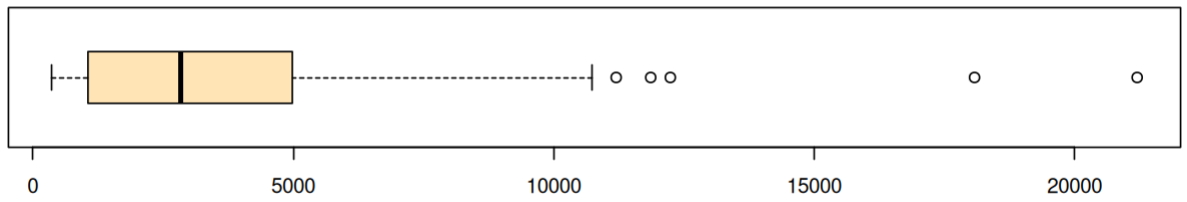
```
library(car)
grafdim(12,12)
varnum <- c("assassinato","populacao","analfabetismo","renda","congelamento","ensino_medio","expectativa")
scatterplotMatrix(st[,varnum], smooth=FALSE, col="firebrick",
                  cex=1.2, cex.labels=1.7, cex.axis=1.3,
                  main="Matriz de Dispersão")
```

```
Loading required package: carData
```



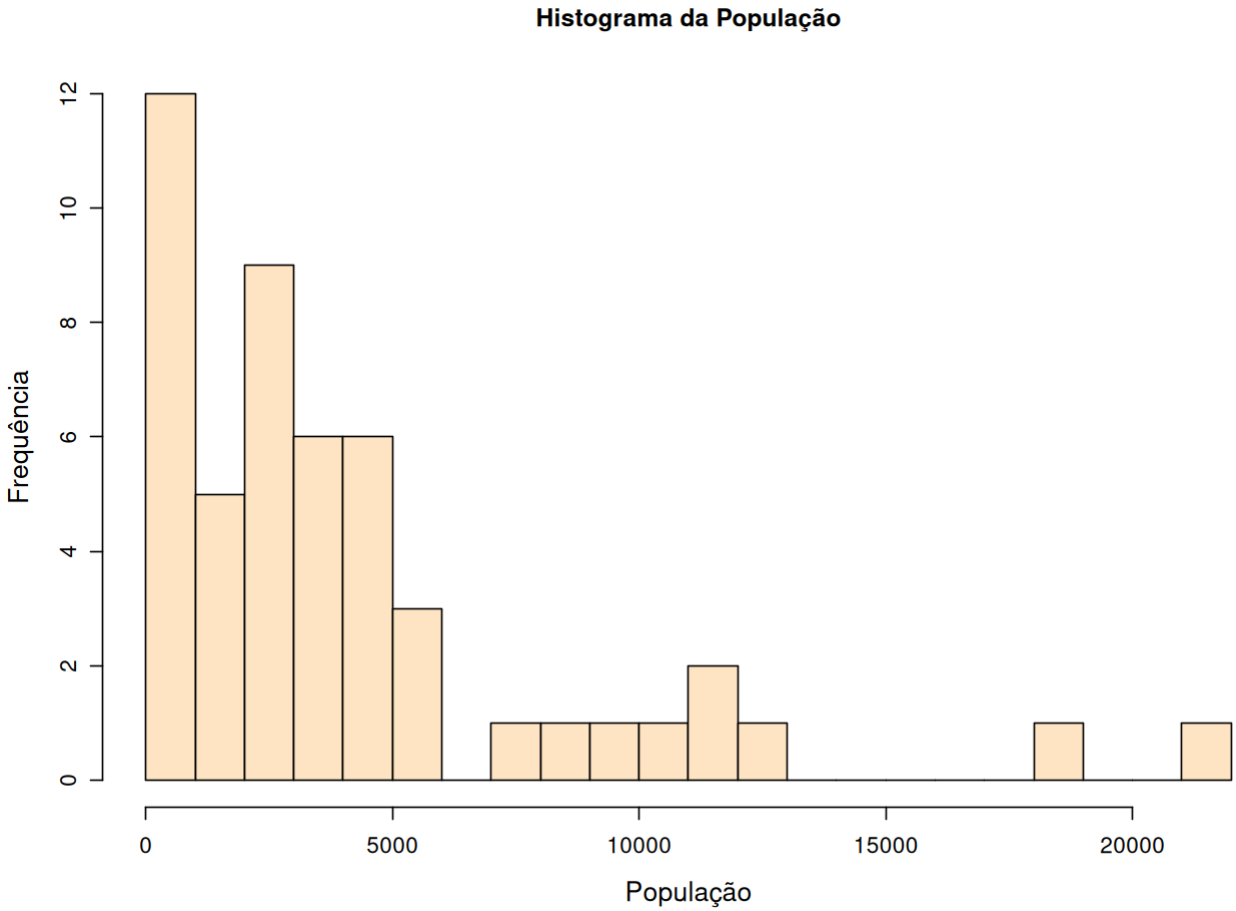

```
grafdim(11,3)
```

```
# se quiser examinar uma das variáveis em particular
boxplot(st$populacao, horizontal=TRUE, col="moccasin")
```



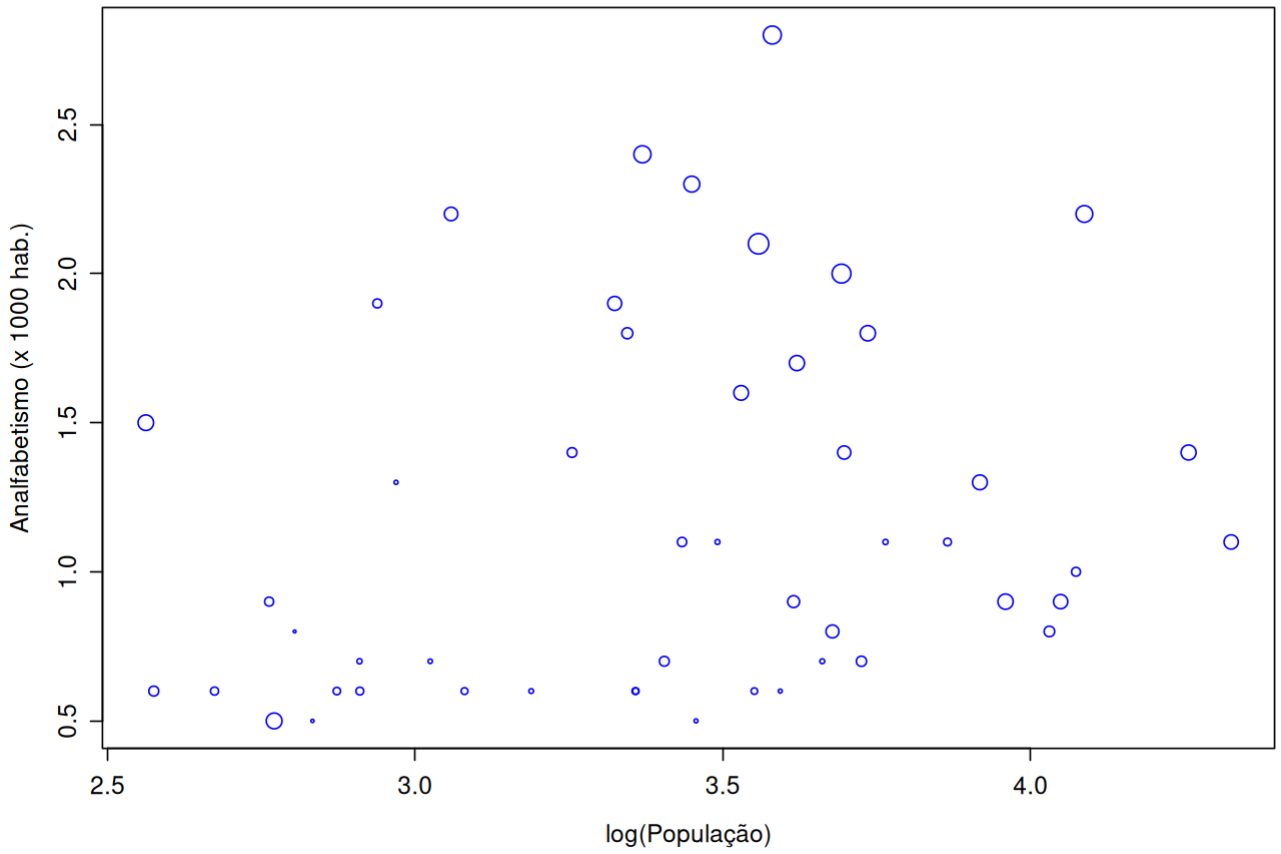
Utilizando um histrograma:

```
grafdim()
hist(st$populacao, main="Histograma da População",
     xlab="População", ylab="Frequência",
     cex.lab=1.3, cex.axis=1.1,
     col=c("bisque"), breaks=15)
```



Pode ser interessante comparar uma variável com outra. A seguir graficamos o *log*(`populacao`) com a proporção de `analfabetismo`. O tamanho dos pontos é proporcional à taxa de `assassinato`:

```
plot(log10(st$populacao), st$analfabetismo, col="blue",
     cex=st$assassinato/7.0, cex.lab=1.2, cex.axis=1.2,
     xlab="log(População)", ylab="Analfabetismo (x 1000 hab.)")
```




```
# Correlação entre as variáveis -1 ⩽ cor ⩽ 1
round(cor(st[,varnum]),3)
```

A matrix: 7 × 7 of type dbl

	assassinato	populacao	analfabetismo	renda	congelamento	ensino_medio	expectativa
assassinato	1.000	0.344	0.703	-0.230	-0.539	-0.488	-0.781
populacao	0.344	1.000	0.108	0.208	-0.332	-0.098	-0.068
analfabetismo	0.703	0.108	1.000	-0.437	-0.672	-0.657	-0.588
renda	-0.230	0.208	-0.437	1.000	0.226	0.620	0.340
congelamento	-0.539	-0.332	-0.672	0.226	1.000	0.367	0.262
ensino_medio	-0.488	-0.098	-0.657	0.620	0.367	1.000	0.582
expectativa	-0.781	-0.068	-0.588	0.340	0.262	0.582	1.000

Modelo Padrão-Base (*Baseline*)

A análise da melhoria do modelo se dá contrastando com um modelo inicial, considerado bom, para que as melhorias sejam significativas. Tal modelo é chamado de modelo-base ou *baseline*.

```
regbas <- lm(formula = assassinato ~ populacao + analfabetismo +
                       renda + congelamento + ensino_medio + expectativa,
             data=st)
```

```
summary(regbas)
```

```
Call:
lm(formula = assassinato ~ populacao + analfabetismo + renda +
    congelamento + ensino_medio + expectativa, data = st)

Residuals:
    Min      1Q  Median      3Q     Max
-3.5237 -1.0835  0.0329  1.1502  3.0804

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.257e+02  1.805e+01   6.965 1.45e-08 ***
populacao      1.922e-04  6.577e-05   2.923  0.00551 **
analfabetismo  1.913e+00  7.708e-01   2.481  0.01707 *
renda          5.691e-05  5.651e-04   0.101  0.92025
congelamento  -1.018e-02  7.310e-03  -1.392  0.17105
ensino_medio   7.355e-02  5.174e-02   1.421  0.16240
expectativa   -1.756e+00  2.522e-01  -6.963 1.45e-08 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.775 on 43 degrees of freedom
Multiple R-squared:  0.797, Adjusted R-squared:  0.7687
F-statistic: 28.14 on 6 and 43 DF,  p-value: 2.217e-13
```

As variáveis `renda`, `congelamento` e `ensino_medio` não se mostraram significativamente (a α=5%) diferentes de zero. Seria interessante avaliar o modelo sem elas.

```r
regbas <- lm(formula = assassinato ~ populacao + analfabetismo + expectativa,
             data=st)
```

```r
summary(regbas)
```

```
Call:
lm(formula = assassinato ~ populacao + analfabetismo + expectativa,
    data = st)

Residuals:
    Min      1Q  Median      3Q     Max
-3.7412 -1.0472  0.1251  1.3323  3.4869

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.131e+02  1.736e+01   6.514 4.89e-08 ***
populacao      2.220e-04  5.860e-05   3.788 0.000440 ***
analfabetismo  2.088e+00  5.297e-01   3.941 0.000274 ***
expectativa   -1.539e+00  2.397e-01  -6.423 6.71e-08 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.821 on 46 degrees of freedom
Multiple R-squared:  0.7716,    Adjusted R-squared:  0.7567
F-statistic: 51.81 on 3 and 46 DF,  p-value: 8.619e-15
```

Um indicador da qualidade da regressão é o erro absoluto médio (eam), que é a média da soma do absoluto das diferenças entre os valores observados e seus valores preditos, ou seja:

$$eam = \frac{\sum |y_i - \hat{y}_i|}{n} = \frac{\sum |observado_i - predito_i|}{n}$$

```
eam <- function(observado, predito) {
    return(sum(abs(observado - predito)) / length(observado))
}
```

Erro absoluto médio para a regressão básica:

```
sum(abs(regbas$residuals))/length(st$assassinato)
eam(st$assassinato, regbas$fitted.values)
```

1.45555049225443

1.45555049225443

O modelo para a taxa de assassinato então seria:

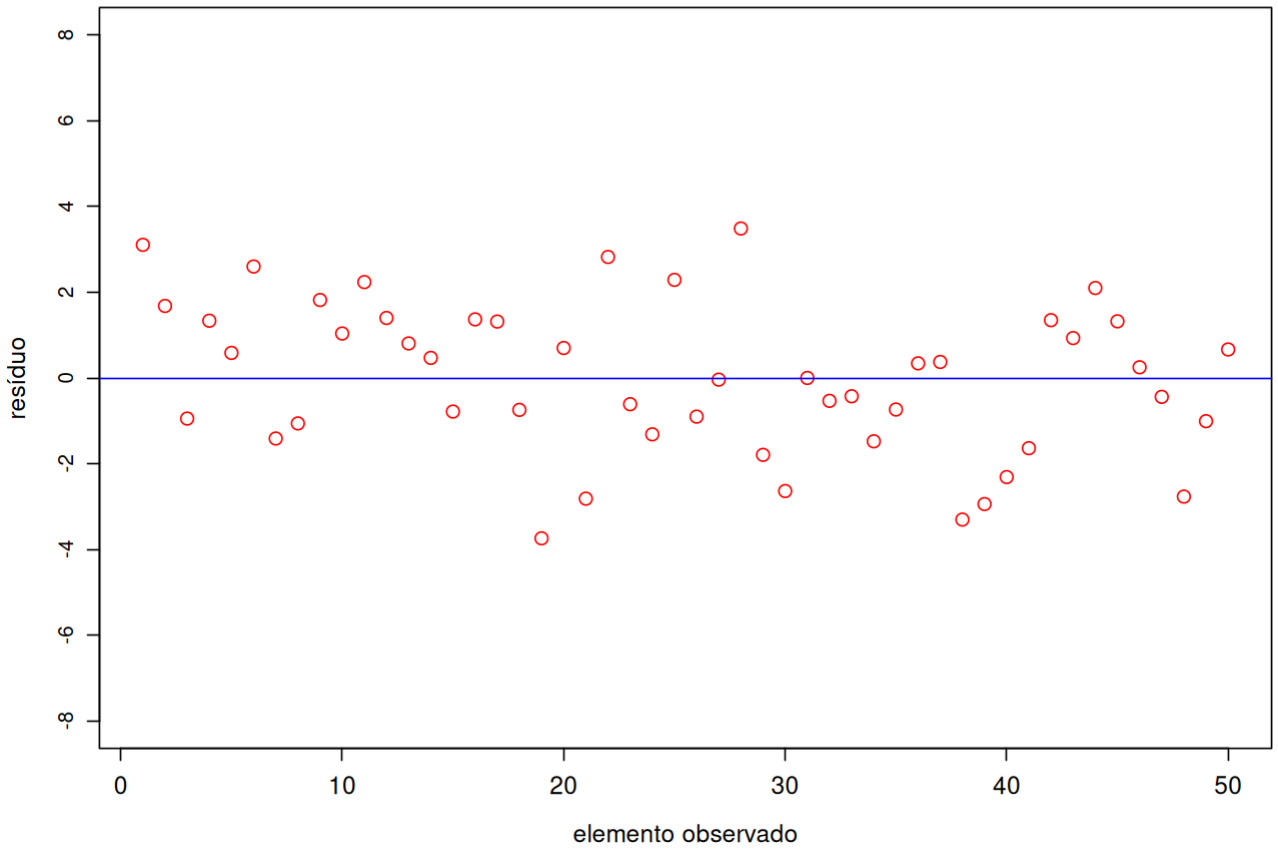
`Assassinato` $= 113{,}1 + 2{,}22 \cdot 10^{-4}$ `populacao` $+\ 2{,}088$ `analfabetismo` $-1{,}539$ `expectativa`

À 5% de significância, ou seja com $\alpha = 0{,}05$, apenas `Populacao` e `Analfabetismo` foram significativamente diferente de 0 em suas hipóteses nulas.

Observação: o nível de significância é **pré-fixado** em todo experimento. Normalmente 0,05.

```
grafdim()
```

```
plot(regbas$residuals,
     xlab="elemento observado", ylab="resíduo",
     cex=1.3, cex.lab=1.2, cex.axis=1.2,
     ylim=c(-8,8), yaxt = "n", col="red")
axis(2, at=seq(-8,8,2))
abline(h=0.0, col="blue")
```




```
print(head(sort(regbas$residuals)))
```

```
      Maine  Pennsylvania  Rhode Island Massachusetts West Virginia
  -3.741159     -3.303655     -2.941253     -2.815396     -2.767664
 New Jersey
  -2.637901
```

```
print(tail(sort(regbas$residuals)))
```

```
  Hawaii Missouri Colorado Michigan  Alabama   Nevada
2.236904 2.288546 2.600192 2.823166 3.106045 3.486866
```

Modelos Avançados

```
reg_nivel2 <- lm(formula= assassinato ~
                          populacao + analfabetismo + renda +
                          congelamento + ensino_medio + expectativa +
                          populacao:analfabetismo +
                          populacao:renda +
                          populacao:congelamento +
                          populacao:ensino_medio +
                          populacao:expectativa +
                          analfabetismo:renda +
                          analfabetismo:congelamento +
                          analfabetismo:ensino_medio +
                          analfabetismo:expectativa +
```

```
                        renda:congelamento +
                        renda:ensino_medio +
                        renda:expectativa +
                        congelamento:ensino_medio +
                        congelamento:expectativa,
                data=st)
```

```
summary(reg_nivel2)
```

```
Call:
lm(formula = assassinato ~ populacao + analfabetismo + renda +
    congelamento + ensino_medio + expectativa + populacao:analfabetismo +
    populacao:renda + populacao:congelamento + populacao:ensino_medio +
    populacao:expectativa + analfabetismo:renda + analfabetismo:congelamento +
    analfabetismo:ensino_medio + analfabetismo:expectativa +
    renda:congelamento + renda:ensino_medio + renda:expectativa +
    congelamento:ensino_medio + congelamento:expectativa, data = st)

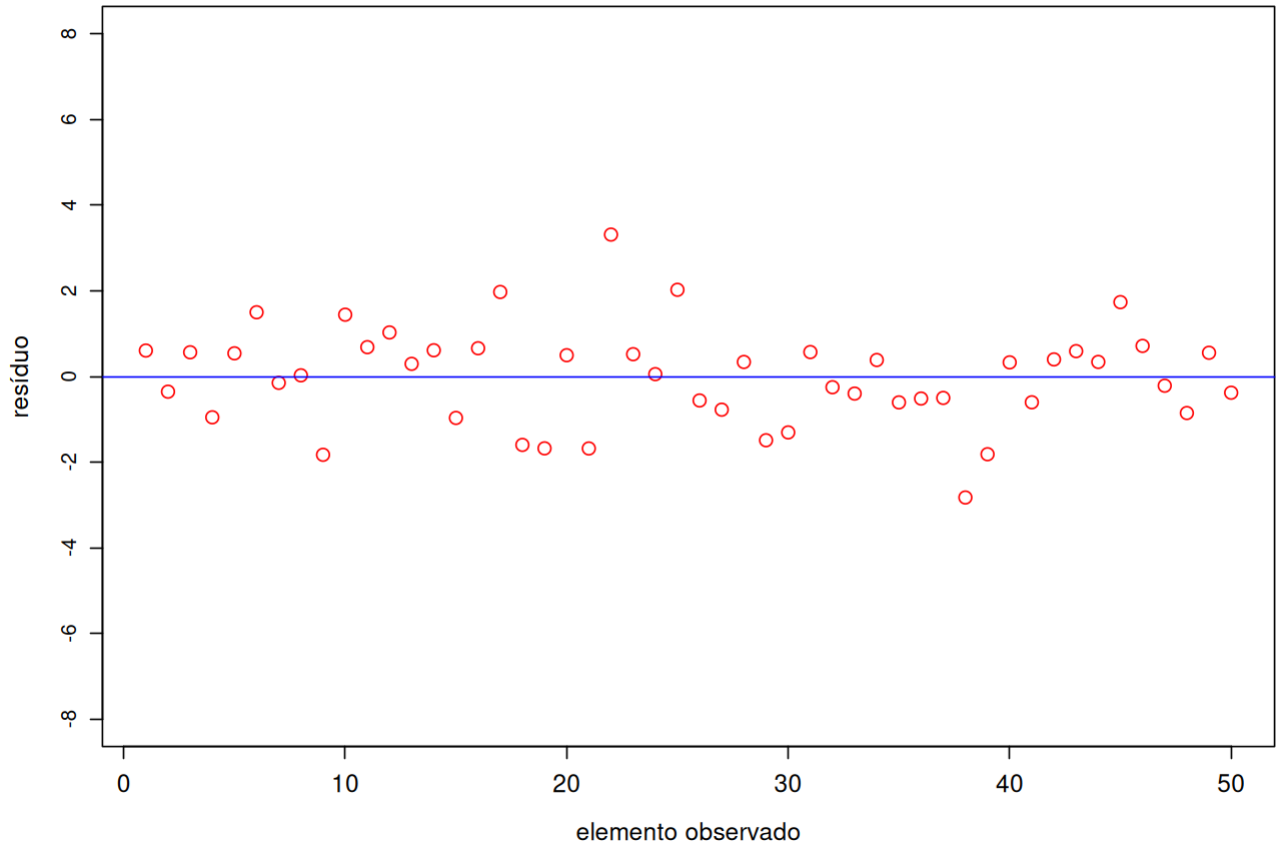
Residuals:
    Min      1Q  Median      3Q     Max
-2.8257 -0.6045  0.1748  0.5865  3.3135

Coefficients:
                             Estimate Std. Error t value Pr(>|t|)
(Intercept)                -1.035e+02  2.057e+02  -0.503   0.6186
populacao                   2.002e-02  1.208e-02   1.657   0.1083
analfabetismo              -1.620e+01  5.037e+01  -0.322   0.7500
renda                       2.885e-02  3.325e-02   0.868   0.3926
congelamento                2.051e-01  6.266e-01   0.327   0.7458
ensino_medio               -6.319e-01  5.911e-01  -1.069   0.2939
expectativa                 1.942e+00  2.878e+00   0.675   0.5052
populacao:analfabetismo    -5.071e-04  3.509e-04  -1.445   0.1592
populacao:renda            -2.861e-08  3.094e-07  -0.092   0.9270
populacao:congelamento     -5.303e-06  2.850e-06  -1.860   0.0730 .
populacao:ensino_medio     -1.723e-05  4.513e-05  -0.382   0.7053
populacao:expectativa      -2.489e-04  1.851e-04  -1.345   0.1892
analfabetismo:renda        -1.573e-03  1.489e-03  -1.057   0.2993
analfabetismo:congelamento  2.880e-03  1.104e-02   0.261   0.7960
analfabetismo:ensino_medio  8.834e-02  1.452e-01   0.608   0.5476
analfabetismo:expectativa   2.847e-01  7.616e-01   0.374   0.7113
renda:congelamento          5.515e-06  2.350e-05   0.235   0.8161
renda:ensino_medio          3.562e-05  9.558e-05   0.373   0.7121
renda:expectativa          -4.191e-04  4.555e-04  -0.920   0.3652
congelamento:ensino_medio   4.038e-03  1.970e-03   2.049   0.0496 *
congelamento:expectativa   -6.482e-03  9.694e-03  -0.669   0.5090
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.49 on 29 degrees of freedom
Multiple R-squared:  0.9035,    Adjusted R-squared:  0.837
F-statistic: 13.58 on 20 and 29 DF,  p-value: 8.326e-10
```

```
plot(reg_nivel2$residuals,
     xlab="elemento observado", ylab="resíduo",
```

```
     cex=1.3, cex.lab=1.2, cex.axis=1.2,
     ylim=c(-8,8), yaxt = "n", col="red")
axis(2, at=seq(-8,8,2))
abline(h=0.0, col="blue")
```




```
eam(st$assassinato,reg_nivel2$fitted.values)
```

0.892128593862913

```
reg_nivel3 <- lm(formula = assassinato ~
                           (populacao + analfabetismo + renda +
                            congelamento + ensino_medio + expectativa)^3,
              data=st)
```

```
summary(reg_nivel3)
```

```
Call:
lm(formula = assassinato ~ (populacao + analfabetismo + renda +
    congelamento + ensino_medio + expectativa)^3, data = st)

Residuals:
     Min       1Q   Median       3Q      Max
-1.66577 -0.35397 -0.00463  0.20403  2.94508

Coefficients:
                                          Estimate Std. Error t value Pr(>|t|)
```

```
(Intercept)                             -1.037e+03  1.186e+04  -0.087    0.932
populacao                               -2.988e-01  6.794e-01  -0.440    0.672
analfabetismo                           -1.401e+03  2.993e+03  -0.468    0.652
renda                                    1.794e+00  2.308e+00   0.777    0.459
congelamento                            -4.668e+01  4.027e+01  -1.159    0.280
ensino_medio                             7.649e+01  1.026e+02   0.746    0.477
expectativa                             -2.065e+00  1.902e+02  -0.011    0.992
populacao:analfabetismo                 -5.657e-03  1.629e-01  -0.035    0.973
populacao:renda                         -1.988e-05  5.472e-05  -0.363    0.726
populacao:congelamento                  -4.538e-04  1.530e-03  -0.297    0.774
populacao:ensino_medio                   7.514e-03  7.281e-03   1.032    0.332
populacao:expectativa                    4.846e-03  9.502e-03   0.510    0.624
analfabetismo:renda                      2.617e-01  6.770e-01   0.387    0.709
analfabetismo:congelamento               8.385e-01  3.420e+00   0.245    0.812
analfabetismo:ensino_medio              -7.556e+00  2.831e+01  -0.267    0.796
analfabetismo:expectativa                2.478e+01  4.924e+01   0.503    0.628
renda:congelamento                       7.671e-04  6.282e-03   0.122    0.906
renda:ensino_medio                      -4.191e-02  2.308e-02  -1.816    0.107
renda:expectativa                       -2.124e-02  3.722e-02  -0.571    0.584
congelamento:ensino_medio                5.926e-01  3.547e-01   1.671    0.133
congelamento:expectativa                 7.362e-01  6.866e-01   1.072    0.315
ensino_medio:expectativa                -7.918e-01  1.618e+00  -0.490    0.638
populacao:analfabetismo:renda            1.252e-06  3.358e-06   0.373    0.719
populacao:analfabetismo:congelamento     2.020e-06  3.128e-05   0.065    0.950
populacao:analfabetismo:ensino_medio    -8.879e-05  3.605e-04  -0.246    0.812
populacao:analfabetismo:expectativa      4.735e-05  2.324e-03   0.020    0.984
populacao:renda:congelamento             3.801e-08  6.185e-08   0.614    0.556
populacao:renda:ensino_medio             1.093e-07  1.697e-07   0.644    0.538
populacao:renda:expectativa              1.238e-07  8.372e-07   0.148    0.886
populacao:congelamento:ensino_medio     -1.205e-06  4.990e-06  -0.242    0.815
populacao:congelamento:expectativa       4.516e-06  2.228e-05   0.203    0.844
populacao:ensino_medio:expectativa      -1.103e-04  9.086e-05  -1.214    0.259
analfabetismo:renda:congelamento         1.661e-04  2.862e-04   0.581    0.578
analfabetismo:renda:ensino_medio         1.459e-03  1.879e-03   0.777    0.460
analfabetismo:renda:expectativa         -5.215e-03  1.095e-02  -0.476    0.647
analfabetismo:congelamento:ensino_medio -2.065e-02  1.752e-02  -1.179    0.272
analfabetismo:congelamento:expectativa  -5.316e-03  5.643e-02  -0.094    0.927
analfabetismo:ensino_medio:expectativa   4.538e-02  3.748e-01   0.121    0.907
renda:congelamento:ensino_medio          2.473e-05  3.691e-05   0.670    0.522
renda:congelamento:expectativa          -3.152e-05  1.081e-04  -0.292    0.778
renda:ensino_medio:expectativa           5.215e-04  3.489e-04   1.495    0.173
congelamento:ensino_medio:expectativa   -9.663e-03  5.586e-03  -1.730    0.122

Residual standard error: 1.661 on 8 degrees of freedom
Multiple R-squared:  0.9669,    Adjusted R-squared:  0.7975
F-statistic: 5.707 on 41 and 8 DF,  p-value: 0.006917
```

O modelo, com interações até o 3º nível, não explica satisfatóriamente o comportamento de `Assassinato` em função de suas variáveis.
Poderíamos melhorar o modelo de 2º nível mantendo as interações consideradas significativas e as variáveis de 1º nível:

```
reg_nivel2_simp <- lm(formula= assassinato ~
                          populacao + analfabetismo + renda +
                          congelamento + ensino_medio + expectativa +
                          populacao:congelamento +
```

```
                        congelamento:ensino_medio,
                    data=st)
```

```
summary(reg_nivel2_simp)
```

```
Call:
lm(formula = assassinato ~ populacao + analfabetismo + renda +
    congelamento + ensino_medio + expectativa + populacao:congelamento +
    congelamento:ensino_medio, data = st)

Residuals:
    Min      1Q  Median      3Q     Max
-3.0390 -0.9854 -0.0126  0.9474  3.4642

Coefficients:
                             Estimate Std. Error t value Pr(>|t|)
(Intercept)                 1.121e+02  1.681e+01   6.667 4.87e-08 ***
populacao                   2.246e-04  9.843e-05   2.282  0.02774 *
analfabetismo               1.164e+00  7.322e-01   1.590  0.11957
renda                       4.827e-04  5.303e-04   0.910  0.36804
congelamento               -1.717e-01  4.891e-02  -3.510  0.00110 **
ensino_medio               -2.496e-01  1.062e-01  -2.351  0.02363 *
expectativa                -1.326e+00  2.611e-01  -5.078 8.72e-06 ***
populacao:congelamento     -1.133e-07  1.089e-06  -0.104  0.91768
congelamento:ensino_medio  2.812e-03  8.344e-04   3.370  0.00165 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.607 on 41 degrees of freedom
Multiple R-squared:  0.8415,    Adjusted R-squared:  0.8106
F-statistic: 27.21 on 8 and 41 DF,  p-value: 4.61e-14
```

Aparentemente há espaço pra melhoria, considerando apenas as variáveis significativas de 1º nível:

```
reg_nivel2_simp2 <- lm(formula= assassinato ~
                        populacao +
                        congelamento + ensino_medio + expectativa +
                        congelamento:ensino_medio,
                    data=st)
```

```
summary(reg_nivel2_simp2)
```

```
Call:
lm(formula = assassinato ~ populacao + congelamento + ensino_medio +
    expectativa + congelamento:ensino_medio, data = st)

Residuals:
    Min      1Q  Median      3Q     Max
-2.8632 -1.1720 -0.1792  1.0812  3.3888

Coefficients:
                            Estimate Std. Error t value Pr(>|t|)
```

```
(Intercept)               1.258e+02  1.522e+01   8.262 1.70e-10 ***
populacao                 2.220e-04  5.682e-05   3.907 0.000318 ***
congelamento             -1.912e-01  4.362e-02  -4.383 7.18e-05 ***
ensino_medio             -2.760e-01  8.653e-02  -3.190 0.002624 **
expectativa              -1.439e+00  2.554e-01  -5.634 1.16e-06 ***
congelamento:ensino_medio  3.037e-03  7.769e-04   3.909 0.000316 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.617 on 44 degrees of freedom
Multiple R-squared:  0.8277,    Adjusted R-squared:  0.8082
F-statistic: 42.28 on 5 and 44 DF,  p-value: 1.011e-15
```

Modelo Escolhido

Apesar de não apresentar a maior explicação da variabilidade (R^2), o modelo mais razoável por ser simples (sem interações complexas de 2º ou 3º nível) com um bom valor de $R^2 = 0{,}8082$ seria `reg_nivel2_simp2`:

```
summary(reg_nivel2_simp2)
```

```
Call:
lm(formula = assassinato ~ populacao + congelamento + ensino_medio +
    expectativa + congelamento:ensino_medio, data = st)

Residuals:
    Min      1Q  Median      3Q     Max
-2.8632 -1.1720 -0.1792  1.0812  3.3888

Coefficients:
                           Estimate Std. Error t value Pr(>|t|)
(Intercept)               1.258e+02  1.522e+01   8.262 1.70e-10 ***
populacao                 2.220e-04  5.682e-05   3.907 0.000318 ***
congelamento             -1.912e-01  4.362e-02  -4.383 7.18e-05 ***
ensino_medio             -2.760e-01  8.653e-02  -3.190 0.002624 **
expectativa              -1.439e+00  2.554e-01  -5.634 1.16e-06 ***
congelamento:ensino_medio  3.037e-03  7.769e-04   3.909 0.000316 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.617 on 44 degrees of freedom
Multiple R-squared:  0.8277,    Adjusted R-squared:  0.8082
F-statistic: 42.28 on 5 and 44 DF,  p-value: 1.011e-15
```

```
print(reg_nivel2_simp2$coefficients)
```

```
             (Intercept)                populacao              congelamento
            1.257591e+02             2.219971e-04             -1.911918e-01
            ensino_medio               expectativa congelamento:ensino_medio
           -2.760216e-01             -1.439071e+00              3.036967e-03
```

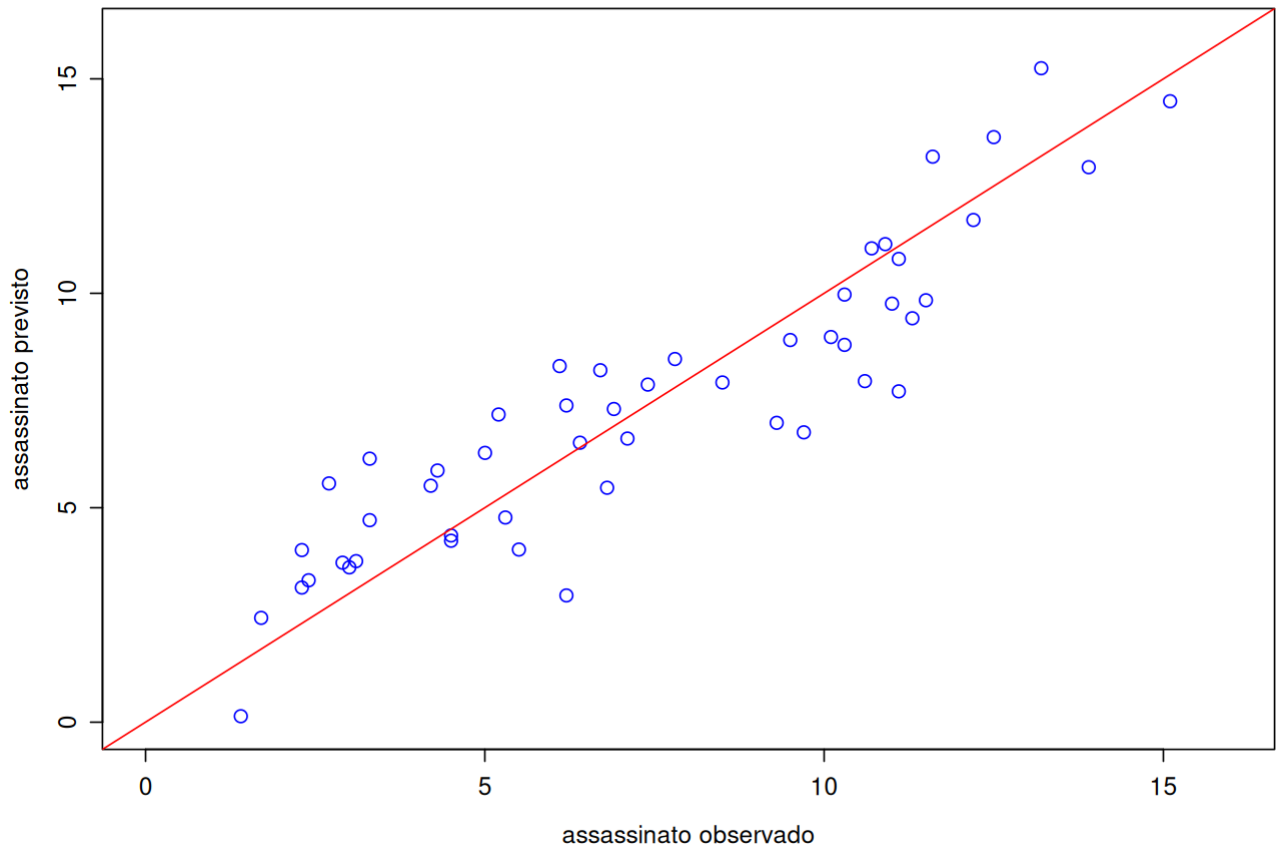
O modelo final:

$

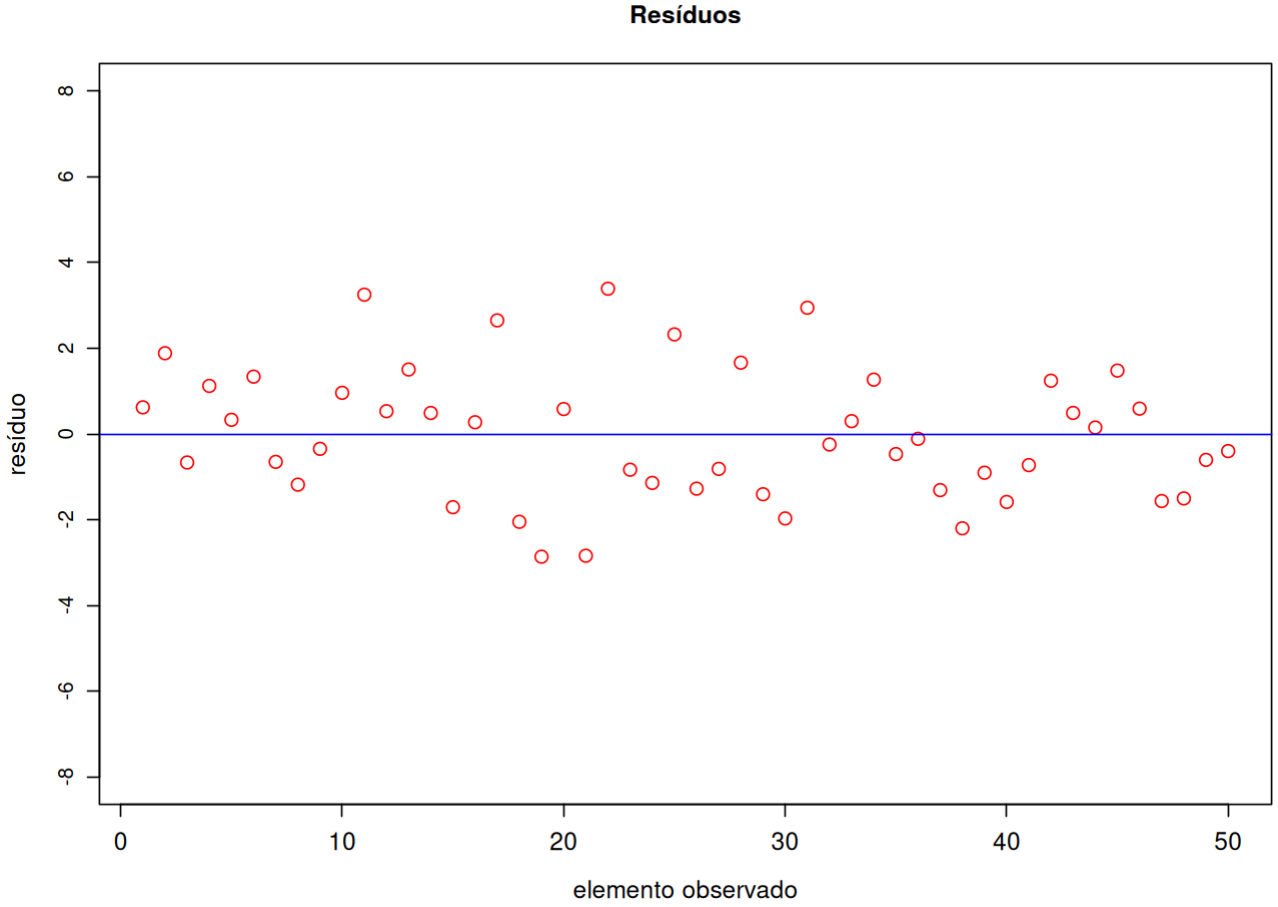
$$\begin{aligned}\text{assassinato} =& 125{,}759 + 2{,}21997 \cdot 10^{-4} \cdot \text{populacao} - 0{,}191191 \cdot \text{congelamento} - 0{,}276022 \cdot \text{ensino_medio} + \\ & - 1{,}43907 \cdot \text{expectativa} + 0{,}00303697 \cdot \text{congelamento} \cdot \text{ensino_medio}\end{aligned} \tag{1}$$

$

```
plot(st$assassinato, reg_nivel2_simp2$fitted.values, col=c("blue"),
     xlim=c(0,16), ylim=c(0, 16),
     xlab="assassinato observado", ylab="assassinato previsto",
     cex.lab=1.2, cex.axis=1.2, cex=1.3)
abline(a=0, b=1, col="red")
```




```
plot(reg_nivel2_simp2$residuals, col="red",
     cex.lab=1.2, cex.axis=1.2, cex=1.3,
     xlab="elemento observado", ylab="resíduo", main="Resíduos",
     ylim=c(-8,8), yaxt="n")
axis(2,at = seq(-8,8,2))
abline(h=0.0, col="blue")
```




```
aval <- cbind(data.frame("residuo"=reg_nivel2_simp2$residuals,"predito"=reg_nivel2_simp2$fitted.values),
              st[,c("assassinato","populacao","congelamento","ensino_medio","expectativa")])
aval[abs(aval$residuo) > 2.5, ]
```

A data.frame: 6 × 7

	residuo <dbl>	predito <dbl>	assassinato <dbl>	populacao <dbl>	congelamento <dbl>	ensino_medio <dbl>	expectativa <dbl>
Hawaii	3.249554	2.950446	6.2	868	0	61.9	73.60
Kentucky	2.650205	7.949795	10.6	3387	95	38.5	70.10
Maine	-2.863175	5.563175	2.7	1058	161	54.7	70.39
Massachusetts	-2.840562	6.140562	3.3	5814	103	58.5	71.83
Michigan	3.388788	7.711212	11.1	9111	125	52.8	70.63
New Mexico	2.944933	6.755067	9.7	1144	120	55.2	70.32

Vamos utilizar o modelo para estimar um valor de taxa de assassinato para um caso particular. Vamos utilizar como base os dados do estado de “New York”:

```
caso <- st['New York',]
vars <- c("assassinato","populacao","analfabetismo","renda",
          "congelamento","ensino_medio","expectativa")
caso[,vars]
```

A data.frame: 1 × 7

	assassinato <dbl>	populacao <dbl>	analfabetismo <dbl>	renda <dbl>	congelamento <dbl>	ensino_medio <dbl>	expectativa <dbl>
New York	10.9	18076	1.4	4903	82	52.7	70.55

Ajustando alguns valores das variáveis preditoras (*features*):

```
rownames(caso) <- "predição"
caso$analfabetismo <-   2.8         # dobrar a taxa de analfabetismo
caso$ensino_medio  <-  26.35        # diminuir o ensino médio pela metade
caso$expectativa   <-  69.55        # diminuir a expectativa de vida em um ano
```

Utilizando o modelo para predizer qual seria a taxa de assassinato para esse caso:

```
caso$assassinato   <- predict(reg_nivel2_simp2, caso)
caso[,vars]
```

A data.frame: 1 × 7

	assassinato <dbl>	populacao <dbl>	analfabetismo <dbl>	renda <dbl>	congelamento <dbl>	ensino_medio <dbl>	expectativa <dbl>
predição	13.29562	18076	2.8	4903	82	26.35	69.55

O valor predito, para essa situação hipotética, seria 13,3 assassinatos para cada 100000 habitantes, 2,4 a mais que o original (New York), se o analfabetismo dobrar (2,8), a taxa de concluintes do ensino médio for a metade (26,35) e a expectativa de vida for de um ano a menos (69,55).