Regressão Logística e Indicadores

IFSP - PEP

Cláudio M. Zaina

Regressão Logística. Conceitos e exemplo. Indicadores de qualidade do modelo.

Índice

Regressão Logística **1**
Introdução . . . 1
Dados . . . 2
Função Logística . . . 4
Regressão . . . 6

Indicadores de qualidade do modelo **10**
Matriz de confusão . . . 11
Acurácia . . . 12
Acurácia balanceada . . . 13
Sensitividade ou *Recall* (Taxa de Verdadeiro Positivo) . . . 13
Precisão . . . 14
Curva ROC . . . 14
Área sob a curva ROC . . . 15
Exercitando o comportamento da curva ROC e AUC: . . . 15

Modelagem **16**

Referências **22**

Regressão Logística

Introdução

As Regressões simples e múltiplas constroem um modelo que se esforça por explicar o comportamento de uma variável resposta (ou *target*), dependente, a partir de variáveis preditoras, independentes. Vimos como adequar as variáveis preditoras por meio de padronização ou variáveis fictícias a fim de agregar a maior quantidade de informação ao modelo. A resposta do modelo sempre era uma estimativa numérica: salário, taxa de assassinato, preço de imóvel. E se o resultado desejado do modelo for um valor binário, como sim/não, aceito/recusado, presente/ausente etc? Estamos falando então de uma situação de *classificação*, uma técnica de aprendizado de máquina na qual o processo identifica, a partir de um conjunto de variáveis preditoras ou *features* em qual categoria se enquadra uma determinada observação.
A Regressão Logística é a primeira técnica de classificação, na qual o conjunto dos valores das variáveis preditoras indica se a observação é da categoria de interesse do estudo (possui uma doença, será promovido, dará calote no empréstimo etc) ou não.

Dados

Vamos considerar, por exemplo, o conjunto de dados baseado (alguns valores foram alterados por motivos didáticos) em um *dataset* simples de propostas de empréstimo (Simple Loan Classification Dataset). Aqui temos os termos traduzidos (porém a `renda` foi mantida em US$):

```
rm(list=ls())
library(repr)
grafdim <- function (x=11, y=7) { options(repr.plot.width=x,repr.plot.height=y) }
grafdim()
load("emprestimo_simples.RData")
```

```
str(emp)
```

```
'data.frame':   61 obs. of  7 variables:
 $ emprestimo  : chr  "aprovado" "aprovado" "recusado" "aprovado" ...
 $ sexo        : Factor w/ 2 levels "feminino","masculino": 2 1 2 1 2 1 2 1 2 1 ...
 $ profissao   : Factor w/ 36 levels "Advogado","Agente Imobiliário",..: 16 28 19 22 9 15 1 5 34
 $ nivel_educ  : Ord.factor w/ 5 levels "Ensino Médio"<..: 3 4 1 3 3 2 5 3 4 5 ...
 $ estado_civil: Factor w/ 2 levels "casado","solteiro": 1 2 2 1 1 2 1 2 1 1 ...
 $ renda       : num  85000 62000 25000 105000 75000 48000 120000 38000 92000 180000 ...
 $ pont_credito: num  720 680 590 780 710 645 790 620 750 820 ...
```

As variáveis são:

- `emprestimo`: variável objetivo do estudo (*target*), indicando se o empréstimo foi *aprovado* ou *recusado*;
- `sexo`: sexo do proponente;
- `profissao`: profissão do proponente;
- `nivel_educ`: nível educacional (*Ensino Médio*, *Tecnólogo*, *Superior*, *Mestrado*, *Doutorado*);
- `estado_civil`: estado civíl, informando se o/a proponente é *casado* ou *solteiro*;
- `renda`: renda anual do/a proponente em US$;
- `pont_credito`: pontuação de crédito do/a proponente, no intervalo [300, 850].

```
summary(emp)
```

```
    emprestimo        sexo         profissao         nivel_educ   estado_civil
 Length   :61   feminino :30   Engenheiro: 5   Ensino Médio: 7   casado  :37
 N.unique : 2   masculino:31   Professor : 4   Tecnólogo   : 6   solteiro:24
 N.blank  : 0                  Vendedor  : 3   Superior    :23
 Min.nchar: 8                  Advogado  : 2   Mestrado    :15
 Max.nchar: 8                  Analista  : 2   Doutorado   :10
                               Arquiteto : 2
                               (Other)   :43
    renda          pont_credito
 Min.   : 25000   Min.   :560.0
 1st Qu.: 50000   1st Qu.:650.0
 Median : 78000   Median :720.0
 Mean   : 77656   Mean   :709.4
 3rd Qu.: 95000   3rd Qu.:770.0
 Max.   :180000   Max.   :830.0
```

```
table(emp$emprestimo)
```

```
aprovado recusado
      45       16
```

Este *dataset* é incomum no sentido de que há uma quantidade muito maior de observações **com** a propriedade de estudo (empréstimo *aprovado*) do que **sem** (empréstimo *recusado*). Normalmente a propriedade de estudo é mais rara, ocorrendo em uma proporção perigosamente menor que sua ausência. Quando a proporção de estudo fica abaixo de, digamos, 1/3 dos casos, métodos mitigantes (de correção) devem ser aplicados (super amostragem dos casos com característica de estudo presente, sub amostragem dos casos sem a característica de estudo etc). A falha no esforço de correção pode levar a um modelo especializado em identificar *a falta da característica*. No caso em estudo aqui, seria um modelo especializado em achar *aceite em empréstimo*.

Vamos ver alguns dados:

```
head(emp, 10)  # as 10 primeiras observações
```

A data.frame: 10 × 7

	emprestimo <chr>	sexo <fct>	profissao <fct>	nivel_educ <ord>	estado_civil <fct>	renda <dbl>	pont_cr <dbl>
1	aprovado	masculino	Engenheiro	Superior	casado	85000	720
2	aprovado	feminino	Professor	Mestrado	solteiro	62000	680
3	recusado	masculino	Estudante	Ensino Médio	solteiro	25000	590
4	aprovado	feminino	Gerente	Superior	casado	105000	780
5	aprovado	masculino	Contador	Superior	casado	75000	710
6	recusado	feminino	Enfermeiro	Tecnólogo	solteiro	48000	645
7	aprovado	masculino	Advogado	Doutorado	casado	120000	790
8	recusado	feminino	Artista	Superior	solteiro	38000	620
9	aprovado	masculino	TI	Mestrado	casado	92000	750
10	aprovado	feminino	Médico	Doutorado	casado	180000	820

O interesse é estimar se o `emprestimo` será aprovado ou recusado em função dos valores das demais variáveis. Vamos avaliar mais de perto o comportamento de `emprestimo`:

```
table(emp$sexo, emp$emprestimo)
```

```
           aprovado recusado
  feminino       19       11
  masculino      26        5
```

Aparentemente a proporção de empréstimos recusados é diferente em função do sexo: aproximadamente 1/3 para as mulheres enquanto, para os homens, foi a metade disso, apenas 1/6.
Observando o comportamento conjunto com `estado_civil`:

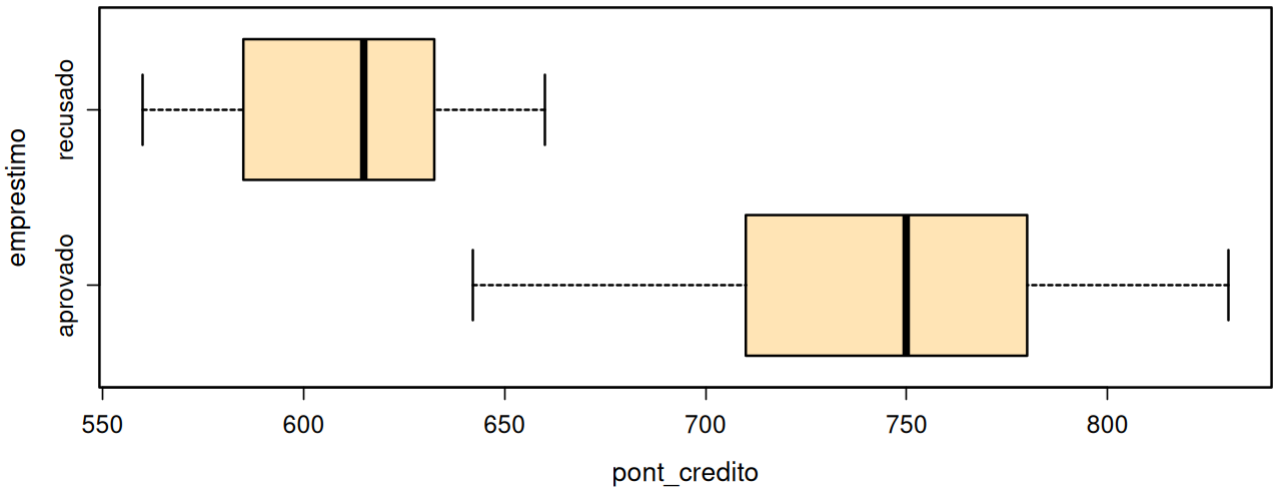
```
ftable(table(emp$estado_civil, emp$sexo, emp$emprestimo))
```

```
                    aprovado recusado
casado   feminino         14        0
         masculino        23        0
solteiro feminino          5       11
         masculino         3        5
```

Fica claro que não é o `sexo` a variável mais decisiva e sim `estado_civil`: apenas um proponente casado teve seu pedido de empréstimo recusado enquanto a quantidade de recusas foi aproximadamente o triplo para cada sexo dos proponentes solteiros.

Vamos analisar o comportamento de `emprestimo` com relação à `pont_credito`:

```
grafdim(11,5)
par(cex.lab=1.3, cex.axis=1.2, lwd=1.5)
boxplot(emp$pont_credito ~ emp$emprestimo, horizontal=TRUE, col="moccasin",
       xlab="pont_credito", ylab="emprestimo")
```



Novamente, está claro que a alta pontuação no crédito é relevante para a obtenção do empréstimo.

Função Logística

Uma técnica seria reduzir a variável objetivo a 0 (objeto de estudo *ausente*, *recusado* no caso de empréstimo) e 1 (objeto de estudo *presente*, *aprovado* no caso do empréstimo) pois faz sentido matematicamente (0 como *não há* ou *tem zero ocorrência* e 1 como *existe um*).

Vamos converter então `emprestimo` para operarmos matematicamente:

```
emp$emprestimo <- ifelse(emp$emprestimo == 'aprovado', 1, 0)
summary(emp$emprestimo)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 0.0000  0.0000  1.0000  0.7377  1.0000  1.0000
```

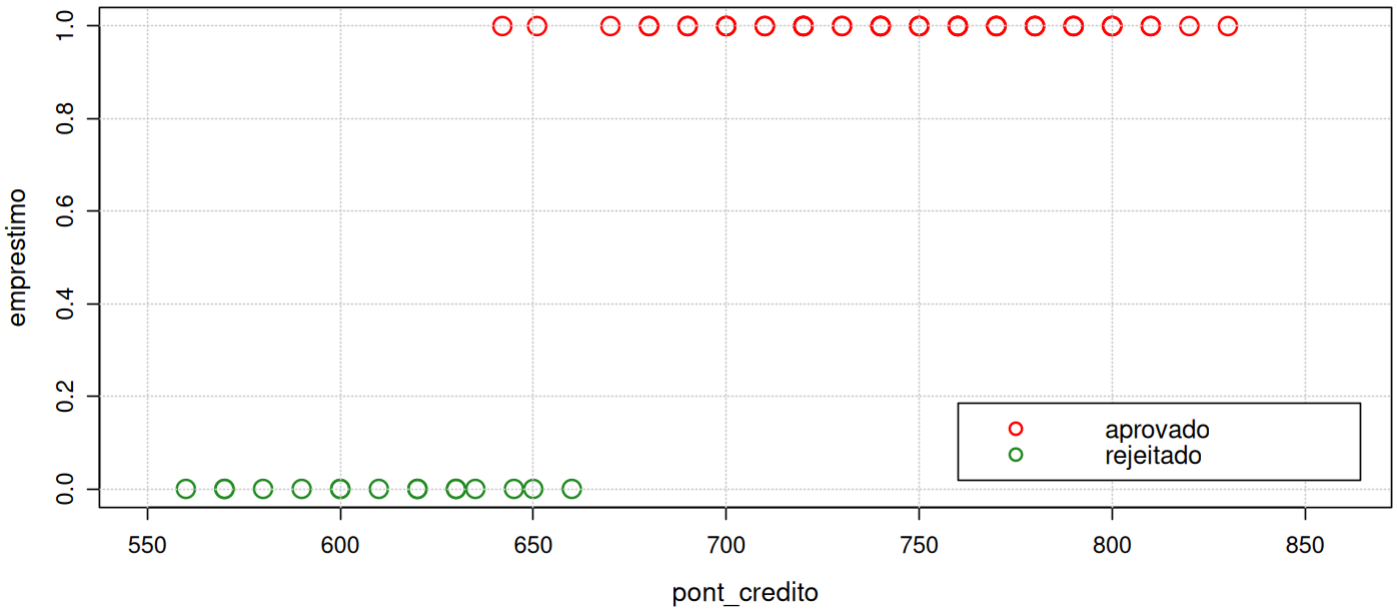
```
table(emp$emprestimo)
```

```
 0  1
16 45
```

Vamos observar o comportamento de `emprestimo` quanto a `pont_credito`:

```
grafdim(12,6)
xl <- c(550, 860)
yl <- c(0, 1)
cor <- ifelse(emp$emprestimo==1,"red","forestgreen")
plot(emp$pont_credito, emp$emprestimo, col=cor, xlim=xl, ylim=yl,
     cex.lab=1.3, cex.axis=1.15, lwd=1.5, cex=1.9,
     xlab="pont_credito", ylab="emprestimo")
```

```
grid(nx=NULL, ny=NULL, col="grey80")
legend(760, 0.186, legend=c("aprovado","rejeitado"), col=c("red","forestgreen"),
       lwd=1.5, cex=1.25, pch=1, lty=NA)
```



É fácil observar que os pedidos rejeitados se concentram em baixa pontuação de crédito, enquanto os aceitos estão em alta pontuação.

Seria interessante então predizer qual a probabilidade de um determinado valor de `pont_credito` ter o pedido de empréstimo *aceito*.

A função Logística:

$$g(x) = \frac{1}{1 + e^{-x}}$$

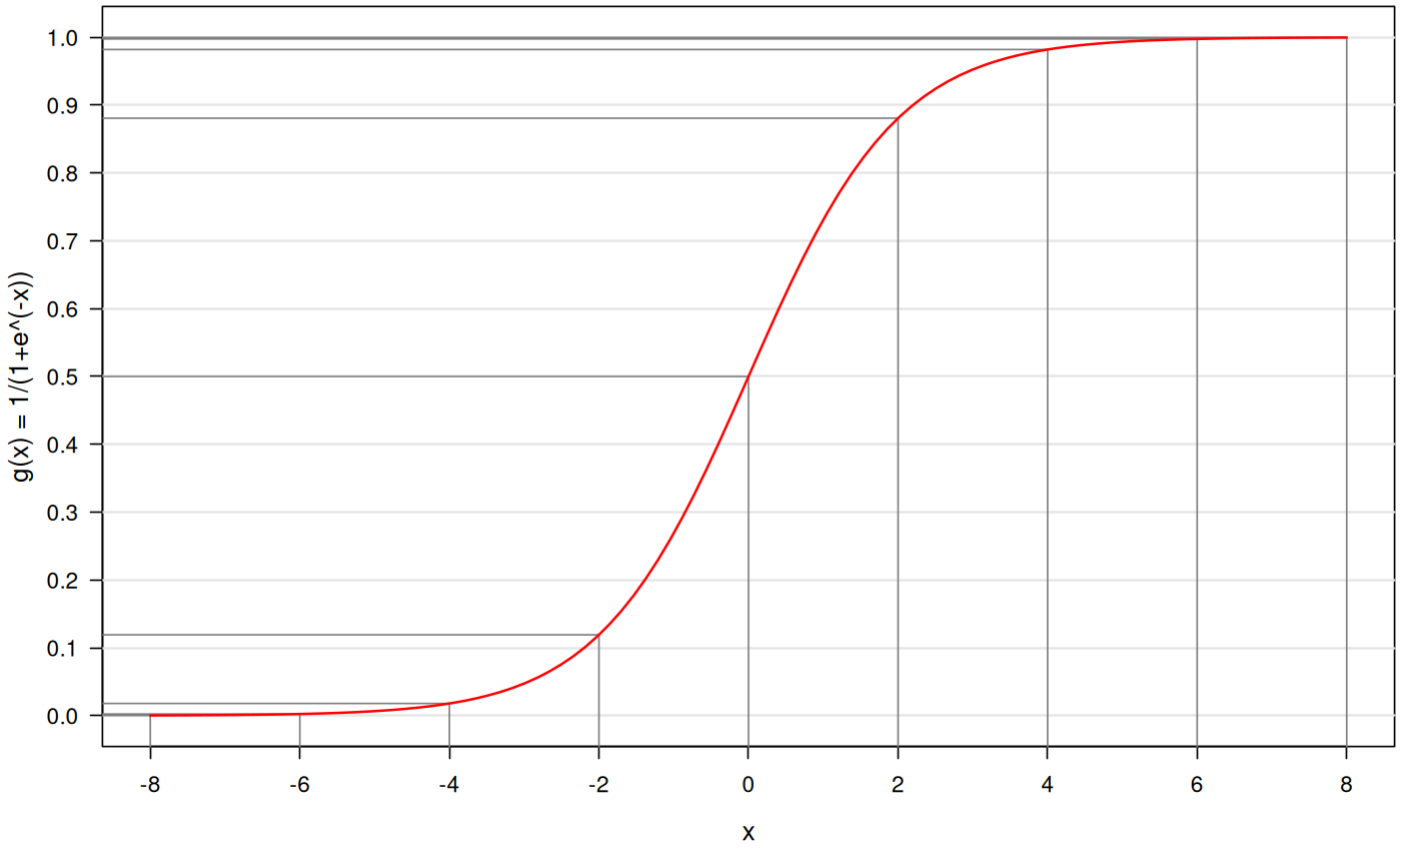
cumpre o papel de reduzir um valor de uma variável preditora a um valor de probabilidade pois ela tem o domínio em $[-\infty, \infty]$ com uma imagem em [0, 1] ou seja, para um valor $-\infty < x < \infty$, $0 \leq g(x) \leq 1$. Isso permite que estudemos qualquer conjunto de variáveis no intervalo $-\infty <$ (composição de variáveis)$< \infty$ obtendo um resultado entre 0 (considerado como certeza de *objeto de estudo ausente* - probabilidade de empréstimo = 0) e 1 (*objeto de estudo presente* - probabilidade de empréstimo = 1).

Convém reparar que o valor 1, indicando *objeto de estudo* ***presente*** nem sempre é um resultado *bom* ou *positivo*. Se o objeto de estudo é "paciente tem câncer", 0 significa *saudável* e 1, *tem câncer*.

```
logistica <- function (x) { 1 / (1 + exp(-x)) }
```

```
grafdim(12,8)
xinf <- -8
xsup <-  8
ys <- seq(0,1,by=0.1)
yl <- c(-0.005, 1.005)
x <- seq(xinf, xsup, length=100)
y <- logistica(x)
xp <- seq(xinf,xsup, by=2)
yp <- logistica(xp)
plot(x, y, pch=NA, ylab="g(x) = 1/(1+e^(-x))",yaxt="n", xaxt="n", ylim=yl,
```

```
     lwd=1.5, cex.axis=1.3, cex.lab=1.3)
axis(2, at=ys, las=1, cex.axis=1.1)
axis(1, at=xp, las=1, cex.axis=1.1)
abline(h=ys, col="grey90", lwd=1.4)
for (i in 1:(length(xp))) {
    lines(c(xp[i],xp[i],(xinf-2)),c(-1,yp[i],yp[i]), col="grey50")
}
lines(x, y, col="red", lwd=1.5)
```



Podemos observar que, pela função utilizada, qualquer valor de $x < 6$ vai retornar 0 e qualquer valor $x > 6$ vai retornar 1

Regressão

Há diversos critérios que as variáveis devem cumprir para a técnica da Regressão Logística poder ser aplicada. Esses critérios podem ser estudados em: *The 6 Assumptions of Logistic Regression*.

Vamos construir um modelo simples utilizando Regressão Logística que avalia se o empréstimo será concedido apenas em função da pontuação do crédito.

```
modlog <- glm(emprestimo ~ pont_credito, data=emp, family="binomial")
summary(modlog)
```

```
Call:
glm(formula = emprestimo ~ pont_credito, family = "binomial",
    data = emp)
```

```
Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept)  -79.3401    35.7382  -2.220   0.0264 *
pont_credito   0.1214     0.0549   2.212   0.0270 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 70.2041  on 60  degrees of freedom
Residual deviance:  9.8871  on 59  degrees of freedom
AIC: 13.887

Number of Fisher Scoring iterations: 9
```

A regressão estimou os parâmetros e podemos agora costruir uma equação que, segundo o modelo, estima a probabilidade de que um pedido de empréstimo seja *aceito* em função da `pont_credito`:

$$g(x) = \frac{e^{-79{,}34+0{,}1214\times \text{pont_credito}}}{1+e^{-79{,}34+0{,}1214\times \text{pont_credito}}}$$

Agora é possível avaliar, segundo o modelo, quais observações teriam seus pedidos de empréstimo *aceito* ou *recusado* em função da sua pontuação de crédito (`pont_credito`).
Vamos ver a probabilidade de serem preditos como 0 (*recusado*) ou 1 (*aceito*) segundo o modelo:

```r
predito <- predict(modlog, type="response")
```

```r
comparacao <- data.frame(observado=emp$emprestimo,
                         pont_credito=emp$pont_credito,
                         predito=round(predito, 3))
comparacao <- comparacao[order(comparacao$pont_credito),]
print(comparacao[comparacao$predito > 0 & comparacao$predito < 1,])
```

```
   observado pont_credito predito
31         0          600   0.002
50         0          600   0.002
13         0          610   0.005
8          0          620   0.017
40         0          620   0.017
24         0          630   0.055
55         0          630   0.055
52         0          635   0.097
42         1          642   0.200
6          0          645   0.265
16         0          650   0.398
60         1          651   0.428
44         0          660   0.690
29         1          670   0.882
2          1          680   0.962
47         1          680   0.962
12         1          690   0.988
25         1          690   0.988
19         1          700   0.997
27         1          700   0.997
61         1          700   0.997
```

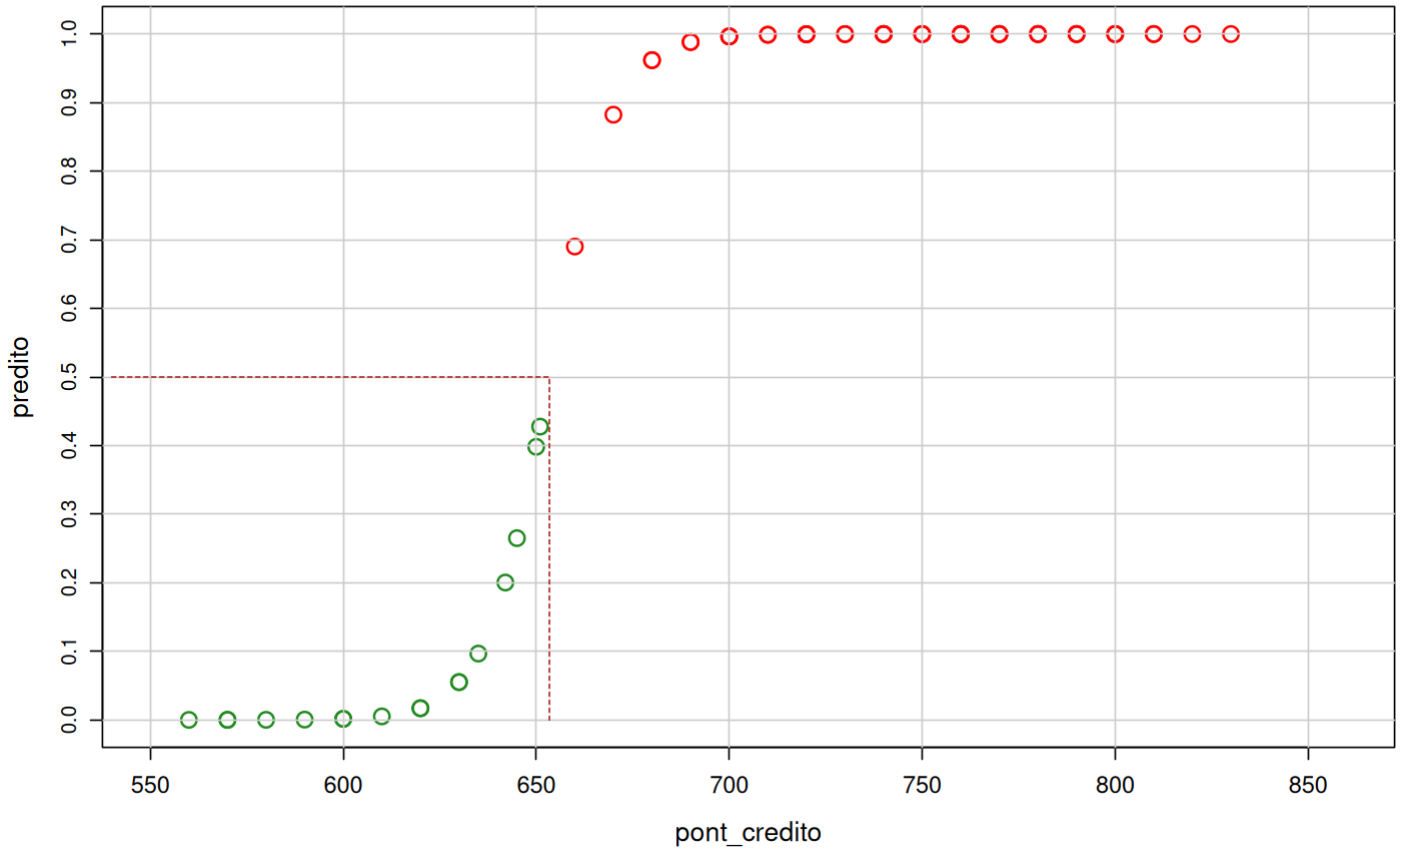
```
5           1           710   0.999
26          1           710   0.999
```

```
# ajustando valores para uniformizar a apresentação dos gráficos
grafdim(12,8)
xl <- c(550, 860)
yl <- c(0, 1)
xp <- seq(0, 1, by=0.1)
yp <- seq(550, 850, by=50)
```

```
predict(modlog, data.frame(pont_credito=c(653.41)), type="response")
x05 <- 653.41
```

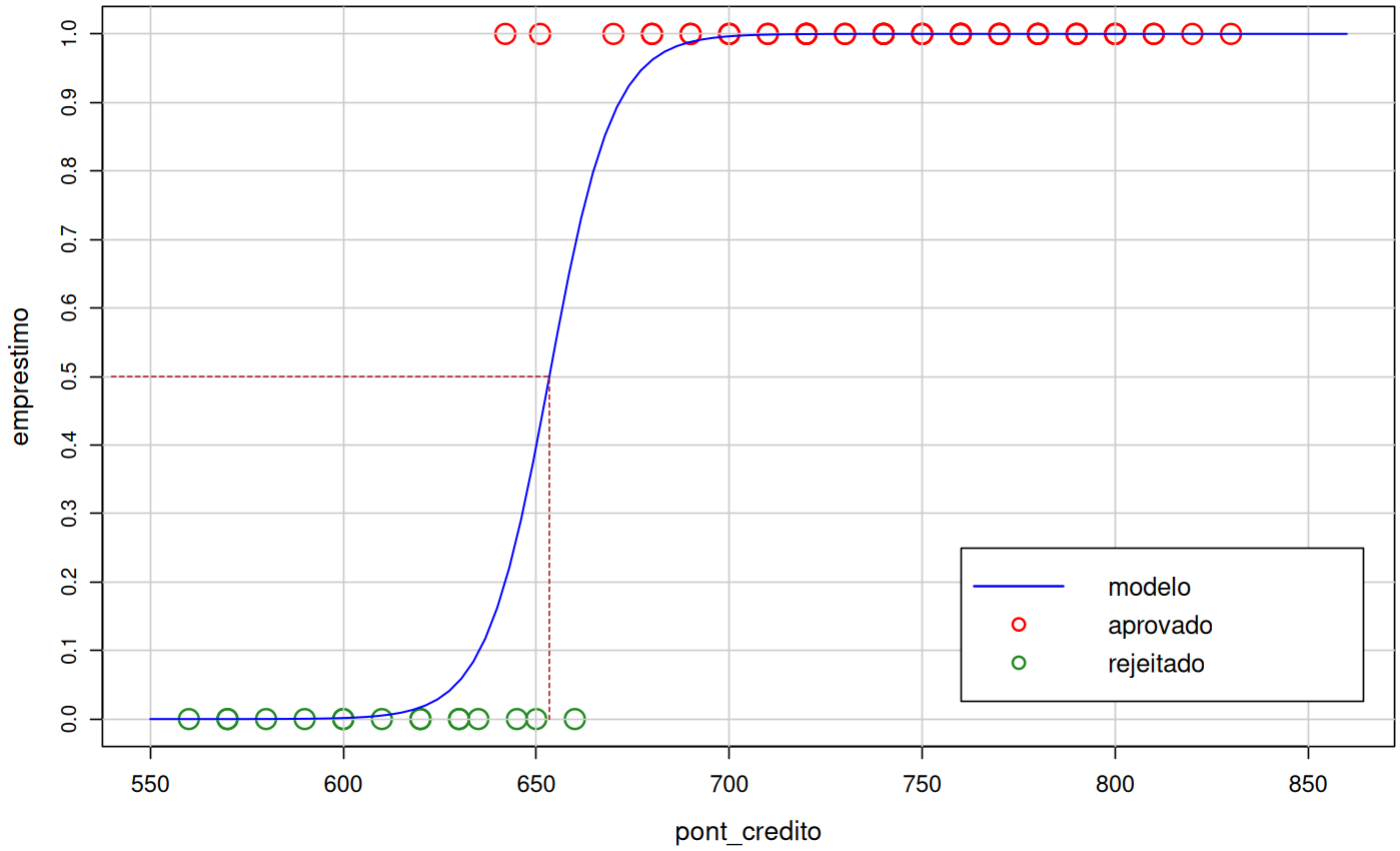
1: 0.500228448744673

```
cor <- ifelse(predito < 0.5, 'forestgreen', 'red')
plot(emp$pont_credito, predito, xlim=xl, ylim=yl, col=cor,
     cex.lab=1.3, cex.axis=1.15, yaxt='n', lwd=1.5, cex=1.6,
    xlab="pont_credito")
axis(side=2, at=xp)
abline(h=xp, v=yp, col="grey80")
lines(c(540,x05,x05),c(0.5,0.5,0), lty=2, col="firebrick", lwd=1.)
```




```
cor <- ifelse(emp$emprestimo==1,"red","forestgreen")
plot(emp$pont_credito, emp$emprestimo, col=cor, xlim=xl, ylim=yl,
     cex.lab=1.3, cex.axis=1.15, lwd=1.5, cex=2.1,
     yaxt='n', xlab="pont_credito", ylab="emprestimo")
```

```
axis(side=2, at=xp)
abline(h=xp, v=yp, col="grey80")
par(new=TRUE)
curve(predict(modlog, data.frame(pont_credito=x), type="response"), add=TRUE,
     col="blue", lwd=1.2)
lines(c(540,x05,x05),c(0.5,0.5,0), lty=2, col="firebrick", lwd=1.)
legend(760, 0.25, legend=c("modelo","aprovado","rejeitado"),
       col=c("blue","red","forestgreen"),
       lwd=1.5, cex=1.25, pch=c(NA, 1, 1), lty=c(1,NA,NA))
```

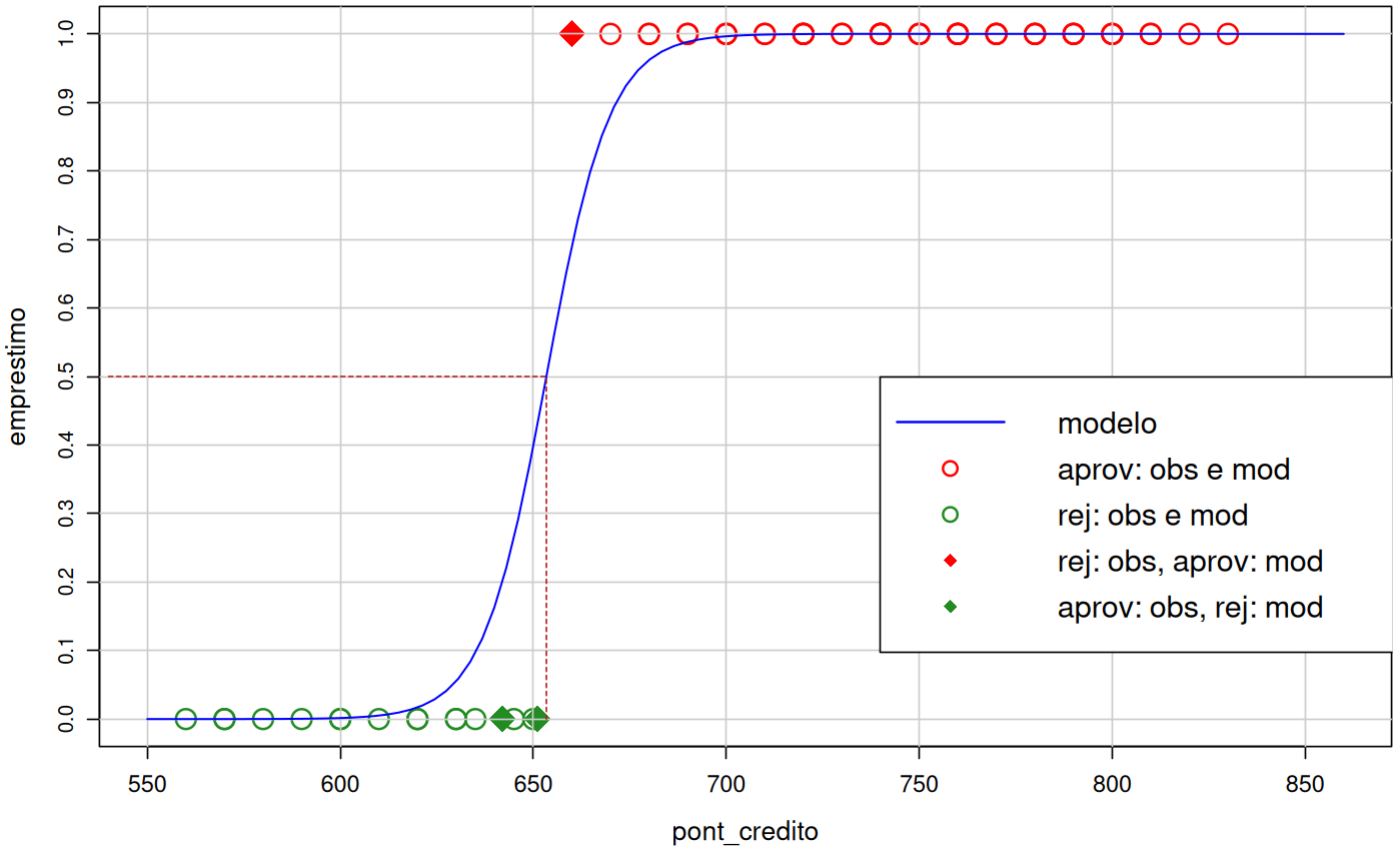


O raciocínio seria considerar todas as observações com um valor previsto de probabilidade menor que um dado valor (normalmente 50%, ou 0,5) como sendo do tipo *sem o critério de estudo* (no nosso caso, empréstimo *recusado*) e as observações com probabilidade maior ou igual ao limiar ou valor-limite (*threshold*) como *tendo o critério* (no nosso caso, empréstimo *aprovado*).

```
predito_prob <- predito
predito <- ifelse(predito > 0.5, 1, 0)
```

```
grafdim(12,8)
tipo <- ifelse(predito == emp$emprestimo, 1, 18)
tam  <- ifelse(predito == emp$emprestimo, 2.1, 3)
# cor_predito<- ifelse(predito==1,"red","forestgreen")
cor <- ifelse(predito == 1,"red","forestgreen")
plot(emp$pont_credito, predito, col=cor, xlim=xl, ylim=yl, pch=tipo,
     cex.lab=1.3, cex.axis=1.15, lwd=1.5, cex=tam,
     yaxt='n', xlab="pont_credito", ylab="emprestimo")
axis(side=2, at=xp)
abline(h=xp, v=yp, col="grey80")
```

```r
par(new=TRUE)
curve(predict(modlog, data.frame(pont_credito=x), type="response"), add=TRUE,
     col="blue", lwd=1.2)
par(new=TRUE)
lines(c(540,x05,x05),c(0.5,0.5,0), lty=2, col="firebrick", lwd=1)
legend(740, 0.5, legend=c("modelo","aprov: obs e mod", "rej: obs e mod",
                          "rej: obs, aprov: mod","aprov: obs, rej: mod"),
       col=c("blue","red","forestgreen","red","forestgreen"),
       lwd=1.5, cex=1.5, pch=c(NA, 1, 1, 18, 18), lty=c(1,NA,NA,NA,NA))
```



Podemos observar que três observações foram incorretamente avaliadas: uma observação cujo pedido de empréstimo *recusado* foi identificado como *aprovado* pelo modelo. É uma observação considerada *possuindo a propriedade em estudo* (*aprovada*, no caso) mas que, na verdade, não a possui (o empréstimo foi *recusado*). Essa ocorrência é o "positivo do empréstimo é falso" é chamada de **falso positivo**.
Aqueles dois casos julgados como não tendo a característica em estudo quando tinham, ou seja, o modelo considerou o empréstimo *rejeitado* quando na verdade foi *aceito* são casos em que a negativa (da presença da propriedade em estudo - empréstimo) é falsa; o modelo afirmar que observações tenham a propriedade em estudo quando na verdade elas têm é um erro de **falso negativo**.

Indicadores de qualidade do modelo

As regressões simples e múltipla possibilitavam que se estimasse a qualidade do modelo a partir da "distância" entre o valor real e o valor predito pelo modelo. Na regressão logística, o conjunto dessas distâncias não faz sentido, uma vez que a "distância" entre estar correto e errado é sempre 1. Faria sentido, porém, considerar a proporção de vezes que o modelo acertou (ou errou) com relação à quantidade de casos que ele avaliou. O modo mais básico de avaliação é a **matriz de confusão**.

Matriz de confusão

A matriz de confusão é construída de modo a exibir as quatro situações encontradas na avaliação do modelo:

- Os casos que não tem a característica de estudo e o modelo identificou que aqueles casos não tem. São os casos em que os negativos foram avaliados como negativos. Chamamos esta situação de **verdadeiro negativo** ou ***true negative***;
- Os casos que tem a característica e o modelo os qualifica como tendo, é o caso de **verdadeiro positivo** ou ***true positive***;
- Os casos que não tem a característica mas o modelo avaliou que tem, são positivos incorretos ou **falsos positivos** (***false positive***);
- Os casos que tem a característica (empréstimo, câncer, diabete, cometeu fraude etc) mas o modelo disse que *não têm*; são **falsos negativos** (***false negative***).

A matriz de confusão é construída da seguinte forma:

		Observado	
		ausente 0	presente 1
Predito	ausente 0	**TN** ou **N – negativo** ou verdadeiro negativo (*true negative*)	FN – falso negativo (*false negative*)
	presente 1	FP – falso positivo (*false positive*)	**TP** ou **P – positivo** ou verdadeiro positivo (*true positive*)

Convém ficar atento para a posição das colunas da tabela pois é comum encontrá-la também transposta (com dados Preditos nas colunas).

Para o nosso exemplo:

```
library(caret)
matriz_confusao <- confusionMatrix(data=as.factor(predito),
                                   reference=as.factor(emp$emprestimo),
                                   positive="1")
```

```
print(matriz_confusao)
```

```
Confusion Matrix and Statistics

          Reference
Prediction  0  1
         0 15  2
         1  1 43

               Accuracy : 0.9508
                 95% CI : (0.8629, 0.9897)
    No Information Rate : 0.7377
    P-Value [Acc > NIR] : 1.633e-05

                  Kappa : 0.8754

 Mcnemar's Test P-Value : 1

            Sensitivity : 0.9556
            Specificity : 0.9375
```

```
         Pos Pred Value : 0.9773
         Neg Pred Value : 0.8824
             Prevalence : 0.7377
         Detection Rate : 0.7049
   Detection Prevalence : 0.7213
      Balanced Accuracy : 0.9465

       'Positive' Class : 1
```

Temos então:

Modelo `emprestimo`		**Observado**	
		0	**1**
Predito	**0**	15	2
	1	1	43

Como construir um número que sintetize a qualidade da regressão logística como utilizávamos o R^2 em regressão múltipla?

Acurácia

A acurácia é a proporção de "corretos", ou seja:

$$\text{acurácia} = Acc = \frac{N + P}{N + P + FN + FP}$$

No nosso exemplo:

$$Acc = \frac{15 + 43}{15 + 43 + 1 + 2} = \frac{58}{61} = 0{,}9508$$

Uma acurácia de 0,95 é um bom resultado: significa 95% de predições corretas. Há porém um problema com a acurácia: ela é insensível à qualidade de classificação de uma categoria em particular.
Vejamos um outro caso, com um modelo *ruim*. As mesmas 61 observações, mas o modelo afirmou que 60 delas são negativas, ou seja, exceto uma, todas as demais não têm a propriedade:

Modelo *ruim*		**Observado**	
		0	**1**
Predito	**0**	53	7
	1	0	1

$$Acc = \frac{53 + 1}{53 + 1 + 7 + 0} = \frac{54}{61} = 0{,}8852$$

Neste caso, mesmo que o modelo tenha errado quase todos casos da categoria 1 (errou 7 em 8), ainda temos uma acurácia de 89%.

Acurácia balanceada

A acurácia balanceada é composta por uma média das acurácias na identificação de casos positivos e negativos.

A Taxa de Positivos (T_P) ou *True Positive Rate* (TPR) é

$$T_P = \frac{P}{P + FN}$$

e a Taxa de Negativos (T_N) ou *True Negative Rate* (TNR) é

$$T_N = \frac{N}{N + FP}$$

A Acurácia Balanceada (Acc_B) então é

$$Acc_B = \frac{T_P + T_N}{2}$$

No exemplo do modelo para empréstimo:

$$T_P = \frac{P}{P + FN} = \frac{43}{43 + 2} = 0{,}9555 \qquad T_N = \frac{N}{N + FP} = \frac{15}{15 + 1} = 0{,}9375$$

A Acurácia Balanceada então é

$$Acc_B = \frac{(43/45) + (15/16)}{2} = \frac{0{,}9555 + 0{,}9375}{2} = 0{,}9465$$

No caso em que a acurácia teve um desempenho pobre como indicador (não refletiu bem a situação de um modelo *ruim*):

$$T_P = \frac{P}{P + FN} = \frac{1}{1 + 7} = 0{,}125 \qquad T_N = \frac{N}{N + FP} = \frac{53}{53 + 0} = 1$$

A Acurácia Balanceada então é

$$Acc_{B\,ruim} = \frac{(1/8) + 1}{2} = \frac{0{,}125 + 1}{2} = 0{,}5625$$

Convenhamos que um valor de 0,5625 é muito mais razoável que 0,8852 para aquela situação,uma vez que o modelo foi eficiente apenas para metade dos casos.

Portanto sempre é utilizada a Acurácia balanceada para avaliar desempenho de modelo de classificação.

Sensitividade ou *Recall* (Taxa de Verdadeiro Positivo)

A Taxa de Verdadeiro Positivo (TPR - *True Positive Rate*) é a proporção daqueles **corretamente** classificados como positivos, ou seja, qual a porcentagem de positivos corretamente recuperados (*recall*). É 1 quanto nenhum caso foi classificado como falso negativo; é 0 quando nenhum dos casos verdadeiros positivos foi recuperado.

$$recall = \frac{P}{P + FN}$$

O *recall* do modelo de concessão de empréstimo:

$$recall = \frac{43}{43 + 2} = \frac{43}{45} = 0{,}9556$$

No caso do modelo ruim:

$$recall = \frac{1}{1 + 7} = \frac{1}{8} = 0{,}125$$

Precisão

A Precisão avalia a proporção de predições corretas para o critério de interesse do estudo, a classe positiva; quantos casos *se acertou no alvo* ao dizer que são positivos:

$$\text{precisão} = prec = \frac{P}{P + FP}$$

No nosso exemplo de concessão de empréstimo:

$$prec = \frac{43}{43 + 1} = \frac{43}{44} = 0{,}9772$$

No caso do modelo ruim:

$$prec_{ruim} = \frac{1}{1 + 0} = \frac{1}{1} = 1$$

O modelo ruim não classificou casos negativos como positivos, sua precisão foi de 100%. Todos os casos identificados como positivos *de fato eram positivos*!

Curva ROC

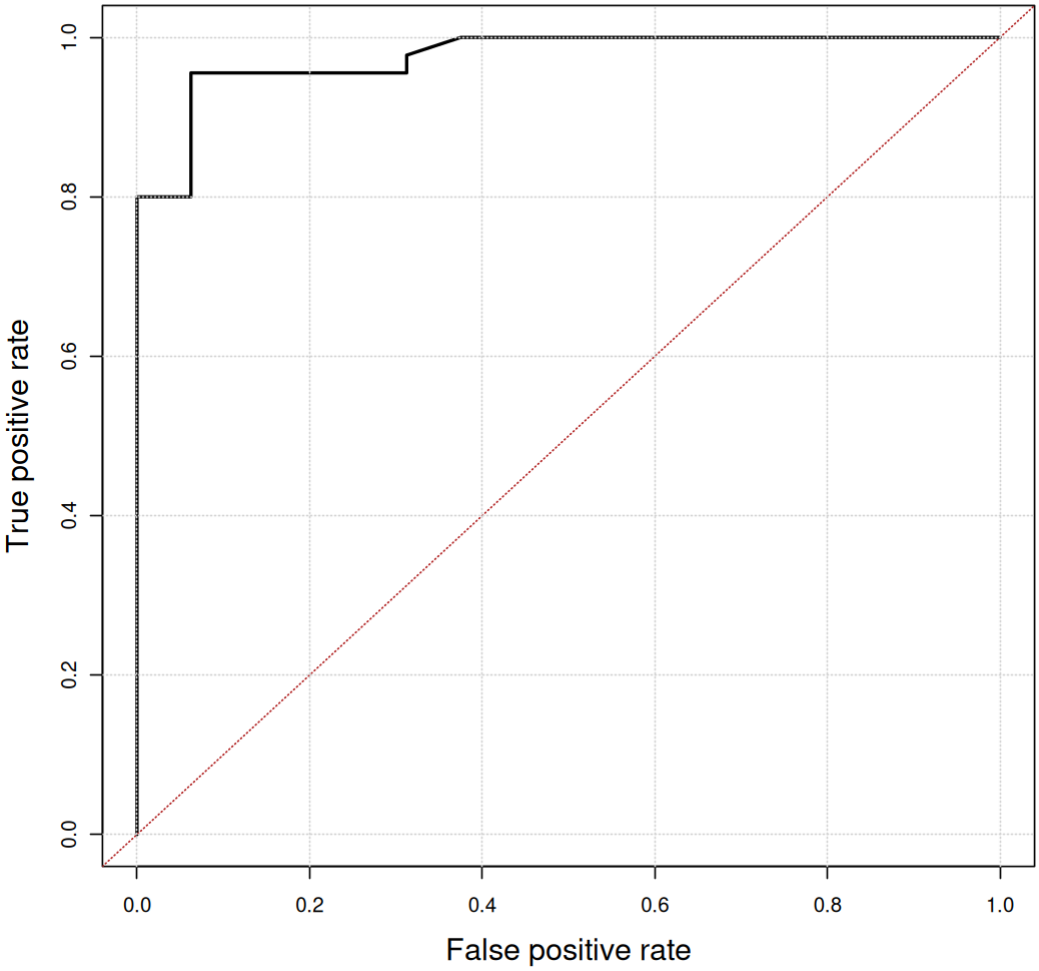
A curva ROC (*Receiver Operating Characteristic* ou Curva Característica de Operação do Receptor) é uma das ferramentas mais utilizadas na avaliação da qualidade do modelo. O diagrama com a curva ROC representa a relação entre o taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos.
É construída ordenando os dados pelo critério do qual se quer estudar a curva característica

```
library(ROCR)
```

```
predict <- prediction(predito_prob, emp$emprestimo)
```

```
roc_modelo <- performance(predict, measure="tpr", x.measure="fpr")
```

```
grafdim(9,9)
plot(roc_modelo, cex.lab=1.5, lwd=2)
abline(a=0, b=1, col="firebrick", lty=3)
grid(nx=NULL)
```



Área sob a curva ROC

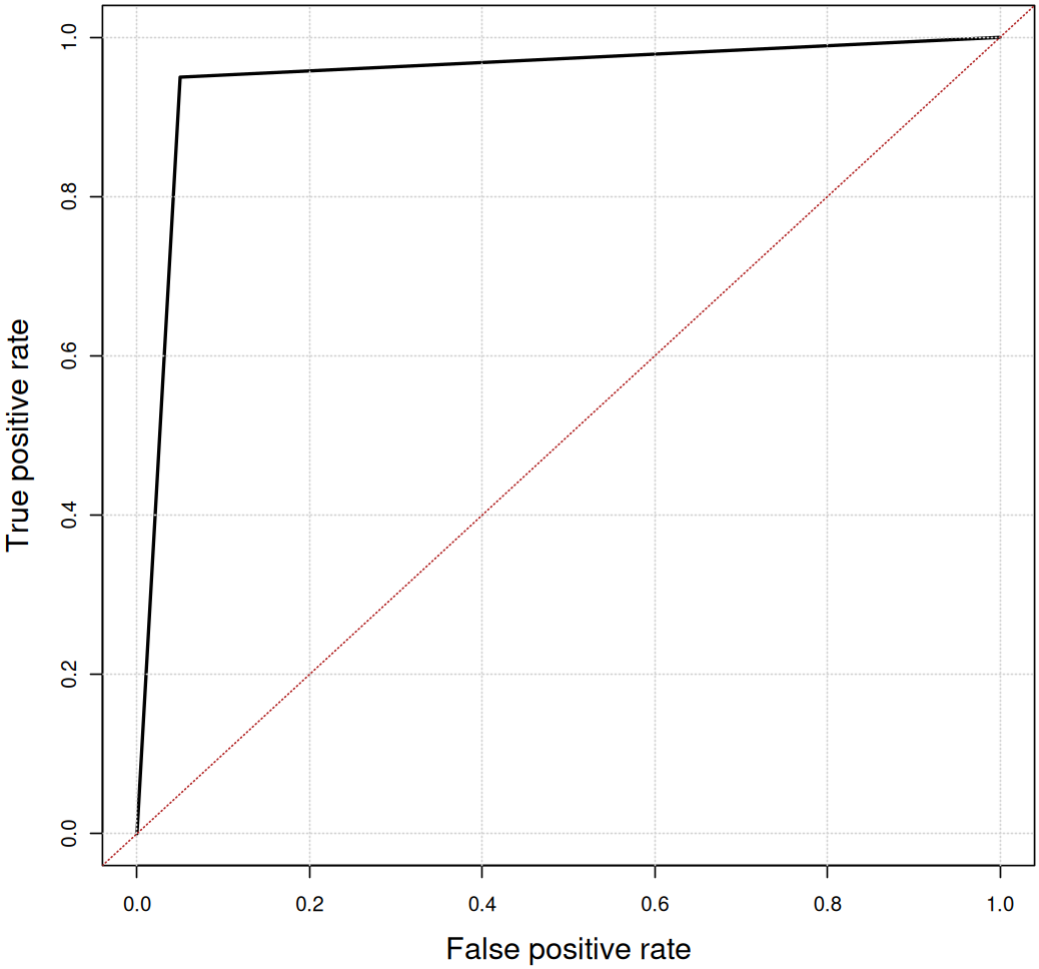
```
auc_perf   <- performance(predict, "auc")
auc_modelo <- auc_perf@y.values[[1]]
cat("Área sob a curva ROC:",auc_modelo)
```

```
Área sob a curva ROC: 0.9944444
```

Exercitando o comportamento da curva ROC e AUC:

```
obs <- c(0,0,0,0,0, 0,0,0,0,0, 0,0,0,0,0, 0,0,0,0,0, 1,1,1,1,1, 1,1,1,1,1, 1,1,1,1,1, 1,1,1,1,1)
mod <- c(0,0,0,0,0, 0,0,0,0,0, 0,0,0,0,0, 0,0,0,0,1, 0,1,1,1,1, 1,1,1,1,1, 1,1,1,1,1, 1,1,1,1,1)
# mod <- rep(c(0,1),20) # puramente aleatório (na verdade, 0,1,0,1, ... )
pre <- prediction(mod,obs)
roc <- performance(pre, measure="tpr", x.measure="fpr")
grafdim(9,9)
plot(roc, cex.lab=1.5, lwd=2)
grid(nx=NULL)
abline(a=0, b=1, col="firebrick", lty=3)
prf <- performance(pre, "auc")
auc <- prf@y.values[[1]]
cat("Área sob a curva ROC:",auc)
```

```
Área sob a curva ROC: 0.95
```



Modelagem

```
str(emp)
```

```
'data.frame':   61 obs. of  7 variables:
 $ emprestimo  : num  1 1 0 1 1 0 1 0 1 1 ...
 $ sexo        : Factor w/ 2 levels "feminino","masculino": 2 1 2 1 2 1 2 1 2 1 ...
 $ profissao   : Factor w/ 36 levels "Advogado","Agente Imobiliário",..: 16 28 19 22 9 15 1 5 34
 $ nivel_educ  : Ord.factor w/ 5 levels "Ensino Médio"<..: 3 4 1 3 3 2 5 3 4 5 ...
 $ estado_civil: Factor w/ 2 levels "casado","solteiro": 1 2 2 1 1 2 1 2 1 1 ...
 $ renda       : num  85000 62000 25000 105000 75000 48000 120000 38000 92000 180000 ...
 $ pont_credito: num  720 680 590 780 710 645 790 620 750 820 ...
```

Ajustando as variáveis (*features*) discretas para *One Hot*:

```
# emp <- emp_orig
```

```
emp_orig <- emp
```

```r
print(summary(emp$nivel_educ))
```

```
Ensino Médio    Tecnólogo     Superior     Mestrado    Doutorado
           7            6           23           15           10
```

```r
emp$sexo_f    <- as.numeric(emp$sexo == "feminino")
emp$casado    <- as.numeric(emp$estado_civil == "casado")
emp$educ_tecn <- as.numeric(emp$nivel_educ == "Tecnólogo")
emp$educ_supr <- as.numeric(emp$nivel_educ == "Superior")
emp$educ_mest <- as.numeric(emp$nivel_educ == "Mestrado")
emp$educ_dout <- as.numeric(emp$nivel_educ == "Doutorado")
```

```r
emp$sexo <- NULL
emp$estado_civil <- NULL
emp$profissao <- NULL
emp$nivel_educ <- NULL
```

```r
str(emp)
```

```
'data.frame':   61 obs. of  9 variables:
 $ emprestimo  : num  1 1 0 1 1 0 1 0 1 1 ...
 $ renda       : num  85000 62000 25000 105000 75000 48000 120000 38000 92000 180000 ...
 $ pont_credito: num  720 680 590 780 710 645 790 620 750 820 ...
 $ sexo_f      : num  0 1 0 1 0 1 0 1 0 1 ...
 $ casado      : num  1 0 0 1 1 0 1 0 1 1 ...
 $ educ_tecn   : num  0 0 0 0 0 1 0 0 0 0 ...
 $ educ_supr   : num  1 0 0 1 1 0 0 1 0 0 ...
 $ educ_mest   : num  0 1 0 0 0 0 0 0 1 0 ...
 $ educ_dout   : num  0 0 0 0 0 0 1 0 0 1 ...
```

```r
renda_med  <- mean(emp$renda)
renda_desv <- sd(emp$renda)
emp$renda  <- (emp$renda - renda_med) / renda_desv
```

```r
pont_med   <- mean(emp$pont_credito)
pont_desv  <- sd(emp$pont_credito)
emp$pont_credito <- (emp$pont_credito - pont_med) / pont_desv
```

```r
summary(emp)
```

```
   emprestimo         renda           pont_credito         sexo_f
 Min.   :0.0000   Min.   :-1.57678   Min.   :-2.0462   Min.   :0.0000
 1st Qu.:0.0000   1st Qu.:-0.82815   1st Qu.:-0.8135   1st Qu.:0.0000
 Median :1.0000   Median : 0.01031   Median : 0.1453   Median :0.0000
 Mean   :0.7377   Mean   : 0.00000   Mean   : 0.0000   Mean   :0.4918
 3rd Qu.:1.0000   3rd Qu.: 0.51937   3rd Qu.: 0.8301   3rd Qu.:1.0000
 Max.   :1.0000   Max.   : 3.06470   Max.   : 1.6519   Max.   :1.0000
     casado         educ_tecn         educ_supr       educ_mest
 Min.   :0.0000   Min.   :0.00000   Min.   :0.000   Min.   :0.0000
 1st Qu.:0.0000   1st Qu.:0.00000   1st Qu.:0.000   1st Qu.:0.0000
 Median :1.0000   Median :0.00000   Median :0.000   Median :0.0000
 Mean   :0.6066   Mean   :0.09836   Mean   :0.377   Mean   :0.2459
```

```
 3rd Qu.:1.0000   3rd Qu.:0.00000   3rd Qu.:1.000   3rd Qu.:0.0000
 Max.   :1.0000   Max.   :1.00000   Max.   :1.000   Max.   :1.0000
   educ_dout
 Min.   :0.0000
 1st Qu.:0.0000
 Median :0.0000
 Mean   :0.1639
 3rd Qu.:0.0000
 Max.   :1.0000
```

```
mod01 <- glm(emprestimo ~ ., data=emp, family="binomial")
summary(modlog)
```

```
Warning message:
“glm.fit: algorithm did not converge”
Warning message:
“glm.fit: fitted probabilities numerically 0 or 1 occurred”



Call:
glm(formula = emprestimo ~ pont_credito, family = "binomial",
    data = emp)

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept)  -79.3401    35.7382  -2.220   0.0264 *
pont_credito   0.1214     0.0549   2.212   0.0270 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 70.2041  on 60  degrees of freedom
Residual deviance:  9.8871  on 59  degrees of freedom
AIC: 13.887

Number of Fisher Scoring iterations: 9
```

```
predito_prob <- predict(mod01, type="response")
```

```
predito <- ifelse(predito_prob > 0.5, 1, 0)
```

```
library(caret)
matriz_confusao <- confusionMatrix(data=as.factor(predito),
                                   reference=as.factor(emp$emprestimo),
                                   positive="1")
matriz_confusao
```

```
Confusion Matrix and Statistics

          Reference
Prediction  0  1
         0 16  0
         1  0 45
```

```
               Accuracy : 1
                 95% CI : (0.9413, 1)
    No Information Rate : 0.7377
    P-Value [Acc > NIR] : 8.727e-09

                  Kappa : 1

 Mcnemar's Test P-Value : NA

            Sensitivity : 1.0000
            Specificity : 1.0000
         Pos Pred Value : 1.0000
         Neg Pred Value : 1.0000
             Prevalence : 0.7377
         Detection Rate : 0.7377
   Detection Prevalence : 0.7377
      Balanced Accuracy : 1.0000

       'Positive' Class : 1
```

Como os dados são sintéticos (fabricados), o modelo acabou sendo perfeito pois a `pont_credito` foi suficiente. Vamos supor que não havia esta variável.

```
str(emp)
```

```
'data.frame':   61 obs. of  9 variables:
 $ emprestimo  : num  1 1 0 1 1 0 1 0 1 1 ...
 $ renda       : num  0.2199 -0.4688 -1.5768 0.8188 -0.0795 ...
 $ pont_credito: num  0.14527 -0.40259 -1.63529 0.96707 0.00831 ...
 $ sexo_f      : num  0 1 0 1 0 1 0 1 0 1 ...
 $ casado      : num  1 0 0 1 1 0 1 0 1 1 ...
 $ educ_tecn   : num  0 0 0 0 0 1 0 0 0 0 ...
 $ educ_supr   : num  1 0 0 1 1 0 0 1 0 0 ...
 $ educ_mest   : num  0 1 0 0 0 0 0 0 1 0 ...
 $ educ_dout   : num  0 0 0 0 0 0 1 0 0 1 ...
```

```
mod02 <- glm(emprestimo ~ renda + sexo_f + casado + educ_tecn +
                          educ_supr + educ_mest + educ_dout,
             data=emp, family="binomial")
summary(mod02)
```

```
Warning message:
“glm.fit: fitted probabilities numerically 0 or 1 occurred”
```

```
Call:
glm(formula = emprestimo ~ renda + sexo_f + casado + educ_tecn +
    educ_supr + educ_mest + educ_dout, family = "binomial", data = emp)

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept)     2.857      2.375   1.203   0.2291
```

```
renda           5.753      3.281   1.753   0.0796 .
sexo_f         -2.621      3.733  -0.702   0.4826
casado         37.539  11313.639   0.003   0.9974
educ_tecn     -15.937   8021.320  -0.002   0.9984
educ_supr       2.355      3.797   0.620   0.5350
educ_mest      24.514  14810.916   0.002   0.9987
educ_dout      20.754  17434.994   0.001   0.9991
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 70.2041  on 60  degrees of freedom
Residual deviance:  6.6358  on 53  degrees of freedom
AIC: 22.636

Number of Fisher Scoring iterations: 22
```

Aparentemente a `renda` também é um bom indicador. Vamos construir um modelo só com a `renda`.

```
mod03 <- glm(emprestimo ~ renda, data=emp, family="binomial")
summary(mod03)
```

```

Call:
glm(formula = emprestimo ~ renda, family = "binomial", data = emp)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)    4.817      1.664   2.895  0.00379 **
renda          6.352      2.022   3.141  0.00169 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 70.204  on 60  degrees of freedom
Residual deviance: 20.428  on 59  degrees of freedom
AIC: 24.428

Number of Fisher Scoring iterations: 8
```

```
predito_prob <- predict(mod03, type="response")
```

```
predito <- ifelse(predito_prob > 0.5, 1, 0)
```

```
library(caret)
matriz_confusao <- confusionMatrix(data=as.factor(predito),
                                   reference=as.factor(emp$emprestimo),
                                   positive="1")
matriz_confusao
```

```
Confusion Matrix and Statistics
```

```
          Reference
Prediction  0  1
         0 15  2
         1  1 43

               Accuracy : 0.9508
                 95% CI : (0.8629, 0.9897)
    No Information Rate : 0.7377
    P-Value [Acc > NIR] : 1.633e-05

                  Kappa : 0.8754

 Mcnemar's Test P-Value : 1

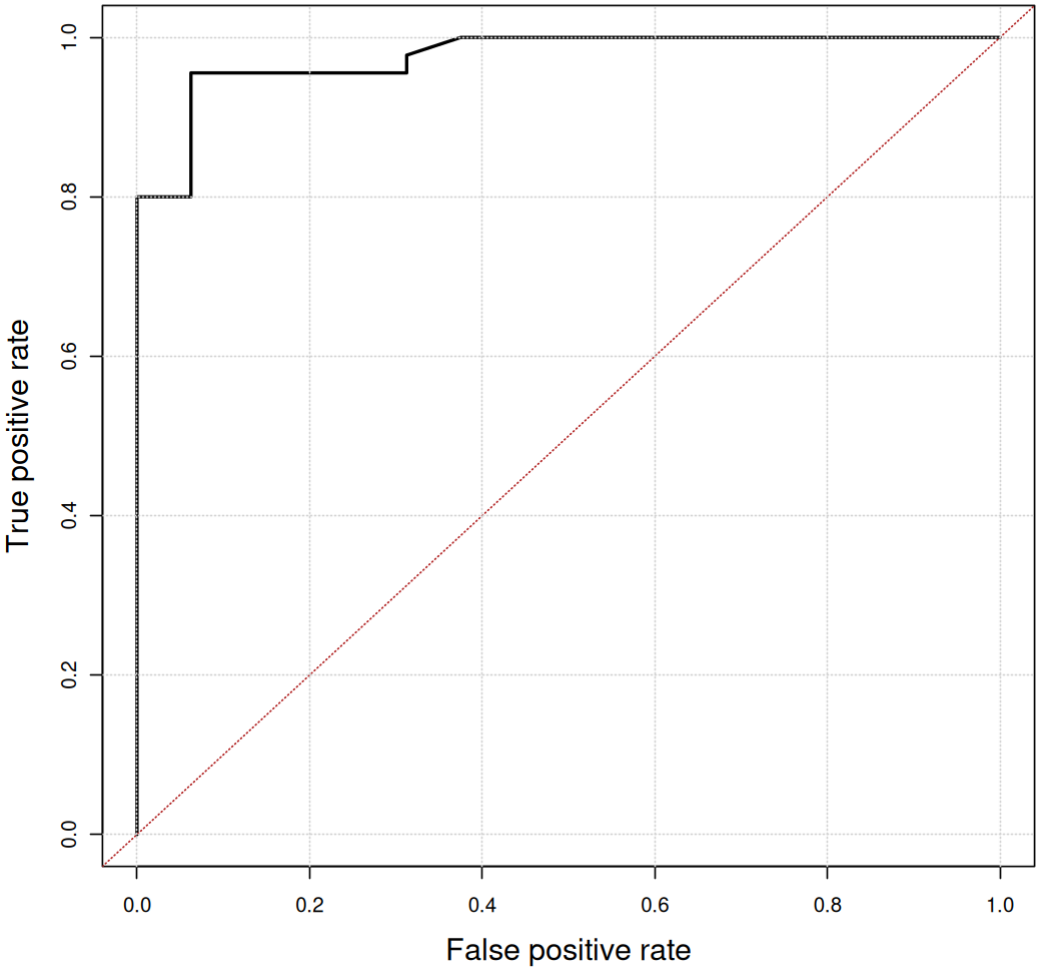
            Sensitivity : 0.9556
            Specificity : 0.9375
         Pos Pred Value : 0.9773
         Neg Pred Value : 0.8824
             Prevalence : 0.7377
         Detection Rate : 0.7049
   Detection Prevalence : 0.7213
      Balanced Accuracy : 0.9465

       'Positive' Class : 1
```

```r
predito_roc <- prediction(predito_prob, emp$emprestimo)
```

```r
roc_modelo <- performance(predito_roc, measure="tpr", x.measure="fpr")
```

```r
grafdim(9,9)
plot(roc_modelo, cex.lab=1.5, lwd=2)
abline(a=0, b=1, col="firebrick", lty=3)
grid(nx=NULL)
```




```
auc_perf   <- performance(predito_roc, "auc")
auc_modelo <- auc_perf@y.values[[1]]
cat("Área sob a curva ROC:",auc_modelo)
```

```
Área sob a curva ROC: 0.9756944
```

Referências

1. Modelling proportions: logistic regression
2. Logistic regression
3. Regressão Logística
4. Loan Eligible Dataset
5. Curva ROC: Como avaliar modelos de classificação
6. Classificação: ROC e AUC
7. A Complete Guide to ROC Curves and AUC
8. ROC curve and AUC: An Intuitive Approach and Implementation Guide