Estudo sobre Florestas Aleatórias

Modelagem

Cláudio M. Zaina

Índice

Floresta Aleatória (*Random Forest*) **1**
Caso 1: Titanic . . . 1
Preparação do ambiente . . . 1
Bibliotecas . . . 2
Funções . . . 2
Dados . . . 3
Separação em treino e validação . . . 4
Escolha das variáveis . . . 5
Classe . . . 5
Sexo . . . 7
Idade . . . 8
Modelo . . . 9
Matriz de Confusão - Preditos Treinamento . . . 11
Matriz de Confusão - Preditos Validação . . . 11
Modelo com `Age` (idade) ajustada . . . 13
Matriz de Confusão para Preditos do Treinamento . . . 16
Matriz de Confusão para Preditos da Validação . . . 17
Gráfico das Acurácias Balanceadas . . . 18

Referências **19**

Floresta Aleatória (*Random Forest*)

Caso 1: Titanic

[6] Random Forest Classifier
Referência local
Kaggle:Titanic

Preparação do ambiente

```
rm(list=ls())
options(digits=3)
```

Bibliotecas

```
library(rpart)         # árvores de decisão
library(rpart.plot)    # gráficos de árvores
library(readr)         # leitura de csv
library(repr)          # representações (ajuste gráfico do jupyter)
library(caret)         # matriz de confusão
library(caTools)       # ferramentas em geral; no caso função que divide datasets
library(rattle)        # bibliotecas para o fancyRpartPlot
library(RColorBrewer)  # gradientes de cores

library(randomForest)  #
```

```
Loading required package: ggplot2

Loading required package: lattice

Loading required package: tibble

Loading required package: bitops

Rattle: A free graphical interface for data science with R.
Version 5.5.1 Copyright (c) 2006-2021 Togaware Pty Ltd.
Type 'rattle()' to shake, rattle, and roll your data.

randomForest 4.7-1.2

Type rfNews() to see new features/changes/bug fixes.


Attaching package: ‘randomForest’


The following object is masked from ‘package:rattle’:

    importance


The following object is masked from ‘package:ggplot2’:

    margin
```

Funções

```
grafdim <- function(x=11, y=9) {
    options(repr.plot.width=x, repr.plot.height=y)
}

exc <- function(antes, depois) {
    print(paste("Excluídos:", (antes-depois), ", Restaram:", depois))
}
```

```
grafdim()
```

Dados

```
titanic.train <- read.csv("/home/max/ref/d/dataset/titanic_train.csv")
```

```
summary(titanic.train)
```

```
  PassengerId     Survived         Pclass         Name
 Min.   :  1   Min.   :0.000   Min.   :1.00   Length:891
 1st Qu.:224   1st Qu.:0.000   1st Qu.:2.00   Class :character
 Median :446   Median :0.000   Median :3.00   Mode  :character
 Mean   :446   Mean   :0.384   Mean   :2.31
 3rd Qu.:668   3rd Qu.:1.000   3rd Qu.:3.00
 Max.   :891   Max.   :1.000   Max.   :3.00

     Sex                 Age           SibSp           Parch
 Length:891         Min.   : 0.4   Min.   :0.00   Min.   :0.00
 Class :character   1st Qu.:20.1   1st Qu.:0.00   1st Qu.:0.00
 Mode  :character   Median :28.0   Median :0.00   Median :0.00
                    Mean   :29.7   Mean   :0.52   Mean   :0.38
                    3rd Qu.:38.0   3rd Qu.:1.00   3rd Qu.:0.00
                    Max.   :80.0   Max.   :8.00   Max.   :6.00
                    NA's   :177
    Ticket               Fare        Cabin             Embarked
 Length:891         Min.   :  0   Length:891         Length:891
 Class :character   1st Qu.:  8   Class :character   Class :character
 Mode  :character   Median : 14   Mode  :character   Mode  :character
                    Mean   : 32
                    3rd Qu.: 31
                    Max.   :512
```

```
cat("Há", nrow(titanic.train),
    "observações no conjunto de dados fornecido como treinamento")
```

```
Há 891 observações no conjunto de dados fornecido como treinamento
```

Variáveis de interesse: - `Survived` : `0` se não sobreviveu; `1` se sobreviveu; - `Pclass`: classe do passageiro (1ª, 2ª ou 3ª classe); - `Sex`: sexo (`female`, `male`); - `Age`: idade; - `SibSp`: número de irmãos, marido/esposa acompanhantes; - `Parch`: número de pais ou filhos acompanhantes; - `Fare`: quanto o passageiro pagou na passagem; - `Embraked`: onde o passageiro embarcou (`C` - Cherbourg, `Q` - Queenstown, `S` - Southpampton).

```
preparar <- function(df) {
    res             <- data.frame(factor(df$Survived))
    res$Pclass      <- factor(df$Pclass, ordered=TRUE, levels=c(1:3), labels=c("1ª","2ª","3ª"))
    res$Sex         <- factor(df$Sex)
    res$Age         <- df$Age
    res$SibSp       <- factor(df$SibSp, levels=c(0:8))
    res$Parch       <- factor(df$Parch, levels=c(0:9))
```

```
    res$Fare        <- df$Fare
    emb             <- df$Embarked
    emb[emb == ""]  <- NA
    res$Embarked    <- factor(emb)

    names(res)[1] <- "Survived"
    return(res)
}
```

```
titanic <- preparar(titanic.train)
summary(titanic)
```

```
 Survived Pclass       Sex           Age           SibSp         Parch
 0:549    1ª:216   female:314   Min.   : 0.4   0      :608   0      :678
 1:342    2ª:184   male  :577   1st Qu.:20.1   1      :209   1      :118
          3ª:491                Median :28.0   2      : 28   2      : 80
                                Mean   :29.7   4      : 18   3      :  5
                                3rd Qu.:38.0   3      : 16   5      :  5
                                Max.   :80.0   8      :  7   4      :  4
                                NA's   :177    (Other):  5   (Other):  1
      Fare     Embarked
 Min.   :  0   C   :168
 1st Qu.:  8   Q   : 77
 Median : 14   S   :644
 Mean   : 32   NA's:  2
 3rd Qu.: 31
 Max.   :512
```

Separação em treino e validação

```
(num_obs   <- nrow(titanic))
tx_teste   <- 0.2
tx_valid   <- 0.2
(num_teste <- trunc(num_obs * tx_teste))
(num_valid <- trunc(num_obs * tx_valid))
(num_trein <- num_obs - num_teste - num_valid)
```

891

178

178

535

```
set.seed(997)
treino   <- titanic
amostra  <- sample(1:num_obs, num_teste, replace=FALSE)
teste    <- treino[ amostra, ]
treino   <- treino[-amostra, ]
```

```r
amostra  <- sample(1:(num_obs - num_teste), num_valid, replace=FALSE)
valid    <- treino[ amostra, ]
treino   <- treino[-amostra, ]
```

```r
cat("Há:\n",
    nrow(treino), "observações no conjunto de treinamento,\n",
    nrow(teste),  "observações no conjunto de teste,\n",
    nrow(valid),  "observações no conjunto de validação,\n"
   )
```

```
Há:
 535 observações no conjunto de treinamento,
 178 observações no conjunto de teste,
 178 observações no conjunto de validação,
```

```r
# save(treino, valid, teste, file="dados/titanic.RData")
```

```r
# load("dados/titanic.RData")
```

Convém avaliar se a proporção de positivos/negativos se mantém nos conjuntos de teste e validação:

```r
proporcao_pos <- function(df, positivo) {
    return (round(sum(df$Survived==positivo)/nrow(df),4))
}
```

```r
cat("Proporção de sobreviventes nos conjuntos:\n",
    "treino:\t", proporcao_pos(treino, 1),
    "\n validação:\t", proporcao_pos(valid, 1),
    "\n teste:\t\t", proporcao_pos(teste, 1))
```

```
Proporção de sobreviventes nos conjuntos:
 treino:     0.359
 validação:  0.444
 teste:      0.399
```

A proporção de sobreviventes é próxima nos três conjuntos.

Escolha das variáveis

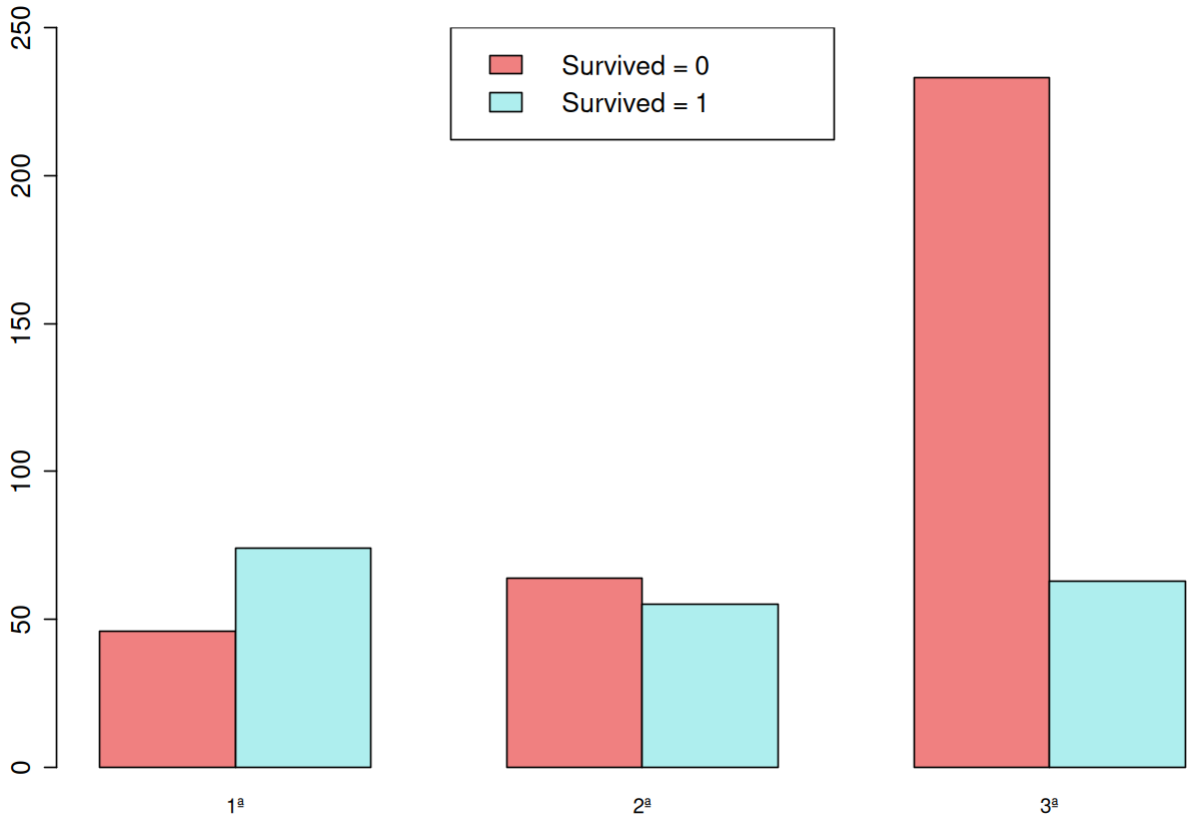
Classe

Avaliando o comportamento de sobreviventes com classe (`Survived` × `Pclass`)

```r
(tab <- table(treino[,c('Survived', 'Pclass')]))
```

```
        Pclass
Survived  1ª  2ª  3ª
       0  46  64 233
       1  74  55  63
```

```r
grafdim(11,8)
barplot(tab, beside=TRUE, col=c("lightcoral","paleturquoise2"),
        ylim=c(0,250), cex.axis=1.3)
legend("top", legend=c("Survived = 0", "Survived = 1"),
       fill=c("lightcoral","paleturquoise2"), cex=1.3)
```

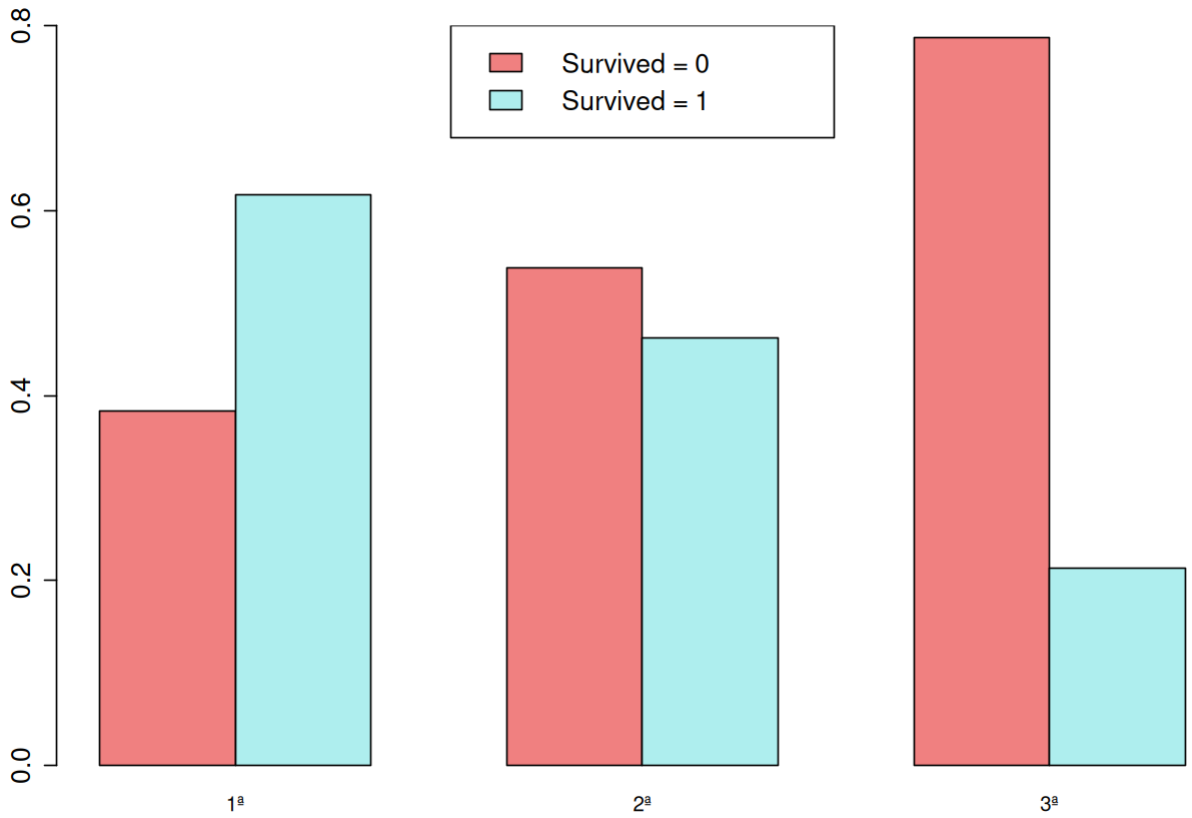


Proporcionalmente:

```r
(tab_prop <- prop.table(tab, margin=2))
```

```
        Pclass
Survived    1ª    2ª    3ª
       0 0.383 0.538 0.787
       1 0.617 0.462 0.213
```

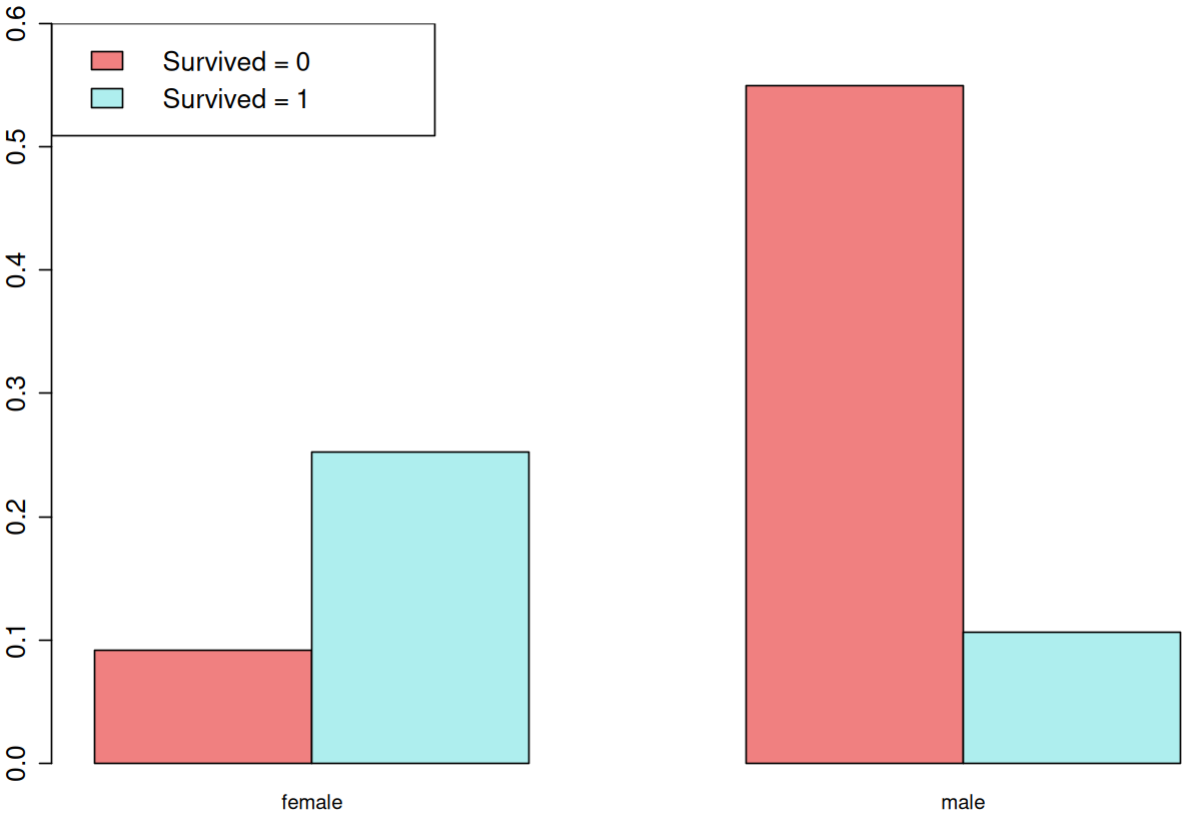
```r
barplot(tab_prop, beside=TRUE, col=c("lightcoral","paleturquoise2"),
        ylim=c(0,0.8), cex.axis=1.3)
legend("top", legend=c("Survived = 0", "Survived = 1"),
       fill=c("lightcoral","paleturquoise2"), cex=1.3)
```



Proporcionalmente, a taxa de sobreviventes cai da 1ª para a 3ª classe.

Sexo

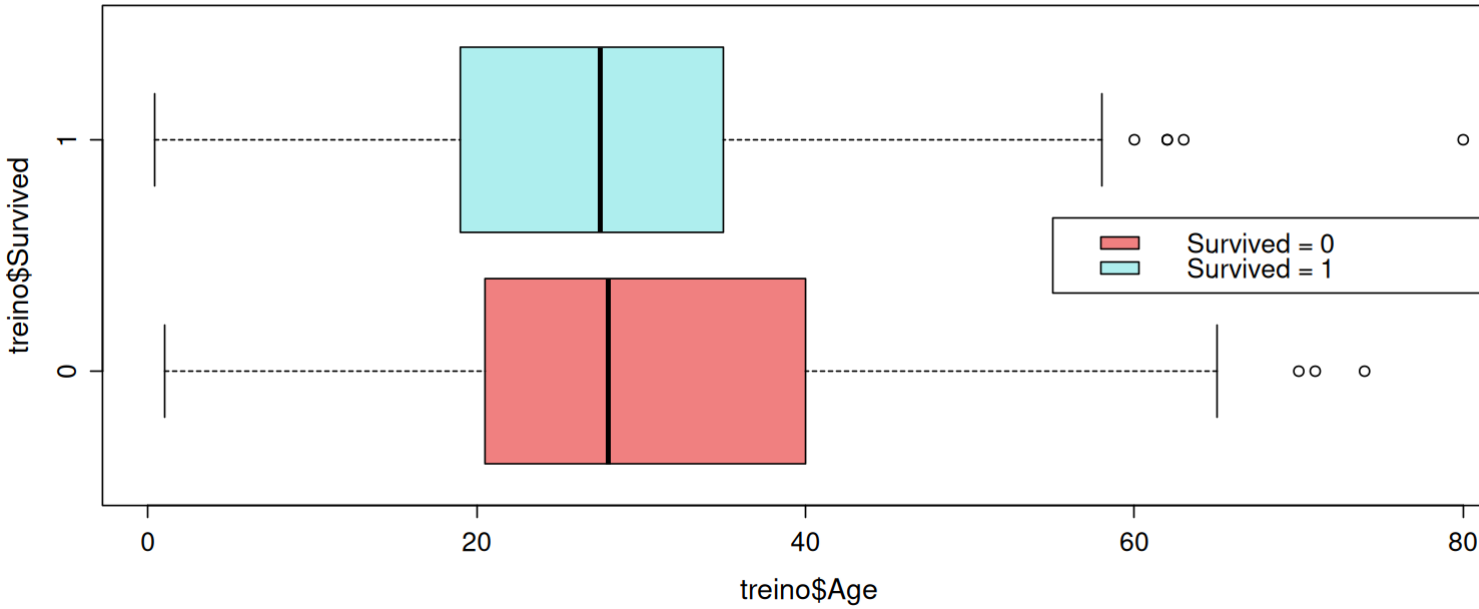
```
grafdim(11,8)
barplot(prop.table(table(treino[,c('Survived', 'Sex')])),
        beside=TRUE, col=c("lightcoral","paleturquoise2"),
        ylim=c(0,0.6), cex.axis=1.3)
legend("topleft", legend=c("Survived = 0", "Survived = 1"),
       fill=c("lightcoral","paleturquoise2"), cex=1.3)
```



Há poucos sobreviventes dentre os homens.

Idade

```
grafdim(13,6)
boxplot(treino$Age ~ treino$Survived, horizontal=TRUE,
        col=c("lightcoral","paleturquoise2"), cex.axis=1.3, cex.lab=1.4)
legend("right", legend=c("Survived = 0", "Survived = 1"),
       fill=c("lightcoral","paleturquoise2"), cex=1.3)
```



Não parece haver distinção de sobreviventes em função da idade.

Modelo

```
set.seed(997)
```

A variável `Age` não será usada pois não apresenta distinção entre sobreviventes ou não e possui muitos dados indisponíveis (`NA`s).

Os `NA`s da variável `Embarked` foram convertidos para a classe mais frequente, no caso, `S`. Deve ser feito tanto para o treino quanto para a validação e o teste..

```
summary(treino$Embarked)
summary(valid$Embarked)
summary(teste$Embarked)
```

C 108Q
53S
372NA's
2

C 33Q
14S
131

C 27Q
10S
141

Dependendo da aleatoridade da separação, os 2 `NA`s podem estar em qualquer grupo. Apenas o treino possui `NA`s para `Embarked`.

```r
treino[is.na(treino$Embarked),"Embarked"] <- "S"
valid[is.na(valid$Embarked),"Embarked"] <- "S"
teste[is.na(teste$Embarked),"Embarked"] <- "S"
```

```r
summary(treino$Embarked)
summary(valid$Embarked)
summary(teste$Embarked)
```

C 108Q
53S
374

C 33Q
14S
131

C 27Q
10S
141

```r
mod_bas <- train(Survived ~ Pclass + Sex + SibSp + Parch + Fare + Embarked,
                 data=treino,
                 method='rf',                          # algoritmo de "random forest"
                 trControl=trainControl(method="cv"), # usar validação cruzada
                 number=5)                             # usar 5 fatias (folds) para val. cruz.
```

```r
trn_pred <- predict(mod_bas)
trn_obs  <- treino$Survived
```

```r
(confmat <- confusionMatrix(table(trn_obs, trn_pred)))
```

```
Confusion Matrix and Statistics

       trn_pred
trn_obs   0   1
      0 338   5
      1  26 166

               Accuracy : 0.942
                 95% CI : (0.919, 0.96)
    No Information Rate : 0.68
    P-Value [Acc > NIR] : < 2e-16

                  Kappa : 0.871

 Mcnemar's Test P-Value : 0.000328

            Sensitivity : 0.929
            Specificity : 0.971
         Pos Pred Value : 0.985
         Neg Pred Value : 0.865
             Prevalence : 0.680
         Detection Rate : 0.632
   Detection Prevalence : 0.641
```

```
      Balanced Accuracy : 0.950

       'Positive' Class : 0
```

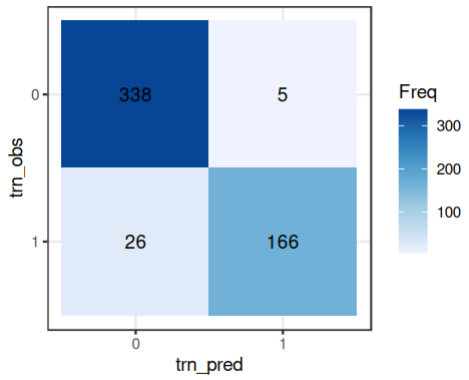
```
(acc_bal_baseline <- confmat$byClass["Balanced Accuracy"])
```

Balanced Accuracy: 0.949665831244779

Matriz de Confusão - Preditos Treinamento

```
cmtab <- data.frame(confmat$table)
cmtab$trn_obs <- factor(cmtab$trn_obs, levels=rev(unique(cmtab$trn_obs)))
```

```
grafdim(4,4)
ggplot(cmtab, aes(x=trn_pred, y=trn_obs, fill=Freq)) +
    geom_tile() + theme_bw() + # tira o fundo cinza
    coord_equal() +
    # palhetas: Reds, Blues, Spectral, RdYlBu, Greens
    scale_fill_distiller(palette="Blues", direction=1) +
#    guides(fill=F) + # tira a legenda Fill
    geom_text(aes(label=Freq), color="black") # rótulos
```




```
val_pred <- predict(mod_bas, newdata=valid)
#trn_pred <- mod_bas$pred
val_obs  <- valid$Survived
```

Matriz de Confusão - Preditos Validação

```
(confmat <- confusionMatrix(table(val_obs, val_pred)))
```

```
Confusion Matrix and Statistics

       val_pred
val_obs  0  1
      0 83 16
      1 25 54
```

```
               Accuracy : 0.77
                 95% CI : (0.701, 0.829)
    No Information Rate : 0.607
    P-Value [Acc > NIR] : 3.03e-06

                  Kappa : 0.528

 Mcnemar's Test P-Value : 0.212

            Sensitivity : 0.769
            Specificity : 0.771
         Pos Pred Value : 0.838
         Neg Pred Value : 0.684
             Prevalence : 0.607
         Detection Rate : 0.466
   Detection Prevalence : 0.556
      Balanced Accuracy : 0.770

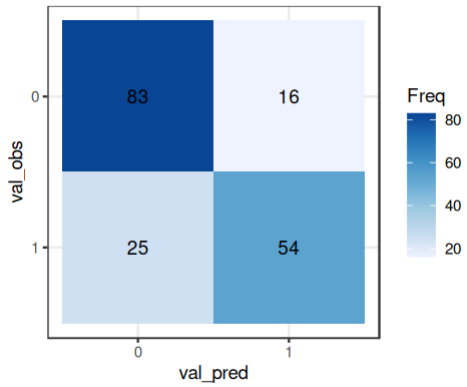
       'Positive' Class : 0
```

```
(acc_bal_baseline_val <- confmat$byClass["Balanced Accuracy"])
```

Balanced Accuracy: 0.769973544973545

```
cmtab <- data.frame(confmat$table)
cmtab$val_obs <- factor(cmtab$val_obs, levels=rev(unique(cmtab$val_obs)))
```

```
grafdim(4,4)
ggplot(cmtab, aes(x=val_pred, y=val_obs, fill=Freq)) +
    geom_tile() + theme_bw() + # tira o fundo cinza
    coord_equal() +
    # palhetas: Reds, Blues, Spectral, RdYlBu, Greens
    scale_fill_distiller(palette="Blues", direction=1) +
#    guides(fill=F) + # tira a legenda Fill
    geom_text(aes(label=Freq), color="black") # rótulos
```



Modelo com `Age` (idade) ajustada

```
nrow(treino)
summary(treino$Age)
```

535

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
    0.4    20.0    28.0    29.3    38.0    80.0     115
```

Apesar da grande quantidade de dados ausentes (107 dentre 534, 20%) seria possível agregar a informação da idade em um modelo, utilizando recursos de contorno como, por exemplo, atribuindo ao valor desconhecido a média de seu grupo, em um esforço de mínima interferência no comportamento da variável.

```
table(treino$Sex,treino$Pclass)
```

```
        1ª  2ª  3ª
  female  54  45  85
  male    66  74 211
```

```
(sexo   <- unique(treino$Sex))
(classe <- sort(unique(treino$Pclass)))
```

1. male
2. female

Levels: 1. 'female' 2. 'male'

1. 1ª
2. 2ª
3. 3ª

Levels: 1. '1ª' 2. '2ª' 3. '3ª'

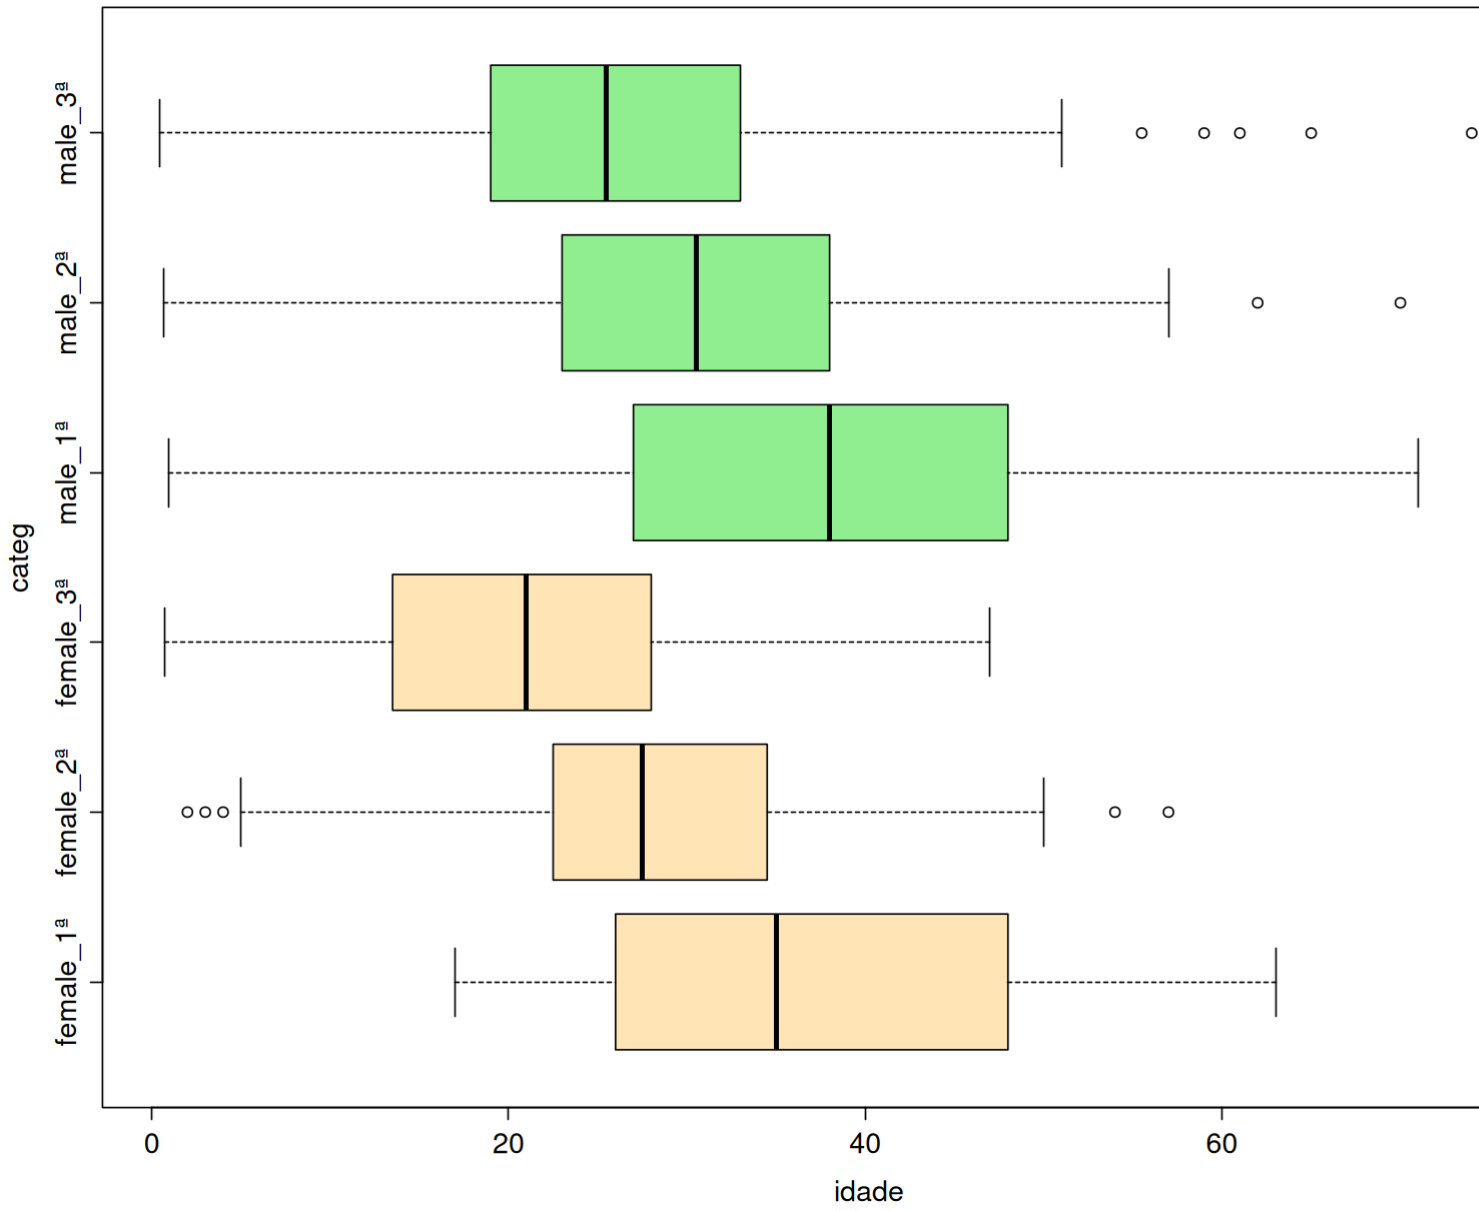
```
(s <- sexo[1])
(p <- classe[1])
```

male **Levels**: 1. 'female' 2. 'male'

1ª **Levels**: 1. '1ª' 2. '2ª' 3. '3ª'

```
idade <- c()
categ <- c()
for (s in sexo) {
    for (p in classe) {
        dados <- treino$Age[treino$Sex==s & treino$Pclass==p]
        categ <- c(categ, rep(paste(s,"_",p, sep=""), length(dados)))
        idade <- c(idade, dados)
    }
}
```

```
grafdim(14,11)
boxplot(idade ~ categ, horizontal=TRUE,
        col=c(rep("moccasin",3),rep("lightgreen",3)), cex.lab=1.4, cex.axis=1.4)
rm(dados,categ,idade)
```




```
treino$Age_original <- treino$Age
valid$Age_original  <- valid$Age
```

```
treino$Age[is.na(treino$Age)] <- mean(treino$Age, na.rm=TRUE)
valid$Age[is.na(valid$Age)] <- mean(valid$Age, na.rm=TRUE)
```

```
summary(treino)
```

```
 Survived Pclass       Sex           Age           SibSp         Parch
 0:343    1ª:120   female:184   Min.   : 0.4   0      :359   0      :412
```

```
 1:192    2ª:119   male  :351   1st Qu.:22.0   1      :131   1      : 66
          3ª:296                Median :29.3   2      : 16   2      : 50
                                Mean   :29.3   4      : 13   3      :  3
                                3rd Qu.:34.0   3      :  9   4      :  2
                                Max.   :80.0   8      :  4   5      :  2
                                               (Other):  3   (Other):  0
      Fare     Embarked  Age_original
 Min.   :  0   C:108    Min.   : 0.4
 1st Qu.:  8   Q: 53    1st Qu.:20.0
 Median : 14   S:374    Median :28.0
 Mean   : 30            Mean   :29.3
 3rd Qu.: 30            3rd Qu.:38.0
 Max.   :512            Max.   :80.0
                        NA's   :115
```

```r
summary(valid)
```

```
 Survived Pclass      Sex           Age            SibSp         Parch
 0:99     1ª:50   female: 70   Min.   : 0.8   0      :127   0      :135
 1:79     2ª:33   male  :108   1st Qu.:22.0   1      : 40   1      : 25
          3ª:95                Median :30.7   2      :  5   2      : 16
                               Mean   :30.7   3      :  2   5      :  1
                               3rd Qu.:36.0   4      :  2   6      :  1
                               Max.   :71.0   5      :  1   3      :  0
                                              (Other):  1   (Other):  0
      Fare     Embarked  Age_original
 Min.   :  0   C: 33    Min.   : 0.8
 1st Qu.:  8   Q: 14    1st Qu.:21.0
 Median : 16   S:131    Median :30.0
 Mean   : 37            Mean   :30.7
 3rd Qu.: 39            3rd Qu.:39.0
 Max.   :512            Max.   :71.0
                        NA's   :35
```

```r
mod_age <- train(Survived ~ Pclass + Sex + SibSp + Parch + Fare + Embarked + Age,
                 data=treino,
                 method='rf',                        # algoritmo de "random forest"
                 trControl=trainControl(method="cv"), # usar validação cruzada
                 number=5)                           # usar 5 fatias (folds) para val. cruz.
```

```r
print(mod_age)
```

```
Random Forest

535 samples
  7 predictor
  2 classes: '0', '1'

No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 481, 482, 482, 481, 482, 482, ...
Resampling results across tuning parameters:
```

```
  mtry  Accuracy  Kappa
   2    0.770     0.423
  13    0.826     0.612
  24    0.809     0.578

Accuracy was used to select the optimal model using the largest value.
The final value used for the model was mtry = 13.
```

```
trn_pred_age <- predict(mod_age)
trn_obs_age  <- treino$Survived
```

```
(confmat <- confusionMatrix(table(trn_obs_age, trn_pred_age)))
```

```
Confusion Matrix and Statistics

           trn_pred_age
trn_obs_age   0   1
          0 340   3
          1  14 178

               Accuracy : 0.968
                 95% CI : (0.95, 0.981)
    No Information Rate : 0.662
    P-Value [Acc > NIR] : <2e-16

                  Kappa : 0.93

 Mcnemar's Test P-Value : 0.0153

            Sensitivity : 0.960
            Specificity : 0.983
         Pos Pred Value : 0.991
         Neg Pred Value : 0.927
             Prevalence : 0.662
         Detection Rate : 0.636
   Detection Prevalence : 0.641
      Balanced Accuracy : 0.972

       'Positive' Class : 0
```

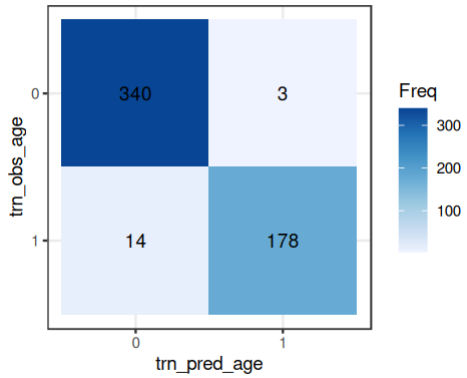
```
(acc_bal_age_trn <- confmat$byClass["Balanced Accuracy"])
```

Balanced Accuracy: 0.971938695882886

Matriz de Confusão para Preditos do Treinamento

```
cmtab <- data.frame(confmat$table)
cmtab$trn_obs_age <- factor(cmtab$trn_obs_age, levels=rev(unique(cmtab$trn_obs_age)))
```

```
grafdim(4,4)
ggplot(cmtab, aes(x=trn_pred_age, y=trn_obs_age, fill=Freq)) +
    geom_tile() + theme_bw() + # tira o fundo cinza
    coord_equal() +
    # palhetas: Reds, Blues, Spectral, RdYlBu, Greens
    scale_fill_distiller(palette="Blues", direction=1) +
#    guides(fill=F) + # tira a legenda Fill
    geom_text(aes(label=Freq), color="black") # rótulos
```



Matriz de Confusão para Preditos da Validação

```
val_pred_age <- predict(mod_age, newdata=valid)
#trn_pred <- mod_bas$pred
val_obs_age  <- valid$Survived
```

```
(confmat <- confusionMatrix(table(val_obs_age, val_pred_age)))
```

```
Confusion Matrix and Statistics

           val_pred_age
val_obs_age  0  1
          0 87 12
          1 29 50

               Accuracy : 0.77
                 95% CI : (0.701, 0.829)
    No Information Rate : 0.652
    P-Value [Acc > NIR] : 0.000446

                  Kappa : 0.523

 Mcnemar's Test P-Value : 0.012462

            Sensitivity : 0.750
            Specificity : 0.806
         Pos Pred Value : 0.879
         Neg Pred Value : 0.633
             Prevalence : 0.652
```

```
         Detection Rate : 0.489
   Detection Prevalence : 0.556
      Balanced Accuracy : 0.778

       'Positive' Class : 0
```

```
(acc_bal_age_val <- confmat$byClass["Balanced Accuracy"])
```

Balanced Accuracy: 0.778225806451613

```
cmtab <- data.frame(confmat$table)
cmtab$val_obs_age <- factor(cmtab$val_obs_age, levels=rev(unique(cmtab$val_obs_age)))
```

```
grafdim(4,4)
ggplot(cmtab, aes(x=val_pred_age, y=val_obs_age, fill=Freq)) +
    geom_tile() + theme_bw() + # tira o fundo cinza
    coord_equal() +
    # palhetas: Reds, Blues, Spectral, RdYlBu, Greens
    scale_fill_distiller(palette="Blues", direction=1) +
#    guides(fill=F) + # tira a legenda Fill
    geom_text(aes(label=Freq), color="black") # rótulos
```

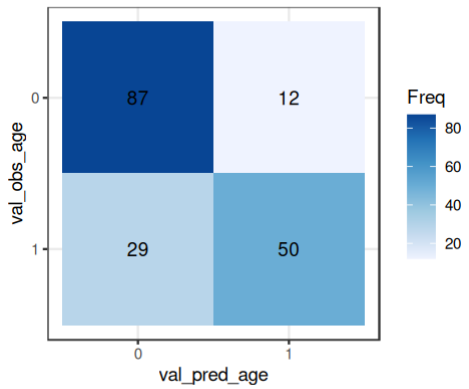


Gráfico das Acurácias Balanceadas

```
nom <- c("baseline", "modelo age")
(abt <- c(acc_bal_baseline, acc_bal_age_trn))
(abv <- c(acc_bal_baseline_val,acc_bal_age_val))
```

Balanced Accuracy 0.949665831244779Balanced Accuracy 0.971938695882886

Balanced Accuracy 0.769973544973545Balanced Accuracy 0.778225806451613

```
acc_bal_baseline
```

Balanced Accuracy: 0.949665831244779

```
grafdim(8,7)
```

```
modelo   <- factor(c(1,1), labels=c("age"))
conjunto <- factor(c(1,2), labels=c("treino","validação"))
acuracia <- c(acc_bal_age_trn, acc_bal_age_val)
dfab <- data.frame(modelo, acuracia, conjunto)
rm(conjunto,acuracia,modelo)
dfab
```

A data.frame: 2 × 3

modelo <fct>	acuracia <dbl>	conjunto <fct>
age	0.972	treino
age	0.778	validação

Referências

1. Random Forest with R - www.listendata.com/2014/11/random-forest-with-r
2. R Random Forest Tutorial - https://www.guru99.com/r-random-forest-tutorial.html
3. Complete Tutorial on Random Forest in R - https://www.edureka.co/blog/random-forest-classifier